

Подробный EDM-анализ

Modular addition, p=211 · OmniGrok-style Transformer · AdamW · fixed weight decay 0.0

Статус эксперимента: отрицательный контроль. Модель быстро меморизует train, но не генерализует за 200 000 шагов. Этот запуск нельзя описывать как delayed generalization и в нём нет grokking transition или post-grok фазы.

Параметр	Значение
Исходный лог	training_log_p_211_wd_0.csv
Weight decay	0.0 (фиксированный)
Строк / шагов	4001 / 1–200000
Стабильная меморизация	2250
Grokking	не произошёл
Финальная accuracy	train=1.000, val=0.036
Лучшая val accuracy	0.0425
Финальный val loss	226.258

EDM рассчитан с $\tau=1$ строка логa (≈ 50 optimizer steps), $W=200$ строк (≈ 10000 шагов), $\text{stride}=100$ строк (≈ 5000 шагов), $E=15$, $k=5$. Перекрытие соседних окон равно 50%. В каждом detrended-окне независимо удалён линейный тренд.

Контроль происхождения: SHA-256 исходного CSV: 289b1df41696656e58842900f5ba740c477257c815320ac6b13be90cc54ae3cc.

1. Трассировка обучения




Рис. 1. Сырые метрики обучения. Пунктир отмечает stable memorization; линии grokking нет, поскольку событие отсутствует.

Train accuracy стабилизируется выше 0.99 около шага 2050, однако validation accuracy остаётся около случайного уровня: максимум 0.0425, финал 0.0361. Validation loss возрастает до 226.3. Weight norm, в отличие от WD=0.5, растёт с 43.3 до 125.8.

Следовательно, это режим memorization without generalization. В дальнейшем временная ось делится только на ранний, средний и поздний участки наблюдения; эти участки не называются fitting/gap/transition/post-grok.

2. Что именно оценивает EDM

Из каждой одномерной метрики $x(t)$ строится delay embedding: $X(t)=[x(t), x(t-\tau), \dots, x(t-(E-1)\tau)]$. EDM-оценка характеризует локальную геометрию облака таких задержанных векторов, а не число параметров сети и не ранг отдельной матрицы.

В отчёте сохранены FNN, Cao, Simplex и арифметическая локальная MLE Levina–Bickel. MacKay–Ghahramani (MG) использует pooled likelihood: сначала усредняется локальная обратная размерность, затем результат инвертируется. MG менее чувствительна к отдельным почти нулевым log-distance sums, из-за которых арифметическая LB может взрываться

Абсолютные значения следует считать диагностическими: соседние delay vectors перекрываются, Theiler exclusion не использован, а $W=200$ оставляет лишь 186 векторов при $E=15$. Поэтому основной объект сравнения — устойчивое изменение кривой при фиксированном протоколе, а не буквальное число активных параметров.

3. Все методы на train/validation loss

Loss observables: estimator comparison

Blue = train, red = validation; pale = raw, saturated = linearly detrended




Figure 2. Each panel is one estimator. Colour distinguishes train/validation; saturation distinguishes raw/detrended. X: EDM window centre in 10^3 optimizer updates. FNN/Cao/Simplex Y: embedding dimension E ; LB/MG Y: intrinsic dimension d . All Y axes are linear; triangles mark values above a labelled display cap.

К концу запуска MG-ID обеих loss-метрик снижается, однако validation accuracy не растёт. Это напрямую показывает, что dimension drop не является достаточным условием grokking: подобный сигнал может сопровождать насыщение, численное вырождение loss или упрощение наблюдаемой скалярной динамики без генерализации.

4. Основные одномерные наблюдатели

Core observers: pooled MG estimate, detrended windows




Figure 3a. Primary MG-ID curves for detrended windows. X: EDM window centre in 10^3 optimizer updates; Y: intrinsic dimension d on a linear scale. Arithmetic LB remains in separate diagnostic files and does not distort the MG scale.

4. Основные одномерные наблюдатели — продолжение

Participation-ratio and entropy observers: pooled MG estimate




Figure 3b. Participation-ratio and entropy observers. Splitting the ten panels across two pages keeps labels legible without changing data or scales.

5. Интерпретация основных наблюдателей

MG-ID показывает нисходящий временной тренд для train loss, validation loss, weight norm, gradient norm, parameter participation ratio и энтропий. Но gradient participation ratio остаётся примерно стационарным, а gradient cosine меняется без единого направленного коллапса. Получается не единый согласованный переход динамической системы, а метрико-зависимое упрощение части наблюдаемых рядов.

Арифметическая LB периодически принимает огромные значения — до сотен и тысяч, а для отдельных raw/projection окон ещё выше. Это не физический рост размерности. Причина — локальные оценки вида $1/s$, где s является малой суммой логарифмов отношений kNN-расстояний. Один почти нулевой s создаёт очень большой локальный d , после чего арифметическое среднее взрывается. MG агрегирует s до инверсии и потому остаётся устойчивее.

Медианные MG-ID по трём равным временным участкам

Метрика	Ранний	Средний	Поздний
train loss	2.75	2.42	1.50
validation loss	3.76	3.13	1.77
weight norm	2.28	2.01	1.52
gradient norm	3.30	2.47	1.75
gradient cosine	9.48	8.35	8.41
gradient participation ratio	9.43	9.62	9.82

Эта таблица особенно важна для критерия будущего grokking: validation-loss MG-ID падает примерно с 3.76 до 1.77, хотя генерализации нет. Следовательно, предиктор не должен срабатывать только по условию $d(t) < \text{threshold}$ или $\Delta d < 0$.

6. Фиксированные случайные проекции

Fixed random projections: LB and MG: MacKay-Ghahramani pooled estimate; detrended windows




Рис. 4. MG-ID detrended loss-, weight-, gradient- и update-проекции. X — центр EDM-окна в 10^3 optimizer updates; Y — intrinsic dimension d [dimensions] на линейной шкале.

Проекции не образуют согласованного набора предикторов. Одна фиксированная случайная проекция может быть почти ортогональна информативному направлению, а gradient projection дополнительно содержит mini-batch noise. Поэтому отдельный r0 нельзя трактовать как надёжное измерение глобального состояния; нужен ансамбль проекций и агрегирование устойчивости эффекта между г.

7. Raw и detrended

MacKay-Ghahramani estimate: raw versus linearly detrended windows




Рис. 5. MG-ID: светлые линии — raw, насыщенные — линейно detrended. X — центр EDM-окна в 10^3 optimizer updates; Y — intrinsic dimension d [dimensions], линейная шкала.

Detrending выполнен независимо в каждом окне обычной least-squares прямой. Он удаляет только линейный дрейф уровня, но не исправляет насыщение, ступени, гетероскедастичность, выбросы или временную корреляцию. Raw и detrended являются разными диагностическими представлениями и в отчёте не смешиваются.

8. Временное резюме без вымышленных фаз

Temporal summary after memorization: descriptive periods, not grokking phases




Рис. 6. Медианы по ранней, средней и поздней третям доступных окон. Это описательные периоды non-generalizing trajectory, а не grokking phases.

9. Робастность к длине окна

Window-length sensitivity of MG estimate; detrended windows




Рис. 7. MG для $W \in \{100, 150, 200, 250\}$ строк лога, то есть примерно $\{5, 7.5, 10, 12.5\} \times 10^3$ optimizer updates. Все оценки detrended; X — центр окна в 10^3 optimizer updates, Y — intrinsic dimension d [dimensions] на линейной шкале.

Качественный поздний спад MG наблюдается при нескольких W , но это не делает его grokking-specific: validation ассигасу при этом остаётся низкой. Размер окна заметно меняет абсолютный уровень и временную локализацию оценки, поэтому W , stride, τ , E , k и logging cadence должны быть одинаковыми во всех сравниваемых запусках.

10. Вывод для критерия раннего предсказания

Этот ablation опровергает слишком простой критерий «размерность упала $\square$ скоро grokking». Падение ID наблюдается и в запуске, который меморизовал train, но не начал генерализовать. Поэтому dimension drop разумно считать только одним компонентом составного критерия.

Рабочий визуальный критерий должен требовать одновременно: (1) устойчивого падения MG-ID на нескольких последовательных trailing windows; (2) согласованности хотя бы между несколькими заранее выбранными наблюдателями; (3) отсутствия объяснения простым насыщением или численным floor/ceiling; (4) отличия от распределения таких же признаков на non-grokking controls; (5) достаточного lead time до заранее фиксированного порога validation accuracy.

Для текущего проекта особенно полезна контрастная пара WD=0.5 versus WD=0. В WD=0.5 падение размерности связано с резким validation transition; в WD=0 оно происходит без transition. Следующий статистический шаг — измерять не наличие падения само по себе, а форму, скорость, согласованность и специфичность падения относительно отрицательных контролей.

11. Ограничения

1. Один seed не позволяет оценить межзапусковую вариативность.
2. Центрированные окна используют данные по обе стороны center step; для честного online predictor нужны trailing windows.
3. Theiler exclusion отсутствует, поэтому временно соседние delay vectors могут искусственно уменьшать расстояния.
4. $W=200$ и $E=15$ дают только 186 delay vectors.
5. Арифметическая LB нестабильна при почти нулевых log-distance sums; MG предпочтительнее как основная кривая.
6. Участки early/middle/late выбраны описательно и не являются подтверждёнными динамическими фазами.
7. EDM скалярного лога оценивает размерность наблюдаемой временной динамики, а не число активных параметров сети.

12. Файлы воспроизводимости

Исходный лог: training_log_p_211_wd_0.csv

EDM-окна: tau1_edm_windows_all_methods.csv

Исправленное временное резюме: wd0_corrected_temporal_summary.csv

Аудит источников и параметров: corrected_report_audit.json

Сборщик отчёта: build_p211_wd0_corrected_report.py

Итог

WD=0 является чистым non-grokking control: сеть меморизует train, validation остаётся около случайного уровня, а weight norm растёт. Некоторые MG-ID кривые при этом заметно снижаются. Следовательно, падение размерности — потенциально полезный, но неспецифичный индикатор перестройки наблюдаемой динамики; для прогноза grokking необходим контроль ложных срабатываний и составной критерий.