

Подробный EDM-анализ гроккинга

Modular addition, p=211 · OmniGrok-style Transformer · AdamW · fixed weight decay 0.5

Отчёт по файлу `training_log_p_211_wd_0_point_5.csv`. Для всех реконструкций временного ряда зафиксировано $t=1$. Основной sliding-window анализ использует $W=200$ строк лога ($\approx 10\,000$ шагов), $\text{stride}=10$ строк (≈ 500 шагов), максимальную размерность задержанного вложения $E=15$ и $k=5$ ближайших соседей.

Строк лога	1024
Диапазон	1–51150 шагов
Стабильная меморизация	13650
Гроккинг	46150
Гар по флагам	32500 шагов
Гар по асс $\geq$ 0.95	38200 шагов
Финальные ассурасу	train=1.000, val=1.000
Время обучения	12.1 мин

Главный результат. В логе есть выраженный режим *delayed generalization*: модель стабильно запоминает *train* около шага 13 650, а флаг *genuine grokking* возникает около 46 150. EDM-кривые не дают единственного истинного числа параметров», но показывают смену геометрии наблюдаемой динамики ещё до резкого роста *validation accuracy*.

1. Траектория обучения и фазы




Рис. 1. Это сырой (raw) тренировочный лог: здесь показаны непосредственно train/validation loss, accuracy и weight norm; detrending и EDM к этим кривым не применяются. Синие/красные пунктирные линии — зафиксированные моменты stable memorization и genuine grokking. Между ними gap $\approx 32.5k$ шагов; по порогу accuracy ≥ 0.95 gap $\approx 38.2k$.

Train accuracy достигает 0.95 около шага 7 750 и 0.99 около 13 450. Validation accuracy остаётся почти нулевой большую часть обучения, достигает 0.5 лишь около 44 700 и затем быстро поднимается до 0.95 около 45 950. Одновременно weight norm после раннего максимума около 88 монотонно уменьшается примерно до 37 — характерный след сильной регуляризации и перехода к более простому решению.

Последние 5 000 шагов недостаточны для полноценного post-grok sliding-window окна $W=10\,000$ шагов. Поэтому фазовые средние для post-grok отсутствуют: это свойство длины записи, а не ошибка расчёта.

2. Что именно измеряется

Из каждого одномерного наблюдателя $x(t)$ строится delay embedding:

$$X_t = [x(t), x(t-\tau), \dots, x(t-(E-1)\tau)], \quad \tau=1.$$

Размерность в отчёте — локальная геометрическая сложность облака таких векторов внутри окна. Это размерность реконструированной динамики конкретного scalar observer, а не число весов модели, не ранг матрицы слоя и не автоматически ранг LoRA. Один scalar observable может при корректной реконструкции кодировать многомерную динамику, но оценка зависит от наблюдаемости, длины окна, шума, кривизны, нестационарности и масштаба соседства.

Перед расчётом detrended-версии в каждом окне методом наименьших квадратов находится прямая $x(i)=a \cdot i+b$ и вычитается. После этого ряд стандартизуется. Так устраняется простое направленное движение среднего, чтобы оценка в большей степени отражала локальные степени свободы колебаний, а не один доминирующий тренд.

Использованы четыре проектных EDM-диагностики: (1) false nearest neighbours (FNN), (2) критерий Cao, (3) simplex projection и (4) kNN maximum-likelihood intrinsic dimension Levina–Bickel. Дополнительно на всех графиках размерности показана агрегация MacKay–Ghahramani.

Оценки FNN/Cao/Simplex имеют иной смысл и дискретную процедуру выбора E , поэтому их абсолютные значения нельзя считать взаимозаменяемыми с kNN-ID. Согласованное изменение нескольких методов важнее совпадения чисел.

Важно: соседние sliding windows перекрываются на 95%, поэтому кривые пригодны для диагностики эволюции, но точки на них не являются независимыми статистическими повторностями.

3. Levina–Bickel и MacKay–Ghahramani

Для каждой точки X_i delay-облака обозначим через $T_j(X_i)$ расстояние до j -го ближайшего соседа. При локально постоянной плотности число точек в шаре моделируется пуассоновским процессом; рост объёма шара как r^d позволяет восстановить d из отношений соседних радиусов.

$$d_i^* = \left\{ \left(1/(k-1) \right) \sum_{j=1}^{k-1} \log[T_k(X_i)/T_j(X_i)] \right\}^{-1}$$

В используемой legacy-версии Levina–Bickel глобальное число получается арифметическим средним локальных оценок:

$$d_{LB}^* = (1/N) \sum_{i=1}^N d_i^*.$$

MacKay–Ghahramani предлагают сначала объединять аддитивные log-distance statistics, то есть усреднять обратные локальные оценки, и только затем инвертировать:

$$d_{MG}^* = \left\{ (1/N) \sum_{i=1}^N d_i^{*-1} \right\}^{-1} = \left\{ [1/(N(k-1))] \sum_{i,j} \log[T_k/T_j] \right\}^{-1}.$$

Следовательно, MG численно является гармоническим средним локальных d_i^* , но мотивация глубже простой «замены среднего ради устойчивости». В пуассоновской likelihood естественно складываются log-distance evidence / inverse-dimension statistics; инверсия каждой шумной локальной оценки до усреднения создаёт выпуклостный (Jensen) upward bias. Пулинг sufficient statistics выполняется раньше нелинейной инверсии и поэтому обычно меньше реагирует на редкие огромные локальные d_i^* .

Так как гармоническое среднее не превосходит арифметическое, MG систематически ниже LB. Это не две разные физические размерности и не доказательство того, что меньшая цифра «истиннее» в каждом окне; это две агрегации одного и того же локального kNN evidence с разными bias/variance свойствами.

В данном анализе $k=5$, $E=15$, евклидово расстояние, без Theiler exclusion. Последнее важно: соседние delay vectors временно коррелированы, поэтому абсолютные ID следует считать диагностическими. Для строгой оценки нужны Theiler window, несколько k , bootstrap по неперекрывающимся блокам и более длинная post-grok запись.

4. Все четыре EDM-метода на loss

Raw versus detrended EDM estimates on train/validation loss




Рис. 2. Верхний ряд — RAW-окна; нижний ряд — DETREND, где в каждом окне вычтена своя линейная регрессия. Это явное сравнение preprocessing для четырёх EDM-методов.

Four EDM diagnostics on linearly detrended losses; MG-ID overlaid




Рис. 3. Все панели выше — только detrended. Raw и detrended оценки сохранены раздельно в tau1_edm_windows_all_methods.csv. Красная MG-ID validation loss — общий kNN-MLE reference.

Для validation loss MG-ID в основной части гар держится примерно в диапазоне 6–8, достигает максимума ≈ 8.14 около 24.5k, затем после $\approx 40k$ быстро падает: среднее 3.07 на 40k–46.15k и ≈ 2.09 на 45k–48k. LB показывает от же коллапс (примерно $9 \rightarrow 4 \rightarrow 3$), но на более высоком уровне.

Это наиболее сильный ранний геометрический сигнал в отчёте: падение ID начинается за несколько тысяч шагов до formal grok flag и совпадает с уходом validation loss с плато. Однако это detection/concurrent precursor, а не доказанный причинный или универсально предсказывающий маркер.

Train loss ведёт себя иначе: MG-ID растёт примерно с 7.5 в раннем участке до 9.7–10.4 во время gap и не коллапсирует перед гроккингом. Поэтому train и validation observers видят разные стороны динамики; validation loss здесь действительно информативнее для перехода генерализации.

5. Численные фазовые оценки

Средние detrended-оценки по окнам, полностью попадающим в memorization gap:

Метрика	FNN	Cao	Simplex	LB	MG
train loss	4.02	5.64	11.53	13.12	10.14
validation loss	3.98	5.38	3.16	9.00	6.60
weight norm	4.29	5.80	3.82	10.12	7.20
gradient norm	5.64	5.44	11.36	6.79	4.88
update norm	4.20	6.33	11.76	12.24	9.36
gradient cosine	3.64	5.87	10.42	16.69	12.32
gradient PR	5.22	6.80	10.82	10.99	7.36
parameter PR	4.24	5.78	4.87	9.62	6.83

В gap MG даёт: train loss 10.14, validation loss 6.60, weight norm 7.20, gradient norm 4.88, update norm 9.36, gradient cosine 12.32. LB соответственно выше: 13.12, 9.00, 10.12, 6.79, 12.24, 16.69.

При переходных окнах validation loss резко падает с MG 6.60 до 2.77 (–58%), weight norm — с 7.20 до 3.27 (–55%), тогда как gradient norm растёт с 4.88 до 5.98 (+22%) и update norm с 9.36 до 10.42 (+11%). Картина согласуется со сжатием наблюдаемой loss/weight геометрии при одновременной активизации градиентной динамики.

Simplex для train loss резко выше в gap (11.53), но для validation loss остаётся низким (3.16). Это расхождение подчёркивает, что simplex выбирает predictive embedding dimension, а kNN-MLE оценивает локальную геометрию; одно число нельзя подставлять вместо другого.

Phase summary: arithmetic LB versus MacKay--Ghahramani




Рис. 4. Фазовые средние LB и MG. Белая колонка post-grok — отсутствие полного окна после перехода, а не нулевая размерность.

6. Основные scalar observers




Рис. 5. На каждом графике фиолетовая кривая — арифметическая LB, красная — pooled/harmonic MG. Все кривые здесь detrended; синяя вертикаль — memorization, красная — grokking.

7. Фиксированные случайные проекции

Fixed random projections: Levina--Bickel and MacKay--Ghahramani (linear trend removed independently in each window)




Рис. 6. Одномерные фиксированные random projections losses, weights, gradients и updates. Все размерности рассчитаны на detrended окнах; для компактности показан r0.

8. Raw против detrended

Raw versus linearly detrended ID; both LB and MG aggregations




Рис. 7. Прозрачные линии — raw, непрозрачные — после локального linear detrending. Разница показывает вклад монотонного дрейфа в геометрию окна.

Detrending не является нейтральным: он намеренно удаляет одну простую временную компоненту. Поэтому raw и detrended отвечают на разные вопросы. Raw ID описывает наблюдаемую траекторию целиком; detrended ID — остаточную локальную сложность вокруг лучшего линейного движения. Для задач раннего детектирования полезно логировать обе версии.

Нельзя интерпретировать detrended ID как прямое количество обучаемых весовых компонент. В частности, scalar validation loss является нелинейной функцией параметров и данных; разные parameter-space направления могут давать одинаковый loss, а одно направление — сложную временную кривую.

9. Робастность к длине окна

Window-length sensitivity of MG ID with LB reference




Рис. 8. $W \in \{100, 150, 200, 250\}$ строк лога, то есть приблизительно 5k–12.5k optimizer steps. Пунктир — LB при $W=200$; оценки detrended.

Среднее MG меняется с W умеренно: validation loss $\approx 5.66 \rightarrow 6.13$, gradient norm $\approx 4.81 \rightarrow 5.17$, weight norm $\approx 5.68 \rightarrow 6.15$, train loss $\approx 8.75 \rightarrow 9.63$. Формы ключевых переходов сохраняются, но абсолютное значение возрастает с окном. Поэтому в сравнении экспериментов W , logging cadence, t , E и k должны быть одинаковыми.

$W=200$ — компромисс: в delay cloud остаётся $N=W-E+1=186$ точек. Этого достаточно для дешёвой диагностики, но мало для точной высокой ID; особенно с $k=5$ и сильной временной корреляцией. Значения вблизи $E=15$ также потенциально насыщаются потолком embedding dimension.

10. Чувствительность к E и k




Рис. 9. MG-ID в заранее выбранном участке memorization gap для $E \in \{6, 9, 12, 15\}$, $k \in \{5, 8, 10, 15\}$; оценка выполнена после detrending.

Разброс по сетке значителен: train loss MG 5.10–10.96, validation loss 3.78–5.48, weight norm 4.14–6.67, gradient norm 3.53–5.51. Следовательно, абсолютную цифру нельзя представлять без гиперпараметров оценки. Более надёжны относительные изменения при фиксированном протоколе и устойчивость знака эффекта по нескольким E/k.

Рост k снижает variance, но усредняет более крупный и потенциально искривлённый участок многообразия; малый k лучше локализует геометрию, но чувствителен к шуму и конечной выборке. E должен быть достаточно большим для unfolding, однако слишком большой E при коротком окне ухудшает kNN distances и усиливает curse of dimensionality.

11. Интерпретация для проекта

Что поддерживается данными. (i) Run демонстрирует genuine delayed generalization с большим gap. (ii) Геометрия validation loss резко упрощается перед/во время перехода: MG-ID падает приблизительно с 6–8 до 2, LB — с 8–11 до ≈ 3 . (iii) Weight-norm ID тоже коллапсирует, тогда как gradient-norm ID растёт к переходу. (iv) MG воспроизводит основные формы LB, но даёт меньшие и менее подверженные локальным выбросам значения.

Что пока не доказано. Нельзя по одному seed утверждать универсальный predictor гроккинга; нельзя считать MG=6.6 «шестью активными параметрами»; нельзя напрямую выбрать LoRA rank=7. EDM одного scalar observable оценивает effective state-space complexity видимой динамики, а LoRA rank — размерность линейного подпространства обновления конкретной матрицы с требованием знать направления.

Практическое применение. Эти кривые полезны как дешёвые online phase indicators: детектор plateau $\rightarrow$ sustained ID shift $\rightarrow$ validation transition; как критерий сравнения optimizer/WD; как сигнал для adaptive checkpointing/early warning; как способ выбрать моменты для дорогих parameter-space probes. Для layer-wise pruning/LoRA EDM лучше использовать только как проху для бюджета, а направления и ранг проверять gradient/update sketches, randomized SVD или спектром ковариации обновлений.

Для честного прогноза следует обучить detector только на префиксе каждого run и оценивать lead time до заранее не использованного grok threshold на новых seeds/moduli. Сглаживание и окна нельзя центрировать через будущие точки в online-сценарии: текущий центрированный график использует данные с обеих сторон центра.

Рекомендуемый следующий эксперимент: 5–10 seeds при $p=211$ и два контрольных режима (не грокнувший и ранне-генерализующий), одинаковые $W/t/E/k$, causal trailing windows, Theiler exclusion $\approx E \cdot t$, $k \in \{5, 8, 10, 15\}$, bootstrap по блокам. Основной candidate score: стандартизованное падение MG-ID validation loss плюс рост MG-ID gradient norm; оценивать AUROC и median lead time.

12. Ограничения и воспроизводимость

1. Один run и один seed; статистической оценки межзапусковой вариативности нет.
2. Logging stride 50 шагов; $\tau=1$ означает задержку именно в одну строку лога, то есть ≈ 50 optimizer steps.
3. В delay embedding соседние точки перекрываются и временно коррелированы; Theiler exclusion не применён.
4. Окна $W=200$ дают только 186 delay vectors при $E=15$.
5. Сильная нестационарность нарушает локально-стационарные предпосылки kNN likelihood; detrending исправляет лишь линейную часть.
6. Центрированные окна визуально могут создавать look-ahead; для реального мониторинга нужны trailing windows.
7. Эффекты возле конца ряда оценены хуже и полноценного post-grok окна нет.
8. Random projections r_0 являются scalar sketches, а не layer-wise intrinsic rank.

Файлы воспроизводимости

Скрипт анализа: analyze_p211_wd05_edm.py

Окна всех методов: tau1_edm_windows_all_methods.csv

Фазовые средние: phase_dimension_summary.csv

Window robustness: window_robustness_lb_mg.csv

E/k sensitivity: E_k_sensitivity_lb_mg.csv

Моменты переходов: transition_metadata.json

Источники метода

E. Levina, P. J. Bickel. Maximum Likelihood Estimation of Intrinsic Dimension, NeurIPS 2004/2005.

D. J. C. MacKay, Z. Ghahramani. Comments on 'Maximum Likelihood Estimation of Intrinsic Dimension', 2005, inference.org.uk/mackay/dimension/.

H. Kantz, T. Schreiber. Nonlinear Time Series Analysis — delay embeddings and nonlinear diagnostics.

L. Cao. Practical method for determining the minimum embedding dimension of a scalar time series, Physica D, 1997.

Вывод

Наиболее репрезентативный сигнал этого run — не абсолютная ID, а согласованный предгрокинг-коллапс LB/MG размерности validation loss и weight norm при росте сложности gradient dynamics. MacKay–Ghahramani логично использовать как основную kNN-MLE агрегацию, потому что она пулингует аддитивную likelihood-информацию до инверсии и уменьшает upward bias от экстремальных локальных оценок. При этом LB стоит сохранять рядом как диагностический индикатор неоднородности: большой разрыв LB–MG означает широкий/тяжёлохвостый набор локальных $\mathcal{L}$.

Отчёт автоматически собран из CSV и артефактов анализа; дата сборки: 03.08.2026.