

Сравнительный EDM-анализ режимов обучения nanoGPT

Фиксированная задержка $\tau = 1$

Технический отчёт по восьми логам из `nanogpt_muon_edm`

30 июля 2026 г.

Аннотация

Восемь завершённых nanoGPT-запусков проанализированы единым скользящим EDM-конвейером при $\tau = 1$. Для каждого ряда training loss использованы FNN, метод Cao, simplex projection и Levina–Bickel MLE, отдельно для исходного и локально detrended ряда. Логи образуют два размеченных режима: `lmo` при learning rate 0.06 (пять запусков) и `sign` при learning rate 0.03 (три запуска). Ни один режим не демонстрирует согласованного позднего dimensionality collapse: FNN слабо снижается, но simplex и MLE растут во всех восьми запусках. Это descriptive negative/control result; одиночные запуски и разные learning rate не позволяют ранжировать оптимизаторы статистически.

1 Данные и методика

Каждый лог содержит 2330 последовательных наблюдений training loss (шаги 0–2329) и 11 validation-loss точек. Восстановленный training loss нормализован к token-level cross-entropy. Для каждого запуска рассчитано 49 скользящих окон: длина 400 шагов, сдвиг 40 шагов. В итоге получено 392 строки оконного анализа.

Во всех окнах использованы фиксированная задержка $\tau = 1$, максимальная размерность embedding $E_{max} = 15$ и $k = 5$ соседей для MLE. “Early” и “late” — средние соответственно первых и последних 12 окон. Анализ повторён для raw loss и после удаления локального линейного тренда. Последнее окно имеет центр на шаге 2120, поэтому extension, начинающийся на шаге 2290, отдельно этим оконным анализом не измеряется.

2 Результаты запусков

Таблица 1: Итоговые показатели запусков.

Оптимизатор	Режим	LR	Final val	Best val	Время, s
Muon	lmo	0.06	3.2785	3.2785	143.8
MuonUSign	lmo	0.06	3.2959	3.2959	143.6
EF21-MuonUSign	lmo	0.06	3.3203	3.3203	144.5
EF21-MuonSign	lmo	0.06	5.5198	4.1967	144.6
EF21-SignMuon	lmo	0.06	3.2860	3.2860	144.5
SignMuon	sign	0.03	3.2881	3.2881	144.3
MuonSign	sign	0.03	3.3249	3.3249	143.1
SignSGD	sign	0.03	3.4049	3.4049	143.2

Семь exact/server-моделей заканчивают в узком диапазоне 3.2785–3.4049. EF21-MuonSign требует отдельной интерпретации: exact/server модель заканчивается на 5.5198, в то время как logged compressed/broadcast модель W заканчивается на 3.3213. Поэтому среднее final validation loss режима `lmo` искажено этой разницей состояний; его медиана равна 3.2959.




Рис. 1: Validation loss всех восьми запусков.




Рис. 2: EF21-MuonSign: exact/server модель и broadcast-модель W.

3 Сводка четырёх EDM-методов

В таблице приведено направление изменения late минус early по всем восьми оптимизаторам. Абсолютные величины разных методов не являются взаимозаменяемыми: важна согласованность направления изменения.

Таблица 2: Изменение оценок размерности: late минус early.

Ряд	Метод	Снижение	Без изм.	Рост	Среднее Δ
Raw	FNN	5	2	1	-0.32
Raw	Cao	1	0	7	+0.46
Raw	Simplex	0	0	8	+3.61
Raw	MLE	0	0	8	+1.83
Detrended	FNN	5	1	2	-0.27
Detrended	Cao	3	0	5	+0.10
Detrended	Simplex	0	0	8	+1.99
Detrended	MLE	0	0	8	+0.68

Simplex и MLE увеличиваются в каждом запуске как для raw, так и для detrended loss. FNN является пороговой целочисленной эвристикой, а Cao выбирает первое плато своей кривой, поэтому их слабые и неоднородные сдвиги не образуют подтверждения коллапса.




Рис. 3: Направления изменений по всем четырём методам.

4 MLE по каждому методу оптимизации

Таблица 3: Полная сводка MLE. Δ равно late минус early.

Оптимизатор	Режим	Raw early	Raw late	Δ	Detr. early	Detr. late	Δ
Muon	lmo	12.88	14.77	+1.89	14.39	15.30	+0.91
MuonUSign	lmo	13.06	15.40	+2.34	14.39	15.02	+0.62
EF21-MuonUSign	lmo	12.48	14.91	+2.43	14.52	15.21	+0.69
EF21-MuonSign	lmo	12.62	14.78	+2.17	14.27	15.33	+1.06
EF21-SignMuon	lmo	13.83	14.64	+0.81	14.34	15.09	+0.75
SignMuon	sign	13.82	14.94	+1.12	14.82	15.16	+0.34
MuonSign	sign	12.97	14.81	+1.84	14.58	15.27	+0.69
SignSGD	sign	12.93	14.93	+2.01	14.70	15.09	+0.39

Во всех восьми случаях MLE возрастает. Detrending уменьшает средний рост, но не меняет его знак; следовательно, даже остаточная локальная геометрия этого скалярного наблюдаемого не

демонстрирует позднего collapse.




Рис. 4: Траектории Levina-Bickel MLE для raw и detrended loss.




Рис. 5: Ранние и поздние MLE-оценки каждого оптимизатора.

5 Сравнение режимов обучения

Таблица 4: Описательное сравнение режимов.

Режим	LR	n	Final mean	Final median	Raw MLE Δ	Detr. MLE Δ
lmo	0.06	5	3.7401	3.2959	+1.93	+0.81
sign	0.03	3	3.3393	3.3249	+1.66	+0.47

После detrending поздние средние MLE почти совпадают: 15.19 для **lmo** и 15.17 для **sign**. Рост несколько больше в **lmo** (+0.81 против +0.47), но это не статистически установленное различие: сравниваются 5 и 3 неоднородных одиночных запуска, а семейство оптимизатора смешано с learning rate.




Рис. 6: Средние MLE-оценки двух размеченных режимов.

Для остальных методов оба режима сходятся в основной картине: FNN слабо уменьшается, simplex увеличивается, MLE увеличивается. Cao raw меняет знак между режимами (+0.98 у **lmo**, -0.42 у **sign**), однако после detrending оба сдвига малы (+0.07 и +0.17); это похоже на чувствительность plateau-правила Cao, а не на надёжное различие динамики обучения.

6 Ограничения и вывод

1. На оптимизатор имеется один запуск; seed не записан.
2. Режимы смешаны с learning rate: **lmo**=0.06, **sign**=0.03.
3. Окна перекрываются на 90% и не являются независимыми репликами.
4. Legacy nearest-neighbour методы не используют Theiler window.
5. Simplex часто выбирает границу $E = 15$; MLE иногда превышает 15 и должен трактоваться как выход эвристики, а не буквальная ID.
6. Скалярный stochastic mini-batch loss не описывает полное состояние оптимизатора или геометрию весов.

Таким образом, при фиксированном $\tau = 1$ эти восемь nanoGPT-запусков не демонстрируют estimator-robust позднего dimensionality collapse в скалярном training loss. Материал годится как negative/control case для статьи: EDM-вывод зависит от выбранного observable и оценителя, а не даёт здесь надёжного способа отличить два режима обучения.

Воспроизводимость. Исходные итоговые таблицы: `results_batch_tau1/optimizer_run_summary.csv`, `tau1_early_late_all_methods.csv`, `training_regime_summary.csv`; полный конвейер — `analyze_batch_tau1.py`