

EDM-анализ Muon/nanoGPT: фиксированная задержка $\tau = 1$ и четыре метода

Технический отчёт по `message (2).txt`

30 июля 2026 г.

Аннотация

Для плотного ряда training loss одного запуска Muon/nanoGPT проведён скользящий анализ с фиксированной задержкой $\tau = 1$. Использованы все четыре метода размерностного анализа из существующего проекта: False Nearest Neighbors, Cao, simplex projection и Levina–Bickel MLE. Методы не дают согласованного свидетельства позднего dimensionality collapse: FNN слабо снижается, в то время как Cao, simplex и MLE в среднем растут или остаются высокими. Результат является negative/control case, а не свидетельством grokking-перехода.

1 Данные и режим расчёта

Из `icomp_article/message (2).txt` извлечён один завершённый запуск `Muon_lr0.06_5db64adc`: 2330 последовательных значений training loss и 11 validation-loss точек. Training loss в исходном логе является усреднённой между GPU суммой loss локального батча; для анализа он нормализован к token-level cross-entropy делением на 32768. Validation loss используется лишь как внешний индикатор: 11 точек недостаточно для корректной фазовой реконструкции.

Во всех окнах длиной 400 шагов со сдвигом 40 использована фиксированная задержка $\tau = 1$ и максимальная размерность embedding $E_{max} = 15$. Методы вызываются непосредственно из `code/Grokking/search_for_optimal_parameters.py` с настройками существующего pipeline: FNN выбирает первое E с долей false neighbours ниже 1%, Cao использует первое $|\Delta E_1| < 0.05$, simplex выбирает минимальный one-step out-of-sample RMSE, а MLE использует $k = 5$ соседей.

Пунктирная вертикаль на рисунках — начало learning-rate cooldown (шаг около 1260), точечная — начало 40-шагового extension (2290).

2 Четыре метода при $\tau = 1$

FNN даёт значения около 3–7 и слабое позднее снижение. Cao имеет постоянное $E = 2$ до cooldown, затем преимущественно принимает значения 6–8 и возвращается к 2 в последних окнах. Simplex имеет очень неустойчивый аргумент минимума RMSE и часто выбирает верхнюю границу $E = 15$. MLE непрерывно растёт с ранних значений около 11–13 к поздним 14–16.

Таблица 1: Средние первых и последних 12 скользящих окон. Изменение равно late минус early.

Метод	Raw loss			Detrended loss		
	Early	Late	Δ	Early	Late	Δ
FNN	4.42	4.17	-0.25	4.17	3.67	-0.50
Cao	2.00	4.25	+2.25	5.58	6.33	+0.75
Simplex	10.08	13.17	+3.08	10.00	12.00	+2.00
MLE ID	12.88	14.77	+1.89	14.39	15.30	+0.91




Рис. 1: Training и validation loss исходного запуска вместе с learning-rate schedule.

3 Критерии выбора размерности

FNN — пороговая дискретная эвристика, поэтому снижение на 0.25–0.50 не является сильным структурным эффектом. В поздних окнах процент false neighbours не достигает устойчивого нуля при малых E . Сао чувствителен к своему plateau-правилу, что видно по скачку от 2 к 6–8 в cooldown. У simplex минимум RMSE часто лежит на границе допустимого диапазона, следовательно, его значения нельзя читать как устойчивую оценку истинной размерности. MLE не демонстрирует падения ни для raw, ни для detrended ряда.

4 Вывод

Четыре метода отвечают на разные операционные вопросы, поэтому их абсолютные значения сравнивать напрямую нельзя. Однако для гипотезы о dimensionality collapse важно согласованное направление, а его здесь нет: один пороговый метод слегка снижается, три других не подтверждают этот сигнал.

Следовательно, этот одиночный Muon/nanoGPT run следует использовать как negative/control case: непрерывное успешное обучение LLM не обязано порождать универсальный поздний коллапс оценок размерности, построенных только по одномерному training loss. Для сильного сравнительного вывода необходимы повторы по seed и логи остальных оптимизаторов того же benchmark.

All four legacy EDM methods, fixed $\tau = 1$ (raw train loss)




Рис. 2: Скользящие оценки четырьмя legacy-методами на исходном train loss.

Fixed $\tau = 1$: raw loss versus locally detrended loss




Рис. 3: Сравнение исходного и локально detrended loss. Удаление тренда не создаёт согласованного падения оценок.

Underlying legacy-method criteria, fixed $\tau = 1$ (raw loss)




Рис. 4: Критериальные кривые FNN, Cao и simplex в representative early, middle и late окнах. MLE не выбирает дискретное E : он оценивает локальную ID в пространстве размерности 15.