

MG по скалярному логу как дешёвый индикатор упрощения обучения:

сводный отчёт по экспериментам

Проект 202, эксперименты 29 сентября — 1 октября 2026

Итог

Цель серии — собрать прикладные примеры, в которых оценка MacKay–Ghahramani (MG), посчитанная по одному скалярному логу обучения, отмечает момент, когда обучение *действительно* упростилось, а само упрощение установлено независимо. Проведено пять экспериментов на CPU; все скрипты, сырые логи и таблицы лежат в `research_trajectory_reference/`.

Эксперимент	Упрощение и его подтверждение	Что показал MG	Вывод
1. Пилот: MLP, digits, SGD	спад lr, заморозка; PR траектории весов	лог loss: падает при упрощении (AUC 0.99), но MG совпадает с MG суррогата	под SGD MG по loss — функция спектра
2. MLP, full batch, большой шаг	—	MG заметно ниже суррогата (0.51–0.66), устойчив к сглаживанию логa	в детерминированном режиме у MG есть своя информация
3. Edge of stability (E2)	число мод Гессмана на пороге $2/\eta$, Ланцош	антикорреляция с числом мод ($\rho = -0.83$)	отрицательный
4. CNN, CIFAR-10, три события (E4)	спад lr, заморозка, прунинг — по построению	лог нормы параметров: $-8\ldots -13\%$, контроли $\geq -3\%$, AUC 0.98	положительный, эффект небольшой
5. То же, события по дозам (E5)	то же + PR ковариации обновлений весов	сильные события $-12\ldots -19\%$, контроли $0\ldots +13\%$; AUC 0.93, для сильнейших доз 0.99; простые статистики ≈ 0.5	положительный, подтверждён на новых сидах

Главный результат. В обучении свёрточной сети на CIFAR-10 MG по логу *нормы параметров* — величине, которая считается по уже имеющимся весам за $O(P)$ и не требует ни одного прохода сети, — падает после явных событий упрощения (заморозка всего, кроме головы; прунинг; спад learning rate в 10–100 раз) на 12–19% в медиане и не падает в контролях без упрощения (обучение без события, меньший шум градиента, масштаб и сглаживание логa). Простые статистики того же логa (пересечения тренда, автокорреляция, разброс) события не отделяют (AUC около 0.5). Результат воспроизвёлся на сидах, которые не участвовали в выборе настроек.

Границы. Эффект составляет десятки процентов, а не кратное изменение; слабые события ($\text{lr}/3$, заморозка двух первых слоёв) MG не видит; как размерность число читать нельзя (отношение идентифицируемости ≈ 1.5). Под SGD MG по логу loss не даёт ничего сверх спектра, а на edge of stability меняется в направлении, обратном числу колеблющихся мод. Сильный положительный пример с кратным эффектом получен пока только в детерминированной системе (FORCE-эксперимент, папка `best_exp`, снижение на 68–80%).

1 Вопрос и методика

Тезис статьи, который проверяется. Теоретически MG по delay-реконструкции скаляра меряет число активных компонент детерминированного возвратного режима; на синтетике так и происходит. Для реального обучения нужен более слабый, но полезный тезис: MG — дешёвый индикатор упрощения динамики, который прикручивается к любому уже записанному логу.

Почему предыдущие попытки (neural collapse, LLM) не подтвердили тезис. MG сравнивали с величинами другого типа: геометрией признаков (NC1/NC2), кривизной Гесса, PR активаций. MG описывает движение траектории оптимизации, поэтому эталон должен описывать то же движение: число направлений, по которым меняются веса, или число колеблющихся мод.

Общая схема. В середине обучения происходит одно событие. По окнам лог считывается MG, берётся медиана по окнам до события и после, и сравнивается их отношение. В каждом эксперименте есть три контроля: масштаб лог (MG обязан не измениться), сглаживание лог скользящим средним (траектория та же, наблюдатель другой) и увеличенный батч (меньше шума при тех же движущихся параметрах). Кроме того, для каждого окна считается MG трёх IAAFT-суррогатов — рядов с тем же спектром, но без нелинейной структуры. Отношение $MG/MG_{\text{сурр}} \approx 1$ означает, что вся информация лог в спектре.

Оценщик. Реализация проекта без изменений ядра (pooled MG, исключение Тейлера на размах вектора задержек). Эксперименты 1–4: $E = 10$, $\tau = 1$, $k = 10$; эксперимент 5: конфигурация статьи $E = 20$, $\tau = 1$, $k = 20$, окно 1 000 шагов.

2 Эксперимент 1. Пилот: MLP на digits, SGD

MLP 64–64–64–10 (9 290 параметров), sklearn digits, SGD, 6 000 шагов, событие на шаге 3 000, 5 сидов. Эталон — detrended PR траектории всех весов в окне 500 шагов.




Рис. 1: Пилот. Слева и в центре — отношение после/до для эталона и для MG лог loss на фиксированном probe. Справа — распределение MG/MG суррогата по окнам: под SGD оно сосредоточено у 1, в полнобатчевом режиме с большим шагом — заметно ниже 1.

событие	PR траектории	MG, probe loss	пересечения тренда	MG/суррогат
нет	0.85	0.91	0.63	1.04
батч $\times 16$	0.89	0.96	0.73	1.03
lr / 10	0.51	0.82	0.32	1.06
учится только голова	0.46	0.80	0.27	1.06
лог сглажен (траектория та же)	0.85	0.50	0.18	1.03

Таблица 1: Отношение после/до, медиана по 5 сидам.

MG разделяет упростившиеся и контрольные запуски (AUC 0.99; корреляция отношений с эталоном $\rho = 0.85$). Однако отношение к суррогату равно 1 (медиана 0.98, межквартильный размах 0.93–1.03): под SGD лог loss — окрашенный шум, и MG на нём определяется одним спектром, как предсказывают Osborne и Provenzale (1989). Поэтому пересечения тренда делают то же самое, а сглаживание лог даёт ложную тревогу. Адаптивный лаг снимает ложную тревогу, но тогда знак отклика на заморозку и спад lr меняется на противоположный (1.60 и 1.45).

3 Эксперимент 2. Полный батч, большой шаг

Та же сеть, полнобатчевый спуск с шагом $\eta \in \{0.5, 2, 5, 10\}$. При $\eta \geq 2$ loss колеблется сам, без шума выборки. MG в этом режиме в 1.5–2 раза ниже суррогатного (отношение 0.66, 0.58, 0.51): в логе есть

детерминированная нелинейная структура. После сглаживания логa MG меняется слабо (0.87–1.15), а MG суррогата и пересечения тренда падают (0.62–0.80 и 0.27–0.56). Это режим, где теория применима и у MG есть информация, недоступная спектральным статистикам.

4 Эксперимент 3 (E2). Edge of stability: число колеблющихся мод

Постановка. MLP на digits, MSE, полнобатчевый спуск, $\eta \in \{0.05, \dots, 0.4\}$, 5 сидов, 8000 шагов, плюс переключения η вниз на середине. На edge of stability несколько собственных значений Гессиана держатся на пороге $2/\eta$; их число растёт с η . Эталоны: число таких мод (Ланцош по произведениям Гессиана на вектор каждые 250 шагов) и PR траектории весов.




Рис. 2: Уровни по шагу η : два дорогих эталона растут, MG падает.

Результат (отрицательный). Число мод растёт от 1 до 22, PR траектории — от 1.05 до 11.2, а MG падает от 5.4 до 2.7. Ранговая корреляция MG с числом мод $\rho = -0.83$ по запускам и -0.73 по окнам; пересечения тренда коррелируют правильно (+0.90). При уменьшении шага моды уходят с порога и PR траектории падает в 3–4 раза, а MG почти удваивается ($\times 1.8$): лог становится гладким транзитом, на котором MG выходит на постоянное значение конфигурации. Отношение идентифицируемости во всех окнах 1.3–1.7, то есть диагностики статьи предупреждают, что уровень не является размерностью. Убрать из логa колебание с периодом 2 перед вложением пробовали всеми способами (все варианты перечислены в REPORT_E2_ru.md); знак не исправляется.




Рис. 3: Переключение шага на середине (пунктир): моды уходят с порога, PR траектории падает, MG растёт.

5 Эксперимент 4 (Е4). CNN на CIFAR-10: три практических события

Постановка. CIFAR-10, 10 000 обучающих изображений (по 1 000 на класс). CNN из трёх свёрток и линейной головы, 14 666 параметров. SGD с momentum 0.9, weight decay $5 \cdot 10^{-4}$, lr 0.02, батч 64, 8 000 шагов, событие на шаге 4 000, 4 сида. Тестовая точность 0.61–0.64 во всех рукавах.

События, для которых упрощение известно по построению:

- lr/10 — шаг и шум в 10 раз меньше;
- обучается только голова — 330 из 14 666 параметров;
- прунинг 80 % весов по модулю.

Логи: loss мини-батча, loss на фиксированных 100 изображениях, норма градиента, норма параметров.

Эталон PR траектории под SGD непригоден. PR траектории всех весов почти не меняется ни при одном событии, в том числе при заморозке (0.92). Моделирование показало причину: detrended PR чистого случайного блуждания на 500 шагах равен ≈ 5 при любой размерности пространства (5.08 при $P = 330$, 5.04 при $P = 14\,666$). Под SGD эта величина описывает форму блуждания, а не число движущихся направлений. В эксперименте 5 эталон заменён на PR ковариации *обновлений* весов.




Рис. 4: Лог нормы параметров, отношение после/до по запускам. Затенено — события упрощения.

Результат. Норма параметров:

- MG после события: lr/10 —8 %, заморозка —10 %, прунинг —13 %;
- контроли: без события —1 %, масштаб —1 %, сглаживание +8 %, батч×4 +17 %;
- все 12 событийных значений не выше —3 %, все контрольные не ниже —3 %; AUC 0.98;
- пересечения тренда, автокорреляция и разброс того же логга: AUC 0.64, 0.41, 0.58;
- MG/суррогат 0.80, и сдвиг MG не спектральный.

Логи loss: MG по probe loss видит события, но только через спектр (отношение к суррогату 1.00, те же AUC у простых статистик, ложная тревога $\times 0.66$ при сглаживании). MG по loss мини-батча не реагирует ни на что: его колебания задаёт выборка батча.

6 Эксперимент 5 (Е5). События по дозам, подтверждение на новых сидах

Что изменено и почему. Две настройки выбраны по логам эксперимента 4 (сиды 0–3) и затем зафиксированы в протоколе:

- наблюдатель — норма параметров;
- конфигурация статьи $E = 20$, $\tau = 1$, $k = 20$, окно 1 000.

Сам эксперимент проведён на новых сидах 10–13, поэтому выбор настроек не влияет на его числа. Упрощения сделаны явнее и по дозам, а после события отводится больше шагов: 10 000 шагов, событие на 4 000, окна после события начинаются в [5 000, 9 000].

Независимое подтверждение измеряется:

- доля параметров, которые двигаются;
- PR ковариации обновлений весов — в отличие от PR траектории, у неё нет артефакта случайного блуждания;
- средний размер обновления.

событие	MG до	MG после	изменение	разброс по сидам	PR обновлений	двигается
без события	4.31	4.32	+0.4 %	−8.7 ... + 3.3	+40 %	100 %
батч ×4 (меньше шума)	4.31	4.85	+12.8 %	+8.3 ... + 13.9	−7 %	100 %
лог ×10	4.31	4.32	+0.4 %	как без события	—	—
лог сглажен	4.31	4.44	+3.4 %	−5.1 ... + 4.2	—	—
lr /3	4.31	4.35	+0.9 %	−6.8 ... + 4.2	−5 %	100 %
lr /10	4.31	3.95	−8.3 %	−12.1 ... − 2.3	−22 %	100 %
lr /100	4.31	3.85	−11.5 %	−14.4 ... − 7.3	−21 %	100 %
заморожены conv1–2	4.31	4.27	−1.8 %	−3.9 ... + 2.2	−14 %	65 %
учится только голова	4.31	3.51	−18.5 %	−24.1 ... − 11.2	−43 %	2.2 %
учится только bias головы	4.31	3.58	−16.7 %	−23.7 ... − 15.0	−68 %	0.07 %
прунинг 50 %	4.31	3.80	−12.7 %	−14.5 ... − 3.9	+15 %	50 %
прунинг 80 %	4.31	3.59	−17.5 %	−20.7 ... − 12.3	−10 %	20 %
прунинг 95 %	4.31	3.79	−11.5 %	−16.1 ... − 9.5	−45 %	6 %

Таблица 2: MG лог нормы параметров до и после события: медиана по 4 сидам и диапазон по сидам. PR обновлений и доля движущихся параметров — независимое дорогое подтверждение.




Рис. 5: Слева — изменение MG после события для каждого запуска (черта — медиана); серый фон — контроли без упрощения. Справа — изменение MG против изменения PR обновлений всех весов.

Проверка заранее записанных предсказаний.

- **P1:** медиана каждого события ниже медианы каждого контроля — **не выполнено**. Самые слабые дозы (lr/3: +0.9%; заморозка conv1–2: −1.8%) неотличимы от контроля. По эталону они и меняют движение слабее всего: PR обновлений −5 % и −14 %.
- **P2:** сильнейшая доза ниже каждого контрольного запуска — **выполнено** для заморозки и прунинга; для lr **не выполнено**: один сид lr/100 (−7.3 %) выше одного сида без события (−8.7 %).
- **P3:** монотонность по дозе — **да** для lr ($\rho = -0.83$) и для заморозки (−0.68); для прунинга **нет** ($\rho = -0.03$: 80 % сильнее, чем 95 %).
- **P4:** контроли не дают ложной тревоги — **выполнено**: масштаб 0 %, сглаживание +3 %, меньший шум +13 %.

Сравнение с простыми статистиками того же лога. AUC «событие против контролей без упрощения»:

	MG	MG сурр.	пересеч. тренда	автокорр.	разброс
все события	0.93	0.68	0.56	0.48	0.57
сильнейшие дозы, все контроли	0.99	—	0.52	0.48	0.67

MG по loss мини-батча: AUC 0.19, то есть знак обратный и эффект слабый. Корреляция изменения MG с изменением PR обновлений по всем запускам $\rho = 0.59$. Отношение MG/суррогат 0.78: изменение MG не сводится к спектру.




Рис. 6: MG во времени, медиана по 4 седам. При прунинге окно, накрывающее сам шаг 4 000, падает до ≈ 2.4 : норма там скачком меняется. Такие окна в сравнение не входят — «после» начинается с шага 5 000.

7 Стоимость

что считается	цена
MG одного окна лога (500–1 000 точек)	5–10 мс
лог нормы параметров	$O(P)$ на шаг, без прохода сети; 31–39 КБ на запуск
PR траектории или обновлений, одно окно	180–300 мс; нужно хранить все веса: 450–560 МБ на запуск
Ланцош по Гессияну (эксперимент 3)	≈ 100 мс и ≈ 60 HVP на чекпойнт
loss на фиксированном probe	один дополнительный проход сети на шаг (+75 % ко времени обучения малой сети)

8 Выводы для статьи

1. **Что можно утверждать.** MG по бесплатному логу нормы параметров воспроизводимо отмечает явные события упрощения обучения CNN: заморозку, прунинг, сильный спад learning rate. Эффект $-12 \dots -19 \%$, контроли $0 \dots +13 \%$, результат воспроизведён на новых седах, а простые статистики того же лога этого не делают. Это прикладной пример в духе тезиса «дешёвый анализатор упрощения».
2. **Как формулировать.** Как относительный сигнал «до/после»: абсолютное значение размерностью не является (отношение идентифицируемости ≈ 1.5). Слабые упрощения метод не различает.
3. **Какой лог брать.** Имеет значение: loss мини-батча бесполезен; MG по probe loss — спектральная сводка с ложной тревогой при сглаживании; норма параметров даёт нелинейную информацию. В grokking-разделе статьи используется тот же лог.
4. **Чего утверждать нельзя.** Что MG считает число колеблющихся мод в реальном обучении (эксперимент 3 даёт обратный знак) и что под SGD уровень MG по loss — размерность.
5. **Эталон.** Для SGD-обучения оконный PR траектории весов эталоном числа направлений не является (артефакт случайного блуждания); это стоит учесть при описании §7.2 статьи.

Что дальше.

- Повторить эксперимент 5 на ResNet-18 и полном CIFAR-10 (Colab), с предобученной моделью и заморозкой при fine-tuning.
- Нормы отдельных слоёв: локализовать, *какой* слой упростился.
- Детектор момента события по порогу, заданному до запуска.
- Для кратного эффекта — события, переводящие обучение в детерминированный режим, как в FORCE-эксперименте (`best_exp`).

Воспроизведение

Все команды выполняются из `2026-Project-202/research_trajectory_reference`:

- эксперименты 1–2: `pilot.py`, `reanalyse.py`, `fullbatch.py`; результаты в `results/`;
- эксперимент 3: `eos.py`, `eos_analyse.py`, `eos_posthoc.py`; результаты в `results_eos/`;
- эксперимент 4: `cifar_events.py`, `cifar_analyse.py`, `cifar_paramnorm.py`; результаты в `results_cifar/`;
- эксперимент 5: `explore_observer.py` (выбор настроек на старых седах), `cifar_graded.py` (протокол в docstring), `graded_analyse.py`; результаты в `results_graded/`.

Подробные отчёты по экспериментам 3 и 4: `REPORT_E2_ru.md`, `REPORT_E4_ru.md`. CPU Intel i5-12500H, PyTorch 2.10 (CPU), без GPU.