

# EDM-анализ обучения Muon/nanoGPT на FineWeb10B

Технический отчёт по файлу `message (2).txt`

30 июля 2026 г.

## Аннотация

Из самодокументируемого текстового лога восстановлен один полный запуск Muon/nanoGPT: 2330 последовательных значений `training loss` и 11 значений `validation loss`. Для плотного ряда проведена фазовая реконструкция и скользящая оценка `intrinsic dimension` методом Levina–Bickel. В отличие от экспериментов с `grokking`, выраженного позднего коллапса размерности не найдено. После удаления локального тренда оценка остаётся около 10–10.5 на основной части обучения. Эксперимент следует интерпретировать как контрольный пример, демонстрирующий важность `detrending` и проверки стационарности.

## 1 Исходный эксперимент и извлечение данных

Файл содержит полный код обучения, описание окружения и собственно лог. Парсер использует только строгие маркеры `RUNMETA`, `RUNEND`, записи `train_loss` и `val_loss`; исходный файл не изменяется.

Восстановлен запуск `Muon_lr0.06_5db64adc`: 12-слойный GPT (model dimension 768, 6 attention heads) обучался на FineWeb10B с Muon (learning rate 0.06, momentum 0.95, weight decay 0) на 8 NVIDIA H100. Глобальный batch равен 262144 токенам, основной цикл содержит 2290 итераций и 40 дополнительных. Linear learning-rate cooldown начинается примерно с шага 1260. Запуск завершился без дивергенции за 143.8 секунды; итоговый `validation loss` равен 3.2785.

`Training loss` в исходном логе является усреднённой между GPU суммой потерь по локальному батчу. Для получения средней token-level cross-entropy он делился на  $262144/8 = 32768$ . Полученный ряд непрерывен на шагах 0–2329.

## 2 Методика EDM

EDM применялся только к `training loss`: 11 `validation`-точек недостаточно для фазовой реконструкции. Использовались окна длиной 400 шагов со сдвигом 40. В каждом окне задержка выбиралась по первому локальному минимуму `delayed mutual information`, после чего строилось `embedding` размерности 12. `Intrinsic dimension` оценивалась методом Levina–Bickel по 10 соседям. Для исключения тривиальной временной близости применялось Theiler window шириной 12 шагов.

Анализ повторялся после удаления локального линейного тренда. Это необходимо, поскольку быстрое монотонное снижение `loss` образует почти одномерную кривую в `delay space` и может искусственно занижить оценку размерности.

Для прямой сопоставимости воспроизведён estimator из существующего проектного кода: `embedding dimension` 15,  $k = 5$ ,  $\tau = 1$ , без Theiler window. Его абсолютные значения выше, однако качественная динамика совпадает.




Рис. 1: Training и validation loss вместе с learning-rate schedule.

### 3 Результаты

Для сырого ряда средняя оценка первых 12 окон равна 8.69, последних 12 окон — 10.12. Для detrended ряда соответствующие значения равны 10.13 и 10.52. Таким образом, ни один вариант не показывает ожидаемого позднего коллапса.

Самая низкая сырая оценка, 7.25, наблюдается в окне с центром на шаге 200. Но lag-1 autocorrelation в этом окне равна 0.993, а после detrending ID возрастает до 10.14. Следовательно, ранняя низкая размерность обусловлена глобальным трендом, а не компактным поздним состоянием оптимизатора.

Таблица 1: Средние скользящие оценки по фазам schedule.

| Фаза        | Центры окон | $\tau$ | ID raw           | ID detrended     | Legacy ID        |
|-------------|-------------|--------|------------------|------------------|------------------|
| Constant LR | 200–1240    | 4      | $9.10 \pm 0.73$  | $10.25 \pm 0.46$ | $13.81 \pm 1.46$ |
| LR cooldown | 1280–2120   | 4      | $10.01 \pm 0.31$ | $10.33 \pm 0.39$ | $14.57 \pm 0.72$ |

### 4 Проверка устойчивости

Расчёт повторён для окон 300, 400, 500 и 600 и задержек 1, 2, 3, 5 и 8. Поздняя оценка не становится устойчиво ниже ранней. Для detrended loss диапазоны составляют 7.7–10.3 (early), 10.0–11.1 (middle) и 9.5–11.3 (late).

Оценка зависит и от размерности пространства реконструкции, приближаясь при  $m = 12$  к верхней границе. Поэтому значения 10–10.5 нельзя считать точной физической размерностью; надёжным является сравнительный вывод об отсутствии выраженного позднего коллапса.




Рис. 2: Скользящие оценки размерности, выбранный DMI lag и статистики loss.

## 5 Интерпретация и ограничения

Эксперимент не содержит plateau между memorization и delayed generalization: train и validation loss непрерывно снижаются, а ассигасу не логируется. Кроме того, learning-rate schedule делает процесс нестационарным. Доступен один запуск, один плотный observable и нет контрольных seed или других оптимизаторов.

Поэтому полученный результат полезен как negative/control case: успешное обучение большой языковой модели само по себе не обязано сопровождаться dimensionality collapse в скалярном loss. Для сравнительного исследования нужны логи остальных методов (MuonUSign, EF21-\*, SignMuon, MuonSign, SignSGD) и несколько seed. Разработанный парсер и анализатор готовы к их обработке.

### Delay-coordinate portraits across training




Рис. 3: Delay-coordinate portraits в ранней, средней и поздней частях обучения.

### Sensitivity of the intrinsic-dimension estimate




Рис. 4: Чувствительность оценки к размеру окна и задержке.




Рис. 5: Зависимость MLE ID от размерности delay embedding.