

EDM-анализ резкой генерализации без memorization gap

Контрольный эксперимент на S_n

1 августа 2026 г.

Аннотация

Проведён скользящий EDM-анализ запуска, в котором train- и validation-accuracy растут практически синхронно. Используются четыре проектных метода оценки размерности: False Nearest Neighbors, Cao, simplex projection и Levina–Bickel MLE при фиксированной задержке $\tau = 1$. Резкая генерализация сопровождается выраженной перестройкой локальной геометрии временных рядов, но не единым dimensionality collapse: MLE validation loss снижается, тогда как MLE общей gradient norm устойчиво растёт. Результат поддерживает трактовку EDM как маркера смены режима оптимизационной динамики, а не как универсального скалярного порядка grokking.

1 Данные и положение перехода

Файл `training_log.csv` содержит 2221 наблюдение, записанное каждые 20 optimizer steps, и охватывает шаги 0–44400. В отличие от классического grokking, длительного интервала между запоминанием train-set и обобщением нет.

Таблица 1: Устойчивые пороги accuracy: пять последовательных лог-точек.

Событие	Шаг
Validation accuracy ≥ 0.50	43420
Validation accuracy ≥ 0.90	44040
Batch train accuracy ≥ 0.95	44160
Validation accuracy ≥ 0.95	44300

Validation accuracy достигает 0.90 на 120 шагов раньше, чем batch train accuracy устойчиво достигает 0.95. Поэтому наблюдается резкий совместный переход обучения и генерализации, а не memorization plateau с последующим grokking.




Рис. 1: Train/validation loss и accuracy. Красный пунктир — устойчивое достижение validation accuracy 0.50, точечная линия — достижение 0.90.

2 Методика EDM

Основной анализ выполнен со следующими настройками:

- фиксированная задержка $\tau = 1$;
- окно 100 лог-точек, то есть 2000 optimizer steps;
- stride 10 лог-точек, то есть 200 optimizer steps;
- максимальная embedding dimension $E_{max} = 15$;
- пять соседей для Levina–Bickel MLE;
- исходные и локально линейно detrended временные ряды.

Анализируются `train_loss`, `val_loss`, `weight_norm`, `grad_norm`, `embed_grad_norm` и `grad_cosine`. Для MLE дополнительно проверены окна 50 и 150 точек.

После устойчивого достижения validation accuracy 0.95 остаётся только шесть лог-точек. Поэтому отдельная post-transition фазовая реконструкция невозможна: последние пять окон смешивают подход к переходу и сам переход. Они сравниваются с последними пятью полностью пред-переходными окнами, заканчивающимися до шага 42500.

3 Четыре метода на loss

Four fixed- $\tau = 1$ EDM diagnostics on loss observables ($W=100$)




Рис. 2: FNN, Cao, simplex и MLE на train- и validation-loss.

Raw MLE train loss резко падает с 12.09 до 7.31, но после удаления локального линейного тренда изменение уменьшается с -4.78 до -0.77 . Значительная часть raw-сигнала, следовательно, создаётся формой быстрого падения loss. Для validation loss падение detrended MLE остаётся выраженным.

Таблица 2: Transition-window mean минус pre-transition mean.

Метрика	Метод	Raw Δ	Detrended Δ
Train loss	FNN	-1.20	-0.40
Train loss	Cao	-0.80	+0.40
Train loss	Simplex	-0.20	+1.60
Train loss	MLE	-4.78	-0.77
Validation loss	FNN	-1.00	-0.80
Validation loss	Cao	-2.60	-0.80
Validation loss	Simplex	-0.20	+0.20
Validation loss	MLE	-0.30	-1.65

4 MLE по всем наблюдаемым




Рис. 3: Levina-Bickel MLE исходных и локально detrended рядов.

Наиболее важное несогласие наблюдаемых — противоположный знак gradient norm. Её detrended MLE увеличивается примерно на 2.96, хотя validation loss и несколько других рядов упрощаются. Следовательно, переход не является глобальным сжатием всей оптимизационной динамики.

Таблица 3: Средние пяти пред-переходных и пяти переходных окон, $W = 100$.

Метрика	Raw MLE		Detrended MLE	
	Pre	Transition	Pre	Transition
Train loss	12.09	7.31	12.64	11.87
Validation loss	1.72	1.42	3.46	1.81
Weight norm	3.64	1.84	4.36	2.26
Gradient norm	15.58	17.61	14.41	17.37
Embedding-gradient norm	15.16	11.36	14.63	12.01
Gradient cosine	14.97	13.04	15.54	12.92




Рис. 4: Изменения всех четырёх методов у перехода. Синий цвет означает снижение оценки, красный — рост.

5 Чувствительность к длине окна




Рис. 5: Detrended MLE loss при окнах 50, 100 и 150 лог-точек.

Таблица 4: Detrended MLE: transition минус pre-transition.

Метрика	$W = 50$	$W = 100$	$W = 150$	Устойчивый знак
Validation loss	-2.65	-1.65	-1.78	да
Gradient norm	+5.51	+2.96	+2.30	да
Train loss	+1.87	-0.77	+1.42	нет
Weight norm	+1.09	-2.09	-2.64	нет
Embedding-gradient norm	-1.89	-2.62	-0.58	да
Gradient cosine	-3.36	-2.62	+0.43	нет

Наиболее устойчивы два противоположных эффекта: снижение MLE validation-loss траектории и увеличение MLE gradient-norm траектории. Падение train-loss MLE после detrending не устойчиво к длине окна.

6 Ограничения

1. После перехода недостаточно наблюдений для независимой post-transition фазы.
2. Окна перекрываются на 90% и не являются статистическими повторениями.
3. Legacy nearest-neighbour методы не используют Theiler exclusion.
4. 141 raw и 113 detrended MLE-оценок превышают $E_{max} = 15$; максимумы равны 20.44 и 18.94. Это выход legacy-эвристики, а не буквальная размерность 15-мерного embedding.
5. Simplex выбирает верхнюю границу $E = 15$ примерно в 16.4% raw окон gradient cosine, но значительно реже для остальных наблюдаемых.
6. Имеется один запуск и один seed, поэтому вывод является описательным.

7 Вывод

Резкое обобщение без memorization gap сопровождается измеримой EDM-перестройкой. Однако её направление зависит от observable и метода. Validation-loss динамика становится более низкоразмер-

ной, тогда как динамика общей нормы градиента становится более сложной. Поэтому EDM в этом эксперименте является маркером смены режима оптимизации, но не подтверждает универсальный dimensionality collapse всей системы.

Воспроизводимость. Полные таблицы находятся в `results_tau1_no_gap/`; скрипт расчёта — `analyze_sharp_no_gap_edm.py`.