
Grokking prediction via estimation of neural network attractor dimensionality

Nickolay Karlov
MIPT
Moscow, Russia
karlov.na@phystech.edu

Alexey Kravatskiy
MIRIAI
Moscow, Russia
kravatskii.a@miriai.org

Abstract

We analyze delayed generalization (grokking) through the lens of empirical dynamic modeling. We hypothesize that the process of neural network training can be viewed as the evolution of a forced dynamical system possessing an attractor, which corresponds to a local minimum of the loss function, and that grokking represents a structural phase transition to a low-dimensional attractor. We apply the Levina-Bickel maximum likelihood estimator (MLE) of intrinsic dimension to 1D scalar logs of the weight norm, analyzing the resulting dimensionality trajectories to enable the early prediction of grokking. Results on modular addition and composition tasks over the non-abelian S_5 symmetric group demonstrate that grokking is characterized by an initial increase in attractor dimensionality followed by a sustained reduction, which supports the hypothesis that a topological collapse underlies delayed generalization.

Keywords: grokking, Levina-Bickel method, phase space, dynamical systems, neural network optimization.

1 Introduction

In classical statistical learning theory, the central paradigm is the bias-variance tradeoff. For a long time, it was believed that if, during the optimization process, the empirical risk (training error) drops to zero while the generalization gap remains large or begins to grow, the model irreversibly overfits, which requires stopping the training. However, in 2022, the phenomenon of grokking [1] was discovered—an effect of delayed generalization where a model, having been in a state of overfitting for thousands of iterations, undergoes a phase transition and achieves 100% accuracy on the test set. This phenomenon challenges classical approaches to training monitoring and highlights the need for new methods for early prediction of generalization ability.

In modern literature, several approaches to studying grokking have emerged. The first direction, based on mechanistic interpretability [2?], investigates grokking as a process of forming structured algebraic representations (e.g., Fourier bases) within the weight matrices. Although this "white-box" approach provides a deep understanding of the mechanics, it is computationally unscalable and requires the creation of unique progress measures for each new task. The second direction focuses on the macroscopic dynamics of the loss landscape ("black-box" approach). Recent works [? ?] analyze the influence of the weight norm and the slingshot effect, while the authors of [3] propose using spectral signatures of the loss (Hjorth parameters) to predict the phenomenon.

However, existing macroscopic methods possess a significant limitation: they only capture statistical changes in the system's metrics, yet they remain uninterpretable in terms of the internal complexity of the model.

In this paper, we propose a new statistical framework relying on the Levina-Bickel maximum likelihood estimator (MLE) of intrinsic dimension for the early prediction and structural description

of grokking. In the rigorous formulation of stochastic optimization, the task consists of minimizing the expected risk $\mathbb{E}_{\xi \sim \mathcal{D}}[\mathcal{L}(\mathbf{w}, \xi)]$, where the random variable ξ_t corresponds to the selection of a specific mini-batch at iteration t .

Because modern adaptive optimizers (such as SGD with momentum or AdamW) utilize the history of previous gradients, the weight trajectory $\mathbf{w}_t \in \mathbb{R}^D$ does not intrinsically form a Markov process. Therefore, we formalize the learning process as a non-autonomous dynamical system in an extended phase space:

$$\mathbf{s}_{t+1} = \Phi(\mathbf{s}_t, \xi_t), \quad \text{where } \mathbf{s}_t = (\mathbf{w}_t, \mathbf{h}_t) \in \mathbb{S}. \quad (1)$$

Here, $\mathbf{s}_t$ is the full state of the system at step t , comprising both the model parameters $\mathbf{w}_t$ and the vector of internal optimizer variables $\mathbf{h}_t$ (e.g., the exponential moving averages of the first and second moments in AdamW). The deterministic operator Φ defines the state update rule, and the sequence $\{\xi_t\}$ acts as the external stochastic forcing. It is precisely this gradient noise ξ_t that causes the trajectory to deviate from the ideal full-batch gradient descent, forcing the optimizer to continuously explore the local geometry of the loss landscape.

To reconstruct the properties of this system from scalar logs $y_t = \phi(\mathbf{s}_t) \in \mathbb{R}$, we rely on embedding theorems. The presence of hidden momentum variables $\mathbf{h}_t$ only increases the dimensionality of the original space $\mathbb{S}$, but does not prevent reconstruction if the system converges to a low-dimensional attractor. To account for the external influence (learning rate scheduler) and the stochasticity of the forcing ξ_t , the classical basis of Takens' embedding theorem [4] is extended by Stark's theorems on *delay embeddings* for systems with stochastic forcing [5, 6]. Stark proved that for such systems, the delay map preserves diffeomorphism, which provides us with the mathematical justification to estimate the effective dimensionality of the optimizer's attractor exclusively from one-dimensional macroscopic logs.

We consider grokking as a structural topological transition. In the memorization phase, the optimizer's trajectory constitutes a high-dimensional stochastic random walk, during which the system allocates redundant degrees of freedom to memorize the training set rather than to discover generalized rules. In the generalization phase, L_2 regularization (weight decay) forces the system to discard noisy degrees of freedom and build a compact algebraic structure within the weights. Topologically, this is equivalent to the compression of the optimizer's attractor into a low-dimensional submanifold.

To verify the proposed hypothesis and analyze the phenomenon of grokking, we conduct a series of computational experiments. As the primary mathematical tool, we apply the Levina-Bickel maximum likelihood estimation (MLE) of intrinsic dimension [7]. Training is performed on algebraic datasets using a 1-layer Transformer, as proposed in the Omnigrok study [?]. In the first experiment, the problem of modular addition (a commutative group) is solved; in the second, we tackle the composition operation within the non-abelian permutation group S_5 . Such a choice of test environments allows us to evaluate the proposed method both for its ability to provide early prediction of delayed generalization and for its sensitivity to changes in the hidden algebraic complexity of the task.

2 Problem Statement

Consider a neural network model $\mathcal{M}$ optimized to minimize the expected risk $\mathbb{E}_{\xi \sim \mathcal{D}}[\mathcal{L}(\mathbf{w}, \xi)]$. We formulate the training process over T iterations as a non-autonomous stochastic dynamical system. Because modern adaptive optimizers (e.g., SGD with momentum or AdamW) maintain internal state histories, the weight trajectory alone does not form a Markov process. Therefore, let $\mathbf{s}_t = (\mathbf{w}_t, \mathbf{h}_t) \in \mathbb{S}$ be the extended state of the system at step $t \in \{1, \dots, T\}$, where $\mathbf{w}_t \in \mathbb{R}^D$ denotes the model parameters and $\mathbf{h}_t$ represents the optimizer's internal variables. The evolution of this system is governed by the recurrence rule:

$$\mathbf{s}_{t+1} = \Phi(\mathbf{s}_t, \xi_t), \quad (2)$$

where Φ is the deterministic optimizer step and ξ_t acts as the external stochastic forcing, induced by the random mini-batch selection and hyperparameter scheduling.

In practice, the full high-dimensional state $\mathbf{s}_t$ is inaccessible for computationally efficient analysis. Instead, we observe a set of one-dimensional scalar time series $\mathbf{m}_t = [m_1(t), \dots, m_K(t)]^\top$ generated during optimization. Each macroscopic metric (e.g., training loss, weight norm, or gradient norm) acts as an observation function $m_i(t) = \phi_i(\mathbf{s}_t, \xi_t) \in \mathbb{R}$. In this regard, the **global research objective** is to reconstruct the topological properties of the hidden attractor of $\mathbf{s}_t$ and to develop an early predictor of phase transitions during optimization, relying exclusively on the 1D observation series $m_i(t)$.

The primary target phase transition in our work is the phenomenon of delayed generalization. Let us introduce its formal description.

Definition 1 (Grokking). *Let $\text{Acc}_{\text{train}}(\mathbf{w}_t)$ and $\text{Acc}_{\text{val}}(\mathbf{w}_t)$ denote the model’s accuracy on the training and validation sets, respectively. Due to stochastic optimizer noise, instantaneous metric values are prone to random fluctuations (e.g., spurious accuracy spikes early in training). Let $\overline{\text{Acc}}(t)$ denote the smoothed metric (a moving average over a local time window). For a given small error threshold $\epsilon > 0$ (set to 0.05 in this work), we define two critical optimization moments:*

- **Memorization moment** (t_{mem}): *the minimum step t starting from which the network robustly interpolates the training data:*

$$t_{\text{mem}} = \min \{t \mid \forall \tau \geq t, \overline{\text{Acc}}_{\text{train}}(\mathbf{w}_\tau) \geq 1 - \epsilon\}.$$

Typically, at this moment, the validation accuracy remains at the level of random guessing ($\text{Acc}_{\text{val}}(\mathbf{w}_{t_{\text{mem}}}) \approx 0$).

- **Generalization moment** (t_{gen}): *the minimum step t starting from which a stable increase in generalization ability is recorded:*

$$t_{\text{gen}} = \min \{t \mid \forall \tau \geq t, \overline{\text{Acc}}_{\text{val}}(\mathbf{w}_\tau) \geq 1 - \epsilon\}.$$

The optimization process is classified as grokking if there is an anomalous delay between these events: $t_{\text{gen}} \gg t_{\text{mem}}$.

As Definition 1 implies, on the interval $t \in (t_{\text{mem}}, t_{\text{gen}})$, classical macroscopic accuracy metrics reside on a quasi-stationary plateau. During this period, the optimizer outwardly appears trapped in an overfitting regime; however, hidden structural reorganizations occur within the model weights. We hypothesize that the transition from memorization to generalization constitutes a topological collapse of the optimizer’s degrees of freedom.

To detect this collapse, we introduce $\hat{d}(t)$ —an estimate of the effective (intrinsic) dimensionality of the reconstructed attractor at time t . Based on this, we formulate a formal criterion for successful early prediction.

Definition 2 (Grokking prediction criterion). *A successful early warning signal of grokking is characterized by the formation of a stable downward trend in the effective dimensionality $\hat{d}(t)$, culminating in its stabilization at a new, lower-dimensional level strictly before the actual increase in validation accuracy:*

$$\exists t_{\text{drop}} \in (t_{\text{mem}}, t_{\text{gen}}) \quad \text{such that} \quad \forall t \in [t_{\text{drop}}, t_{\text{gen}}]: \hat{d}(t) \ll \hat{d}(t_{\text{mem}}). \quad (3)$$

Furthermore, on the interval $(t_{\text{mem}}, t_{\text{drop}})$, a macroscopically monotonic decline of $\hat{d}(t)$ without significant upward rebounds must be observed.

Meeting the conditions of Definition 2 in practice implies that the topological dimensionality collapse indeed precedes generalization, and that the scalar observation functions $m_i(t)$ contain sufficient information for its early detection.

3 Теоретическое обоснование и предлагаемый метод

Для решения поставленной задачи предложен метод, опирающийся на теорию нелинейных динамических систем. В данном разделе обосновывается возможность извлечения геометрии многомерной системы из 1D-лога и приводится алгоритм оценки эффективной размерности $\hat{d}(t)$.

3.1 Обучение как вынужденная динамическая система (Теоремы о вложении)

В теории нелинейной динамики под **аттрактором** $\mathcal{A} \subset \mathbb{W}$ понимается компактное инвариантное подмножество фазового пространства, к которому асимптотически притягиваются траектории системы. В контексте машинного обучения процесс градиентной оптимизации стремится минимизировать функцию потерь. В связи с этим мы опираемся на допущение, что с течением

времени траектория весов w_t теряет избыточные степени свободы и сходится к некоторому локальному аттрактору (например, стационарному стохастическому облаку вокруг плоского минимума). Пусть истинная размерность этого аттрактора равна m , где $m \ll D$.

Согласно классической теореме Такенса [4], для автономных систем топологию всего многомерного аттрактора $\mathcal{A}$ можно реконструировать по одному скалярному ряду наблюдений $X(t) \in \{m_i(t)\}$, используя векторы запаздывания (delay embeddings):

$$\mathbf{x}_t = [X(t), X(t - \tau), \dots, X(t - (E - 1)\tau)]^\top \in \mathbb{R}^E, \quad (4)$$

при условии, что размерность пространства вложения $E \geq 2m + 1$.

Для формализации алгоритмов введем оператор построения вложения DelayEmbedding, который сопоставляет исходному одномерному временному ряду $\{X(t)\}_{t=1}^N$ множество векторов в реконструированном фазовом пространстве:

$$\text{DelayEmbedding}(\{X(t)\}_{t=1}^N, E, \tau) = \{\mathbf{x}_t\}_{t=(E-1)\tau+1}^N, \quad (5)$$

где каждый вектор $\mathbf{x}_t \in \mathbb{R}^E$ сконструирован согласно формуле (3). Результатом работы данного оператора является восстановленное фазовое многообразие $M \subset \mathbb{R}^E$, состоящее из $|M| = N - (E - 1)\tau$ точек.

Фундаментальным математическим требованием теорем о вложении является «типичность» (genericity) функции наблюдения $\phi(\cdot)$. С точки зрения дифференциальной топологии это означает, что функция метрики не должна обладать вырожденными симметриями, которые склеивают различные точки фазового пространства при проекции. Например, агрегированная норма весов $\|\mathbf{w}_t\|_2$ обладает сферической симметрией, измеряя лишь радиальное расстояние от начала координат. В определенных режимах она может выступать в роли «вырожденного наблюдателя» (degenerate observer), теряющего информацию об алгебраической структуре (угловых координатах) весов. В то же время, нелинейные метрики, например напрямую зависящие от распределения логитов (такие как функция потерь $\mathcal{L}$), выступают в роли типичных наблюдателей, сохраняющих многомерную топологию системы.

Однако градиентный спуск в глубоком обучении не является автономной системой. Влияние случайного выбора мини-батчей, а также использование расписаний гиперпараметров (learning rate schedulers) формально нарушают классические условия Такенса. Для математического обоснования нашего подхода мы опираемся на теоремы Старка о вложениях для вынужденных систем со смешанным воздействием [5, 6].

В современной теории оптимизации процесс обучения $\mathbf{w}_{t+1} = F(\mathbf{w}_t, \omega_t, \xi_t)$ рассматривается под воздействием двух типов форсинга. Детерминированный форсинг ω_t (расписание шага обучения) подчиняется теореме Старка для детерминированных систем [5], гарантирующей сохранение топологии при гладком внешнем драйвере. В свою очередь, стохастический форсинг ξ_t (градиентный шум мини-батчей) аппроксимируется многомерным Гауссовским процессом, а выбор батча из конечного набора описывается в терминах систем итерлируемых функций (Iterated Function Systems) [6]. Для обоих случаев Старк с соавторами доказал, что отображение задержки сохраняет свойства диффеоморфизма. Это фундаментально обосновывает правомерность измерения размерности скрытого аттрактора в пространстве параметров $\mathbb{W}$, оперируя исключительно скалярными логитами в реконструированном фазовом пространстве $\mathbb{R}^E$, независимо от наличия детерминированных расписаний или стохастического шума.

3.2 Оценка эффективной размерности фазового пространства

Для детекции фазового перехода нам необходимо оценивать размерность аттрактора системы. В нашем методе мы рассмотрели как классические, так и современные методы, ранжировав их по устойчивости к специфике нейросетевой оптимизации (шуму мини-батчей):

1. Метод ложных ближайших соседей (FNN) [8] и Метод Цао [9]. Суть классического метода FNN заключается в последовательном «развертывании» аттрактора. При недостаточной размерности вложения удаленные участки многомерной траектории проецируются близко друг к другу, образуя так называемых «ложных» соседей. Метод измеряет расстояние между точкой и её ближайшим пространственным соседом в размерности d , а затем проверяет, насколько сильно они отдалятся друг от друга при переходе к размерности $d + 1$. Если точки разлетаются

(расстояние превышает эвристический порог R_{tol}), сосед признается ложным. Метод Цао является строгим математическим развитием этого подхода: он анализирует усредненное отношение расстояний при росте размерности, что позволяет отказаться от ручного подбора порогов.

Однако фундаментальным ограничением обоих геометрических методов является жесткое требование *глобальной возвратности (рекуррентности)* траектории. Чтобы алгоритм мог выявить сложную форму аттрактора, динамическая система должна регулярно возвращаться в окрестности своих прошлых состояний (пересекать саму себя в проекции). При обучении нейросети мы часто имеем дело с транзитными (переходными) процессами — например, когда функция потерь монотонно падает. В отсутствие возвратности ближайшим пространственным соседом точки x_t становится её же временной сосед с предыдущего шага x_{t-1} . Поскольку такие точки не «разлетаются» ни в какой размерности, геометрические методы вырождаются, ошибочно воспринимая многомерную траекторию спуска как простую 1D-линию, и выдают тривиальную оценку $\hat{d} = 1$.

2. Метод максимизации симплексной проекции [10]: Оптимальное E ищется как аргумент, максимизирующий авторегрессионную корреляцию ρ при предсказании будущего состояния y_{t+1} по его соседям в $\mathbb{R}^E$. Метод топологически гарантирует наилучшее развертывание аттрактора, однако его разрешение является целочисленным (дискретным), что загроубляет детекцию плавных фазовых переходов.

3. Метод максимального правдоподобия (MLE Intrinsic Dimension) [7]: Выбран в качестве основного аналитического инструмента в нашем методе. В отличие от геометрических методов, подход Левиной-Бикеля проецирует временной ряд сразу в избыточное высокоразмерное пространство (например, $E = 15$) и оценивает локальную внутреннюю размерность $\hat{d}_x$ статистически, по Пуассоновскому распределению расстояний до k ближайших соседей. Процесс формализован в Алгоритме 1.

Algorithm 1 Оценка динамической размерности MLE (Levina-Bickel)

Input: Временной ряд наблюдений $\mathcal{D}_{obs}$, задержка τ , избыточная размерность E_{max} , окно W , соседи k

Output: Эффективная размерность $\hat{d}(t)$

- 1: $M \leftarrow \text{DelayEmbedding}(\mathcal{D}_{obs}, E_{max}, \tau)$ ▷ Вложение в $\mathbb{R}^{E_{max}}$
- 2: **for** каждой точки $x_t \in M$ внутри скользящего окна W **do**
- 3: Найти k ближайших соседей с расстояниями $r_1 \leq r_2 \leq \dots \leq r_k$
- 4: $\hat{d}_{x_t} \leftarrow \left[\frac{1}{k-1} \sum_{j=1}^{k-1} \log \left(\frac{r_k}{r_j} \right) \right]^{-1}$ ▷ Локальная оценка по радиусу r_k
- 5: **end for**
- 6: $\hat{d}(t) \leftarrow \frac{1}{|W|} \sum_{x_t \in W} \hat{d}_{x_t}$ ▷ Усреднение размерности на окне W
- 7: **return** $\hat{d}(t)$

Данный метод возвращает *непрерывную* величину, которая вычисляется локально, не требует глобальной возвратности траектории и демонстрирует устойчивость к шуму мини-батчей.

3.3 Физика Гроккинга как топологического коллапса

Применяя описанный математический аппарат, мы формализуем гроккинг как структурный фазовый переход в ландшафте потерь.

- **Фаза меморизации:** Сеть "заучивает" данные как несвязанный шум. Траектория оптимизатора w_t блуждает по высокоразмерному многообразию. В этот период эффективная размерность $\hat{d}(t)$, вычисляемая алгоритмом MLE, будет максимальной.
- **Фаза генерализации (Гроккинг):** Под воздействием L_2 -регуляризации (weight decay) сеть отбрасывает шумовые признаки и «кристаллизует» оптимальный алгебраический алгоритм в структуре своих весов.

Нахождение обобщающего решения строго ограничивает степени свободы системы. Геометрически это означает, что аттрактор динамической системы стягивается в низкоразмерное

подмногообразии. Следовательно, отслеживание эффективной размерности $\hat{d}(t)$ на скользящем окне должно действовать как опережающий индикатор топологического упрощения системы.

4 Вычислительный эксперимент

Для проверки гипотезы о гроккинге как о структурном переходе, сопровождающемся понижением размерности аттрактора, и валидации статистического метода как раннего предиктора гроккинга была проведена серия вычислительных экспериментов.

Во всех экспериментах использовалась архитектура однослойного Трансформера Omnigrok, которая была специально разработана для демонстрации более плавного и отчетливого эффекта гроккинга. Обучение проводилось с помощью оптимизатора AdamW со стохастикой (mini-batch), поскольку это является стандартом в глубоком обучении, а стохастический шум увеличивает дисперсию рядов скалярных метрик, позволяя алгоритмам фазовой реконструкции более точно оценивать истинную размерность фазового пространства. Отметим, что базовые эксперименты с полнопакетным градиентным спуском (Full-Batch GD) выявили проблему «вырожденного наблюдателя» из-за падения лосса в ноль и отсутствия дисперсии; эти результаты и их анализ вынесены в Приложение 7.1.

Помимо базовых метрик ($\mathcal{L}$, точность), алгоритм отслеживает норму градиента $\|g\|_2$, норму весов $\|w\|_2$, а также скалярное произведение между градиентами на соседних итерациях. Задержка τ подбирается эмпирически, а размерность вложения E вычисляется динамически с помощью метода MLE.

4.1 Эксперимент 1: Модульное сложение и нетипичный наблюдатель

В первом эксперименте использовался датасет модульного сложения по модулю $p = 113$. В качестве целевой метрики для метода MLE была выбрана норма весов ($\|w\|_2$), так как она сохраняет дисперсию на протяжении всей фазы меморизации и, что не менее важно, никак не зависит от валидационной выборки.

На Рис. 1 представлены результаты эксперимента. В верхней строке (с включенной L_2 -регуляризацией, $WD = 1.0$) наблюдается топологический коллапс: эффективная размерность (а точнее её оценка $d^*(t)$, полученная MLE методом) заканчивает падение быстрее нормы весов задолго до того, как метрика Ассигасу фиксирует генерализацию. В нижней строке (без регуляризации, $WD = 0.0$) гроккинг не наступает, сеть уходит в вечную меморизацию, и метод MLE корректно показывает не спадающую размерность фазового пространства. Это доказывает отсутствие ложноположительных срабатываний.

Как итог, наш метод успешно предсказывает гроккинг, фиксируя топологический коллапс размерности аттрактора. Однако, как мы видим, норма весов не является типичным наблюдателем: она имеет симметрии, из-за чего не передает истинную размерность аттрактора, но зато довольно чётко передает падение размерности и не зависит от валидационной выборки. Также наш предиктор на данной задаче не превосходит по точности предсказания предиктор, основанный напрямую на норме весов и $\mathcal{L}_{val}$, что связано с простотой самой задачи.




Рис. 1: Анализ гроккинга на модульном сложении при наличии стохастического шума. Сравнение динамики размерности E , построенной по ряду `weight_norm`, относительно Accuracy, Loss и `weight_norm` в режимах с генерализацией (верхний ряд) и без нее (нижний ряд).

4.2 Эксперимент 2: Неабелевы группы и сложные алгебраические представления (S_5)

Для верификации универсальности метода задача была усложнена до композиции перестановок неабелевой (некоммутативной) группы S_5 . С точки зрения механистической интерпретируемости [?], нейронные сети обобщают задачи на конечных группах путем выучивания их линейных неприводимых представлений (отображения элементов группы в матрицы весов).

В то время как коммутативное модульное сложение проецируется сетью в 2D-окружности (вещественный Фурье-базис, размерность представления равна 2 [2]), структура неабелевой группы S_5 значительно сложнее. Согласно алгебраической теории представлений, размерности неприводимых представлений группы S_5 составляют 1, 1, 4, 4, 5, 5 и 6. Поскольку одномерные представления теряют информацию о самих перестановках (являются неточными, *unfaithful*), для безошибочного вычисления композиции любых элементов сети математически необходимо задействовать подпространства весов размерности как минимум 4.

В контексте нелинейной динамики это означает, что минимальное количество степеней свободы, которое оптимизатор обязан сохранить для удержания обобщающего правила S_5 , равно 4. Следовательно, истинная размерность аттрактора лосса после гроккинга должна коллапсировать, но остановиться на уровне не ниже 4 компонент, что позволяет проверить способность нашего метода «вслепую» измерять алгебраическую сложность задачи.

Как видно на Рис. 2, предложенный метод успешно справился с этой задачей при анализе нормы весов. В фазе хаотичного поиска размерность E держится на более высоком уровне. При формировании сетью обобщающего алгебраического правила, размерность предсказуемо коллапсирует. Эксперимент без `Weight Decay` (нижний ряд) вновь подтверждает, что размерность не падает в случае, когда нет гроккинга.




Рис. 2: Анализ композиции в группе S_5 . Коллапс размерности аттрактора, построенного по ряду `weight_norm`, надежно фиксирует структурную перестройку сети даже при более сложной структуре скрытых представлений.

Особый интерес представляет оценка размерности по валидационной функции потерь (Рис. 3). Это доказывает, что данный эффект не зависит от выбранной метрики и не является субъективным. Взяв типичную метрику (`validation loss`), мы можем смотреть не только на коллапс её размерности, но и на её абсолютные значения, что полезно для понимания количества активных компонентов в модели. В случае S_5 мы видим, что размерность коллапсирует примерно до 4, что напрямую связано с тем, что для представления S_5 требуется как минимум 4 компонента. При этом в случае $WD = 0$ размерность не падает, а даже растет, что показывает переобучение модели и уход в вечную меморизацию.




Рис. 3: Анализ композиции в группе S_5 . Размерность E , восстановленная по `validation loss`, позволяет оценивать количество активных компонентов.

4.3 Теоретическая интерпретация результатов

Анализ полученных графиков позволяет сделать следующие теоретические выводы:

1. **Природа гроккинга:** Зафиксированный коллапс размерности доказывает, что гроккинг — это не просто уменьшение ошибки, а качественная перестройка динамической системы: переход с высокоэнтропийного аттрактора "запоминания" на низкоразмерный аттрактор "алгебраического правила".
2. **Метрики оптимизатора:** Эксперименты показали, что мы можем диагностировать гроккинг, не используя валидационную выборку (через норму весов). Это доказывает,

что данное явление не является субъективным артефактом конкретной отложенной выборки.

3. **Размерность при $WD = 0$:** При типичном наблюдателе ($\mathcal{L}_{val}$) размерность при $WD = 0$ не падает, а даже растет. Это подтверждает, что при переобучении модель заучивает выборку, используя большое количество активных компонент, и показывает важность выбора типичного наблюдателя для оценки алгебраической сложности алгоритма. В случае нетипичного наблюдателя (weight norm) размерность на протяжении всего обучения остается низкой, так как модель просто находит тривиальное решение и в силу устройства кросс-энтропии просто начинает наращивать масштаб весов, из-за чего эффективная размерность не растет.

5 Обсуждение результатов (Discussion)

Результаты проведенных вычислительных экспериментов подтверждают фундаментальную гипотезу работы: процесс оптимизации глубоких нейронных сетей может быть исследован с точки зрения теории нелинейных динамических систем и отслеживая размерность аттрактора можно предсказывать и качественно описывать гроккинг. Однако перенос методов фазовой реконструкции в ML выявил ряд специфических ограничений и физических эффектов, требующих отдельного осмысления.

1. Проблема вырожденного наблюдателя и роль стохастичности. В ходе экспериментов с полнопакетным градиентным спуском (Full-Batch GD) мы столкнулись с сложностью оценки размерности аттрактора: все используемые нами 1-D скалярные метрики вырождались в константу. С точки зрения нелинейной динамики, идеальная оптимизация без шума схлопывает траекторию в прямолинейный луч, лишая методы (такие как MLE) необходимой дисперсии для оценки кривизны ландшафта. Таким образом при анализе размерности стоит следить за тем, чтобы ряд не выражался. Это можно делать за счёт прореживания ряда, но это может негативно сказаться на точности оценки. Таким образом этот метод работает лучше всего в системах где ряды не выражаются, то есть в системах со стохастикой. Высокочастотный шум SGD заставляет оптимизатор исследовать локальную геометрию аттрактора. Кроме того, эксперименты показали, что норма весов ($\|w\|_2$) является гораздо более информативным и стабильным «наблюдателем» скрытой динамики, чем склонный к вырождению обучающий лосс.

3. Зависимость топологии от выбора наблюдателя (Observability). Одним из важнейших эмпирических результатов нашей работы стало выявление зависимости реконструированной размерности E от выбора скалярной метрики (функции наблюдения). В теории динамических систем теорема Такенса требует, чтобы функция наблюдения была «типичной» (generic) и не имела вырожденных симметрий.

Наши эксперименты показали, что норма весов ($\|w\|_2$) является симметричным наблюдателем. Динамика нормы определяется преимущественно балансом двух глобальных сил: градиентом ошибки (увеличивающим веса) и L_2 -регуляризацией (сжимающей веса). Из-за этого эффективная размерность ряда $\|w\|_2$ всегда коллапсирует до низких значений ($E \approx 2 \dots 4$), независимо от сложности решаемой задачи, так как эта метрика «слепа» к сложной угловой структуре представлений.

В противовес этому, функция потерь ($\mathcal{L}_{val}$ или зашумленный $\mathcal{L}_{train}$) напрямую зависит от логитов и чувствительна к внутренней алгебраической структуре сети. Работы по прямому спектральному анализу весов [2] показывают, что для модульного сложения сеть формирует 2D-окружности (Фурье-базисы). Оценка MLE по ряду лосса подтверждает это топологически: коллапс траектории останавливается на $E \approx 2$. В свою очередь, для неабелевой группы S_5 , неприводимые представления которой требуют пространств большей размерности [?], коллапс размерности, измеряемый именно по ряду лосса, предсказуемо останавливается на более высоком уровне $E \approx 4 \dots 6$. Таким образом, мы доказали, что для «слепой» оценки алгебраической сложности выученного алгоритма необходимо использовать метрики, напрямую связанные с распределением выходов сети, или более аккуратно агрегировать статистики параметров. Также стоит отметить, что лучше использовать именно $\mathcal{L}_{val}$, так как $\mathcal{L}_{train}$ быстрее выражается.

4. Независимость от валидационной выборки и количество активных компонент. С практической точки зрения, мониторинг валидационной функции потерь ($\mathcal{L}_{val}$) остается более

быстрым и дешевым предиктором наступления гроккинга, по крайней мере в простых проведенных экспериментах. Однако метрики являются лишь симптомами улучшения обобщающей способности. В свою очередь, обвал эффективной размерности E предоставляет строгое математическое доказательство структурного фазового перехода — процесса, при котором сеть отсекает шумовые степени свободы и сжимает траекторию в компактное подмногообразие. Также для нашего метода в принципе не нужна валидационная выборка.

6 Заключение

В данной работе предложен и верифицирован новый статистический метод ранней диагностики гроккинга, основанный на топологической реконструкции фазового пространства нейронной сети. Рассматривая стохастический градиентный спуск как вынужденную динамическую систему, мы эмпирически доказали, что феномен отложенной генерализации представляет собой структурный фазовый переход к низкоразмерному состоянию. Отслеживание этого процесса с помощью оценки Левиной-Бикеля (MLE Intrinsic Dimension) позволяет зафиксировать коллапс эффективной размерности аттрактора задолго до скачка валидационной точности, выступая надежным опережающим предиктором генерализации.

Предложенный подход отличается высокой универсальностью и практической применимостью. Показано, что топологический коллапс уверенно детектируется по внутренним скалярным логам оптимизатора (например, норме весов), что позволяет мониторить обобщающую способность без выделения валидационной выборки. Кроме того, эксперименты на задачах модульного сложения и композиции в неабелевой группе S_5 подтвердили, что остаточная размерность аттрактора строго согласуется с теоретической алгебраической сложностью выученного алгоритма при использовании типичного наблюдателя ($E \approx 2$ и $E \approx 4 \dots 6$ соответственно). Поскольку метод работает по принципу «черного ящика» и оперирует исключительно 1D-логами, он легко переносится на любые архитектуры и задачи без адаптации.

Главный итог исследования заключается в том, что одномерные скалярные ряды содержат исчерпывающую информацию для диагностики скрытых фазовых переходов в процессе обучения. Это открывает путь к созданию вычислительно дешевых методов мониторинга и структурной оптимизации глубоких моделей без необходимости ресурсоемкого анализа скрытых представлений или матриц Гесса.

Список литературы

- [1] Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. Grokking: Generalization beyond overfitting on small algorithmic datasets. *arXiv preprint arXiv:2201.02177*, 2022.
- [2] Neel Nanda, Lawrence Chan, Tom Lieberum, Jess Smith, and Jacob Steinhardt. Progress measures for grokking via mechanistic interpretability. In *International Conference on Learning Representations (ICLR)*, 2023.
- [3] Paul J T Notsawo, Hattie Zhou, Mohammad Pezeshki, Irina Rish, and Guillaume Dumas. Predicting grokking long before it happens: A look into the loss landscape of models which grok. *arXiv preprint arXiv:2306.13253*, 2023.
- [4] Floris Takens. Detecting strange attractors in turbulence. In *Dynamical systems and turbulence, Warwick 1980*, pages 366–381. Springer, 1981. doi: 10.1007/BFb0091924.
- [5] Jaroslav Stark. Delay embeddings for forced systems. i. deterministic forcing. *Journal of Nonlinear Science*, 9(3):255–332, 1999. doi: 10.1007/s003329900072.
- [6] Jaroslav Stark, David S Broomhead, ME Davies, and J Huke. Delay embeddings for forced systems. ii. stochastic forcing. *Journal of Nonlinear Science*, 13(6):519–577, 2003. doi: 10.1007/s00332-003-0534-4.
- [7] Elizaveta Levina and Peter J. Bickel. Maximum likelihood estimation of intrinsic dimension. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 17, 2004. URL <https://proceedings.neurips.cc/paper/2004/file/74934548253bcab8490ebd74afecebb5-Paper.pdf>.

- [8] Matthew B Kennel, Reggie Brown, and Henry DI Abarbanel. Determining embedding dimension for phase-space reconstruction using a geometrical construction. *Physical review A*, 45(6):3403, 1992. doi: 10.1103/PhysRevA.45.3403.
- [9] Liang Cao. Practical method for determining the minimum embedding dimension of a scalar time series. *Physica D: Nonlinear Phenomena*, 110(1-2):43–50, 1997. doi: 10.1016/S0167-2789(97)00118-8.
- [10] George Sugihara and Robert M May. Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series. *Nature*, 344(6268):734–741, 1990. doi: 10.1038/344734a0.

7 Appendix / supplemental material

7.1 Базовый эксперимент с полнопакетным градиентным спуском (Full-Batch)

В данном приложении приведены результаты первоначальных экспериментов, которые проводились на задаче модульного сложения с использованием полнопакетного градиентного спуска (Full-Batch GD). Этот эксперимент выступал в качестве базового (baseline) для подтверждения изначальной гипотезы.

Как видно на Рис. 4, в этом сеттинге нам удалось зафиксировать падение эффективной размерности (MLE ID) ряда $\mathcal{L}_{train}$ непосредственно перед скачком валидационной точности (с $E \approx 4 - 5$ до $E \approx 2.8$).

Однако этот эксперимент выявил важную методологическую проблему. При полнопакетной оптимизации корреляция между размером фазового пространства E и эффектом гроккинга становилась менее очевидной. С теоретической точки зрения это объясняется проблемой «вырожденного наблюдателя»: в отсутствие стохастического шума мини-батчей траектория оптимизатора вырождается в детерминированную гладкую кривую, а обучающий лосс падает практически до нуля, лишая метод MLE необходимой дисперсии для оценки истинной размерности пространства $d^*(t)$.

Именно это наблюдение послужило мотивацией для перехода к стохастической оптимизации (mini-batch) и использованию нетипичного наблюдателя (нормы весов), результаты которых представлены в основном разделе 4.




Рис. 4: Феномен гроккинга на базовом эксперименте (Full-Batch). Переход от запоминания к обобщению сопровождается снижением топологической сложности траектории $\mathcal{L}_{train}$, однако оценка страдает от недостатка дисперсии из-за вырождения ряда.