
Grokking prediction via estimation of neural network attractor dimensionality

Nickolay Karlov
MIPT
Moscow, Russia
karlov.na@phystech.edu

Alexey Kravatskiy
MIRIAI
Moscow, Russia
kravatskii.a@miriai.org

Abstract

We analyze delayed generalization (grokking) through the lens of empirical dynamic modeling. We hypothesize that the process of neural network training can be viewed as the evolution of a forced dynamical system possessing an attractor, which corresponds to a local minimum of the loss function, and that grokking represents a structural phase transition to a low-dimensional attractor. We apply the Levina-Bickel maximum likelihood estimator (MLE) of intrinsic dimension to 1D scalar logs of the weight norm, analyzing the resulting dimensionality trajectories to enable the early prediction of grokking. Results on modular addition and composition tasks over the non-abelian S_5 symmetric group demonstrate that grokking is characterized by an initial increase in attractor dimensionality followed by a sustained reduction, which supports the hypothesis that a topological collapse underlies delayed generalization.

Keywords: grokking, Levina-Bickel method, phase space, dynamical systems, neural network optimization.

1 Introduction

In classical statistical learning theory, the central paradigm is the bias-variance tradeoff. For a long time, it was believed that if, during the optimization process, the empirical risk (training error) drops to zero while the generalization gap remains large or begins to grow, the model irreversibly overfits, which requires stopping the training. However, in 2022, the phenomenon of grokking [1] was discovered—an effect of delayed generalization where a model, having been in a state of overfitting for thousands of iterations, undergoes a phase transition and achieves 100% accuracy on the test set. This phenomenon challenges classical approaches to training monitoring and highlights the need for new methods for early prediction of generalization ability.

In modern literature, several approaches to studying grokking have emerged. The first direction, based on mechanistic interpretability [2, 3], investigates grokking as a process of forming structured algebraic representations (e.g., Fourier bases) within the weight matrices. Although this "white-box" approach provides a deep understanding of the mechanics, it is computationally unscalable and requires the creation of unique progress measures for each new task. The second direction focuses on the macroscopic dynamics of the loss landscape ("black-box" approach). Recent works [?] analyze the influence of the weight norm and the slingshot effect, while the authors of [4] propose using spectral signatures of the loss (Hjorth parameters) to predict the phenomenon.

However, existing macroscopic methods possess a significant limitation: they only capture statistical changes in the system's metrics, yet they remain uninterpretable in terms of the internal complexity of the model.

In this paper, we propose a new statistical framework relying on the Levina-Bickel maximum likelihood estimator (MLE) of intrinsic dimension for the early prediction and structural description

of grokking. In the rigorous formulation of stochastic optimization, the task consists of minimizing the expected risk $\mathbb{E}_{\xi \sim \mathcal{D}}[\mathcal{L}(\mathbf{w}, \xi)]$, where the random variable ξ_t corresponds to the selection of a specific mini-batch at iteration t .

Because modern adaptive optimizers (such as SGD with momentum or AdamW) utilize the history of previous gradients, the weight trajectory $\mathbf{w}_t \in \mathbb{R}^D$ does not intrinsically form a Markov process. Therefore, we formalize the learning process as a non-autonomous dynamical system in an extended phase space:

$$\mathbf{s}_{t+1} = \Phi(\mathbf{s}_t, \xi_t), \quad \text{where } \mathbf{s}_t = (\mathbf{w}_t, \mathbf{h}_t) \in \mathbb{S}. \quad (1)$$

Here, $\mathbf{s}_t$ is the full state of the system at step t , comprising both the model parameters $\mathbf{w}_t$ and the vector of internal optimizer variables $\mathbf{h}_t$ (e.g., the exponential moving averages of the first and second moments in AdamW). The deterministic operator Φ defines the state update rule, and the sequence $\{\xi_t\}$ acts as the external stochastic forcing. It is precisely this gradient noise ξ_t that causes the trajectory to deviate from the ideal full-batch gradient descent, forcing the optimizer to continuously explore the local geometry of the loss landscape.

To reconstruct the properties of this system from scalar logs $y_t = \phi(\mathbf{s}_t) \in \mathbb{R}$, we rely on embedding theorems. The presence of hidden momentum variables $\mathbf{h}_t$ only increases the dimensionality of the original space $\mathbb{S}$, but does not prevent reconstruction if the system converges to a low-dimensional attractor. To account for the external influence (learning rate scheduler) and the stochasticity of the forcing ξ_t , the classical basis of Takens' embedding theorem [5] is extended by Stark's theorems on *delay embeddings* for systems with stochastic forcing [6, 7]. Stark proved that for such systems, the delay map preserves diffeomorphism, which provides us with the mathematical justification to estimate the effective dimensionality of the optimizer's attractor exclusively from one-dimensional macroscopic logs.

We consider grokking as a structural topological transition. In the memorization phase, the optimizer's trajectory constitutes a high-dimensional stochastic random walk, during which the system allocates redundant degrees of freedom to memorize the training set rather than to discover generalized rules. In the generalization phase, L_2 regularization (weight decay) forces the system to discard noisy degrees of freedom and build a compact algebraic structure within the weights. Topologically, this is equivalent to the compression of the optimizer's attractor into a low-dimensional submanifold.

To verify the proposed hypothesis and analyze the phenomenon of grokking, we conduct a series of computational experiments. As the primary mathematical tool, we apply the Levina-Bickel maximum likelihood estimation (MLE) of intrinsic dimension [8]. Training is performed on algebraic datasets using a 1-layer Transformer, as proposed in the Omnigrok study [?]. In the first experiment, the problem of modular addition (a commutative group) is solved; in the second, we tackle the composition operation within the non-abelian permutation group S_5 . Such a choice of test environments allows us to evaluate the proposed method both for its ability to provide early prediction of delayed generalization and for its sensitivity to changes in the hidden algebraic complexity of the task.

2 Problem Statement

Consider a neural network model $\mathcal{M}$ optimized to minimize the expected risk $\mathbb{E}_{\xi \sim \mathcal{D}}[\mathcal{L}(\mathbf{w}, \xi)]$. We formulate the training process over T iterations as a non-autonomous stochastic dynamical system. Because modern adaptive optimizers (e.g., SGD with momentum or AdamW) maintain internal state histories, the weight trajectory alone does not form a Markov process. Therefore, let $\mathbf{s}_t = (\mathbf{w}_t, \mathbf{h}_t) \in \mathbb{S}$ be the extended state of the system at step $t \in \{1, \dots, T\}$, where $\mathbf{w}_t \in \mathbb{R}^D$ denotes the model parameters and $\mathbf{h}_t$ represents the optimizer's internal variables. The evolution of this system is governed by the recurrence rule:

$$\mathbf{s}_{t+1} = \Phi(\mathbf{s}_t, \xi_t), \quad (2)$$

where Φ is the deterministic optimizer step and ξ_t acts as the external stochastic forcing, induced by the random mini-batch selection and hyperparameter scheduling.

In practice, the full high-dimensional state $\mathbf{s}_t$ is inaccessible for computationally efficient analysis. Instead, we observe a set of one-dimensional scalar time series $\mathbf{m}_t = [m_1(t), \dots, m_K(t)]^\top$ generated during optimization. Each macroscopic metric (e.g., training loss, weight norm, or gradient norm) acts as an observation function $m_i(t) = \phi_i(\mathbf{s}_t, \xi_t) \in \mathbb{R}$. In this regard, the **global research objective** is to reconstruct the topological properties of the hidden attractor of $\mathbf{s}_t$ and to develop an early predictor of phase transitions during optimization, relying exclusively on the 1D observation series $m_i(t)$.

The primary target phase transition in our work is the phenomenon of delayed generalization. Let us introduce its formal description.

Definition 1 (Grokking). *Let $\text{Acc}_{\text{train}}(\mathbf{w}_t)$ and $\text{Acc}_{\text{val}}(\mathbf{w}_t)$ denote the model’s accuracy on the training and validation sets, respectively. Due to stochastic optimizer noise, instantaneous metric values are prone to random fluctuations (e.g., spurious accuracy spikes early in training). Let $\overline{\text{Acc}}(t)$ denote the smoothed metric (a moving average over a local time window). For a given small error threshold $\epsilon > 0$ (set to 0.05 in this work), we define two critical optimization moments:*

- **Memorization moment** (t_{mem}): *the minimum step t starting from which the network robustly interpolates the training data:*

$$t_{\text{mem}} = \min \{t \mid \forall \tau \geq t, \overline{\text{Acc}}_{\text{train}}(\mathbf{w}_\tau) \geq 1 - \epsilon\}.$$

Typically, at this moment, the validation accuracy remains at the level of random guessing ($\text{Acc}_{\text{val}}(\mathbf{w}_{t_{\text{mem}}}) \approx 0$).

- **Generalization moment** (t_{gen}): *the minimum step t starting from which a stable increase in generalization ability is recorded:*

$$t_{\text{gen}} = \min \{t \mid \forall \tau \geq t, \overline{\text{Acc}}_{\text{val}}(\mathbf{w}_\tau) \geq 1 - \epsilon\}.$$

The optimization process is classified as grokking if there is an anomalous delay between these events: $t_{\text{gen}} \gg t_{\text{mem}}$.

As Definition 1 implies, on the interval $t \in (t_{\text{mem}}, t_{\text{gen}})$, classical macroscopic accuracy metrics reside on a quasi-stationary plateau. During this period, the optimizer outwardly appears trapped in an overfitting regime; however, hidden structural reorganizations occur within the model weights. We hypothesize that the transition from memorization to generalization constitutes a topological collapse of the optimizer’s degrees of freedom.

To detect this collapse, we introduce $\hat{d}(t)$ —an estimate of the effective (intrinsic) dimensionality of the reconstructed attractor at time t . Based on this, we formulate a formal criterion for successful early prediction.

Definition 2 (Grokking prediction criterion). *A successful early warning signal of grokking is characterized by the formation of a stable downward trend in the effective dimensionality $\hat{d}(t)$, culminating in its stabilization at a new, lower-dimensional level strictly before the actual increase in validation accuracy:*

$$\exists t_{\text{drop}} \in (t_{\text{mem}}, t_{\text{gen}}) \quad \text{such that} \quad \forall t \in [t_{\text{drop}}, t_{\text{gen}}]: \hat{d}(t) \ll \hat{d}(t_{\text{mem}}). \quad (3)$$

Furthermore, on the interval $(t_{\text{mem}}, t_{\text{drop}})$, a macroscopically monotonic decline of $\hat{d}(t)$ without significant upward rebounds must be observed.

Meeting the conditions of Definition 2 in practice implies that the topological dimensionality collapse indeed precedes generalization, and that the scalar observation functions $m_i(t)$ contain sufficient information for its early detection.

3 Theoretical Justification and Proposed Method

To solve the stated problem, we propose a framework relying on the theory of nonlinear dynamical systems. This section justifies the theoretical possibility of extracting the geometry of a high-dimensional system from a 1D scalar log and presents the algorithm for estimating the effective dimensionality $\hat{d}(t)$.

3.1 Learning as a Forced Dynamical System (Embedding Theorems)

In nonlinear dynamics theory, an **attractor** $\mathcal{A} \subset \mathbb{W}$ is understood as a compact invariant subset of the phase space to which the system’s trajectories asymptotically converge. In the context of machine learning, the gradient optimization process seeks to minimize the loss function. In this regard, we rely on the assumption that over time, the weight trajectory $\mathbf{w}_t$ loses redundant degrees of freedom and

converges to a certain local attractor (e.g., a stationary stochastic cloud around a flat minimum). Let the true dimensionality of this attractor be m , where $m \ll D$.

According to Takens' embedding theorem [5], for autonomous systems, the topology of the entire high-dimensional attractor $\mathcal{A}$ can be reconstructed from a single scalar observation series $X(t) \in \{m_i(t)\}$ using delay embeddings:

$$\mathbf{x}_t = [X(t), X(t - \tau), \dots, X(t - (E - 1)\tau)]^\top \in \mathbb{R}^E, \quad (4)$$

provided that the dimensionality of the embedding space $E \geq 2m + 1$.

To formalize the algorithms, we introduce the DelayEmbedding construction operator, which maps the original one-dimensional time series $\{X(t)\}_{t=1}^N$ to a sequence of vectors in the reconstructed phase space:

$$\text{DelayEmbedding}(\{X(t)\}_{t=1}^N, E, \tau) = \{\mathbf{x}_t\}_{t=(E-1)\tau+1}^N, \quad (5)$$

where each vector $\mathbf{x}_t \in \mathbb{R}^E$ is constructed according to Eq. (3). The result of this operator is the reconstructed phase manifold $M \subset \mathbb{R}^E$, consisting of $|M| = N - (E - 1)\tau$ points.

A fundamental mathematical requirement of embedding theorems is the *genericity* of the observation function $\phi(\cdot)$. From the perspective of differential topology, this means that the metric function must not possess degenerate symmetries that glue distinct points of the phase space together during projection. For example, considering the extended state $\mathbf{s}_t = (\mathbf{w}_t, \mathbf{h}_t)$, the aggregated weight norm $\|\mathbf{w}_t\|_2$ possesses spherical symmetry, measuring only the radial distance of the parameters from the origin while entirely ignoring the optimizer's history $\mathbf{h}_t$. In certain regimes, it can act as a "degenerate observer," losing information about the algebraic structure (angular coordinates) of the system. Conversely, nonlinear metrics directly dependent on the logit distribution (such as the loss function $\mathcal{L}$) act as generic observers that preserve the high-dimensional topology of the extended system.

However, gradient descent in deep learning is not an autonomous system. The influence of random mini-batch selection, combined with hyperparameter schedules (learning rate schedulers), formally violates the classical Takens conditions. To mathematically justify our approach in this non-autonomous setting, we rely on Stark's embedding theorems for forced dynamical systems with mixed forcing [6, 7].

In modern optimization theory, the extended learning process $\mathbf{s}_{t+1} = \Phi(\mathbf{s}_t, \omega_t, \xi_t)$ almost always occurs under the influence of two types of forcing. The deterministic forcing ω_t (e.g., a learning rate schedule) obeys Stark's theorem for deterministic systems [6], which guarantees the preservation of topology under a smooth external driver. In turn, the stochastic forcing ξ_t (mini-batch gradient noise) is approximated by a multivariate Gaussian process [9], and the selection of a batch from a finite set is described in terms of Iterated Function Systems [7]. For both cases, Stark and co-authors proved that the delay map preserves diffeomorphism properties. This fundamentally justifies the validity of measuring the dimensionality of the hidden attractor in the extended state space $\mathbb{S}$ by operating exclusively on scalar logs in the reconstructed phase space $\mathbb{R}^E$, regardless of the presence of internal optimizer memory, deterministic schedules, or stochastic noise.

3.2 Effective Dimensionality Estimation of the Phase Space

To detect phase transitions, we need to dynamically estimate the attractor dimension of the system. In our framework, we reviewed both classical and modern methods, ranking them by their robustness to the specifics of neural network optimization (mini-batch noise):

1. False Nearest Neighbors (FNN) [10] and Cao's Method [11]: These are geometric "bottom-up" approaches. The essence of FNN lies in the sequential "unfolding" of the attractor. Given an insufficient embedding dimension, distant segments of the high-dimensional trajectory are projected close to each other, forming "false" neighbors. The method measures the distance between a point and its nearest spatial neighbor, and checks how much they diverge when transitioning to dimension $d + 1$. Cao's method is a rigorous mathematical development of this approach that analyzes the averaged ratio of distances, eliminating the need for manual threshold selection.

However, a fundamental limitation of both geometric methods is the strict requirement of *global recurrence* of the trajectory. To identify the complex shape of the attractor, the system must regularly return to the vicinity of its past states. During neural network optimization, we frequently deal with

transient processes—for example, when the loss function drops monotonically. In the absence of recurrence, the nearest spatial neighbor of a point $\mathbf{x}_t$ becomes its own temporal neighbor $\mathbf{x}_{t-1}$. Because such points do not "scatter" in any dimensionality, geometric methods degenerate, erroneously perceiving the high-dimensional descent trajectory as a simple 1D line, yielding a trivial estimate of $\hat{d} = 1$.

2. Simplex Projection Maximization [12]: The optimal E is sought as the argument that maximizes the autoregressive correlation ρ when predicting the future state y_{t+1} based on its neighbors in $\mathbb{R}^E$. This topologically guarantees the best unfolding of the attractor without overfitting to noise; however, its discrete (integer-valued) resolution coarsens the detection of smooth phase transitions.

3. Maximum Likelihood Estimation (MLE Intrinsic Dimension) [8]: Selected as the primary analytical tool in our framework. In contrast to geometric "bottom-up" methods, the Levina-Bickel method projects the time series directly into a redundant high-dimensional space (e.g., $E = 15$) and estimates the local intrinsic dimension $\hat{d}_{x_t}$ statistically, based on the Poisson distribution of distances to the k nearest neighbors. The process is formalized in Algorithm 1.

Algorithm 1 MLE Intrinsic Dimension Estimation (Levina-Bickel)

Input: Observation time series $\mathcal{D}_{obs}$, delay τ , maximum embedding dimension E_{max} , window W , neighbors k

Output: Effective dimensionality $\hat{d}(t)$

- 1: $M \leftarrow \text{DelayEmbedding}(\mathcal{D}_{obs}, E_{max}, \tau)$ ▷ Embedding into $\mathbb{R}^{E_{max}}$
 - 2: **for** each point $\mathbf{x}_t \in M$ within the sliding window W **do**
 - 3: Find k nearest neighbors with distances $r_1 \leq r_2 \leq \dots \leq r_k$
 - 4: $\hat{d}_{x_t} \leftarrow \left[\frac{1}{k-1} \sum_{j=1}^{k-1} \log \left(\frac{r_k}{r_j} \right) \right]^{-1}$ ▷ Local estimation via radius r_k
 - 5: **end for**
 - 6: $\hat{d}(t) \leftarrow \frac{1}{|W|} \sum_{\mathbf{x}_t \in W} \hat{d}_{x_t}$ ▷ Averaging dimensionality over the window W
 - 7: **return** $\hat{d}(t)$
-

This method returns a *continuous* value that is computed locally, does not require global recurrence of the trajectory, and demonstrates phenomenal robustness to microscopic mini-batch noise.

3.3 The Physics of Grokking as a Topological Collapse

Applying the described mathematical apparatus, we formalize grokking as a structural phase transition in the loss landscape.

- **Memorization phase:** The network "memorizes" the training data as uncorrelated noise. The optimizer trajectory w_t wanders along a flat, high-dimensional manifold (high-entropy state). During this period, the effective dimensionality $\hat{d}(t)$ computed by the MLE algorithm will be maximal ($\hat{d} \gg 1$).
- **Generalization phase (Grokking):** Under the influence of L_2 regularization (weight decay), the network discards noisy features and "crystallizes" the optimal algebraic algorithm within the structure of its weights.

Finding a generalizing solution strictly restricts the degrees of freedom of the system. Geometrically, this means that the dynamical system's attractor contracts into a low-dimensional submanifold. Consequently, tracking the effective dimensionality $\hat{d}(t)$ over a sliding window should act as an early indicator of the system's topological simplification, without requiring the analysis of heavy Hessian matrices.

4 Вычислительный эксперимент

Для проверки гипотезы о гроккинге как о структурном переходе, сопровождающемся понижением размерности аттрактора, и валидации статистического метода как раннего предиктора гроккинга была проведена серия вычислительных экспериментов.

Во всех экспериментах использовалась архитектура однослойного Трансформера Omnigrok, которая была специально разработана для демонстрации более плавного и отчетливого эффекта гроккинга. Обучение проводилось с помощью оптимизатора AdamW со стохастикой (mini-batch), поскольку это является стандартом в глубоком обучении, а стохастический шум увеличивает дисперсию рядов скалярных метрик, позволяя алгоритмам фазовой реконструкции более точно оценивать истинную размерность фазового пространства. Отметим, что базовые эксперименты с полнопакетным градиентным спуском (Full-Batch GD) выявили проблему «вырожденного наблюдателя» из-за падения лосса в ноль и отсутствия дисперсии; эти результаты и их анализ вынесены в Приложение 7.1.

Помимо базовых метрик ($\mathcal{L}$, точность), алгоритм отслеживает норму градиента $\|g\|_2$, норму весов $\|w\|_2$, а также скалярное произведение между градиентами на соседних итерациях. Задержка τ подбирается эмпирически, а размерность вложения E вычисляется динамически с помощью метода MLE.

4.1 Эксперимент 1: Модульное сложение и нетипичный наблюдатель

В первом эксперименте использовался датасет модульного сложения по модулю $p = 113$. В качестве целевой метрики для метода MLE была выбрана норма весов ($\|w\|_2$), так как она сохраняет дисперсию на протяжении всей фазы меморизации и, что не менее важно, никак не зависит от валидационной выборки.

На Рис. 1 представлены результаты эксперимента. В верхней строке (с включенной L_2 -регуляризацией, $WD = 1.0$) наблюдается топологический коллапс: эффективная размерность (а точнее её оценка $d^*(t)$, полученная MLE методом) заканчивает падение быстрее нормы весов задолго до того, как метрика Ассигасу фиксирует генерализацию. В нижней строке (без регуляризации, $WD = 0.0$) гроккинг не наступает, сеть уходит в вечную меморизацию, и метод MLE корректно показывает не спадающую размерность фазового пространства. Это доказывает отсутствие ложноположительных срабатываний.

Как итог, наш метод успешно предсказывает гроккинг, фиксируя топологический коллапс размерности аттрактора. Однако, как мы видим, норма весов не является типичным наблюдателем: она имеет симметрии, из-за чего не передает истинную размерность аттрактора, но зато довольно чётко передает падение размерности и не зависит от валидационной выборки. Также наш предиктор на данной задаче не превосходит по точности предсказания предиктор, основанный напрямую на норме весов и $\mathcal{L}_{val}$, что связано с простотой самой задачи.




Рис. 1: Анализ гроккинга на модульном сложении при наличии стохастического шума. Сравнение динамики размерности E , построенной по ряду `weight_norm`, относительно Accuracy, Loss и `weight_norm` в режимах с генерализацией (верхний ряд) и без нее (нижний ряд).

4.2 Эксперимент 2: Неабелевы группы и сложные алгебраические представления (S_5)

Для верификации универсальности метода задача была усложнена до композиции перестановок неабелевой (некоммутативной) группы S_5 . С точки зрения механистической интерпретируемости [3], нейронные сети обобщают задачи на конечных группах путем выучивания их линейных неприводимых представлений (отображения элементов группы в матрицы весов).

В то время как коммутативное модульное сложение проецируется сетью в 2D-окружности (вещественный Фурье-базис, размерность представления равна 2 [2]), структура неабелевой группы S_5 значительно сложнее. Согласно алгебраической теории представлений, размерности неприводимых представлений группы S_5 составляют 1, 1, 4, 4, 5, 5 и 6. Поскольку одномерные представления теряют информацию о самих перестановках (являются неточными, *unfaithful*), для безошибочного вычисления композиции любых элементов сети математически необходимо задействовать подпространства весов размерности как минимум 4.

В контексте нелинейной динамики это означает, что минимальное количество степеней свободы, которое оптимизатор обязан сохранить для удержания обобщающего правила S_5 , равно 4. Следовательно, истинная размерность аттрактора лосса после гроккинга должна коллапсировать, но остановиться на уровне не ниже 4 компонент, что позволяет проверить способность нашего метода «вслепую» измерять алгебраическую сложность задачи.

Как видно на Рис. 2, предложенный метод успешно справился с этой задачей при анализе нормы весов. В фазе хаотичного поиска размерность E держится на более высоком уровне. При формировании сетью обобщающего алгебраического правила, размерность предсказуемо коллапсирует. Эксперимент без Weight Decay (нижний ряд) вновь подтверждает, что размерность не падает в случае, когда нет гроккинга.




Рис. 2: Анализ композиции в группе S_5 . Коллапс размерности аттрактора, построенного по ряду `weight_norm`, надежно фиксирует структурную перестройку сети даже при более сложной структуре скрытых представлений.

Особый интерес представляет оценка размерности по валидационной функции потерь (Рис. 3). Это доказывает, что данный эффект не зависит от выбранной метрики и не является субъективным. Взяв типичную метрику (*validation loss*), мы можем смотреть не только на коллапс её размерности, но и на её абсолютные значения, что полезно для понимания количества активных компонентов в модели. В случае S_5 мы видим, что размерность коллапсирует примерно до 4, что напрямую связано с тем, что для представления S_5 требуется как минимум 4 компонента. При этом в случае $WD = 0$ размерность не падает, а даже растет, что показывает переобучение модели и уход в вечную меморизацию.




Рис. 3: Анализ композиции в группе S_5 . Размерность E , восстановленная по validation loss, позволяет оценивать количество активных компонентов.

4.3 Теоретическая интерпретация результатов

Анализ полученных графиков позволяет сделать следующие теоретические выводы:

1. **Природа гроккинга:** Зафиксированный коллапс размерности доказывает, что гроккинг — это не просто уменьшение ошибки, а качественная перестройка динамической системы: переход с высокоэнтропийного аттрактора "запоминания" на низкоразмерный аттрактор "алгебраического правила".
2. **Метрики оптимизатора:** Эксперименты показали, что мы можем диагностировать гроккинг, не используя валидационную выборку (через норму весов). Это доказывает, что данное явление не является субъективным артефактом конкретной отложенной выборки.
3. **Размерность при $WD = 0$:** При типичном наблюдателе ($\mathcal{L}_{val}$) размерность при $WD = 0$ не падает, а даже растет. Это подтверждает, что при переобучении модель заучивает выборку, используя большое количество активных компонент, и показывает важность выбора типичного наблюдателя для оценки алгебраической сложности алгоритма. В случае нетипичного наблюдателя (weight norm) размерность на протяжении всего обучения остается низкой, так как модель просто находит тривиальное решение и в силу устройства кросс-энтропии просто начинает наращивать масштаб весов, из-за чего эффективная размерность не растет.

5 Обсуждение результатов (Discussion)

Результаты проведенных вычислительных экспериментов подтверждают фундаментальную гипотезу работы: процесс оптимизации глубоких нейронных сетей может быть исследован с точки зрения теории нелинейных динамических систем и отслеживая размерность аттрактора можно предсказывать и качественно описывать гроккинг. Однако перенос методов фазовой реконструкции в ML выявил ряд специфических ограничений и физических эффектов, требующих отдельного осмысления.

1. Проблема вырожденного наблюдателя и роль стохастичности. В ходе экспериментов с полнопакетным градиентным спуском (Full-Batch GD) мы столкнулись с сложностью оценки размерности аттрактора: все используемые нами 1-D скалярные метрики вырождались в константу. С точки зрения нелинейной динамики, идеальная оптимизация без шума схлопывает траекторию в прямолинейный луч, лишая методы (такие как MLE) необходимой дисперсии для оценки кривизны ландшафта. Таким образом при анализе размерности стоит следить за тем, чтобы ряд не выражался. Это можно делать за счёт прореживания ряда, но это может негативно сказаться на точности оценки. Таким образом этот метод работает лучше всего в системах где ряды не выражаются, то есть в системах со стохастикой. Высоочастотный шум SGD заставляет оптимизатор исследовать локальную геометрию аттрактора. Кроме того, эксперименты показали, что норма весов ($\|w\|_2$) является гораздо более информативным и стабильным «наблюдателем» скрытой динамики, чем склонный к вырождению обучающий лосс.

3. Зависимость топологии от выбора наблюдателя (Observability). Одним из важнейших эмпирических результатов нашей работы стало выявление зависимости реконструированной размерности E от выбора скалярной метрики (функции наблюдения). В теории динамических систем теорема Такенса требует, чтобы функция наблюдения была «типичной» (generic) и не имела вырожденных симметрий.

Наши эксперименты показали, что норма весов ($\|w\|_2$) является симметричным наблюдателем. Динамика нормы определяется преимущественно балансом двух глобальных сил: градиентом ошибки (увеличивающим веса) и L_2 -регуляризацией (сжимающей веса). Из-за этого эффективная размерность ряда $\|w\|_2$ всегда коллапсирует до низких значений ($E \approx 2 \dots 4$), независимо от сложности решаемой задачи, так как эта метрика «слепа» к сложной угловой структуре представлений.

В противовес этому, функция потерь (L_{sval} или зашумленный L_{strain}) напрямую зависит от логитов и чувствительна к внутренней алгебраической структуре сети. Работы по прямому спектральному анализу весов [2] показывают, что для модульного сложения сеть формирует 2D-окружности (Фурье-базисы). Оценка MLE по ряду лосса подтверждает это топологически: коллапс траектории останавливается на $E \approx 2$. В свою очередь, для неабелевой группы S_5 , неприводимые представления которой требуют пространств большей размерности [3], коллапс размерности, измеряемый именно по ряду лосса, предсказуемо останавливается на более высоком уровне $E \approx 4 \dots 6$. Таким образом, мы доказали, что для «слепой» оценки алгебраической сложности выученного алгоритма необходимо использовать метрики, напрямую связанные с распределением выходов сети, или более аккуратно агрегировать статистики параметров. Также стоит отметить, что лучше использовать именно L_{sval} , так как L_{strain} быстрее выражается.

4. Независимость от валидационной выборки и количество активных компонент. С практической точки зрения, мониторинг валидационной функции потерь (L_{sval}) остается более быстрым и дешевым предиктором наступления гроккинга, по крайней мере в простых проведенных экспериментах. Однако метрики являются лишь симптомами улучшения обобщающей способности. В свою очередь, обвал эффективной размерности E предоставляет строгое математическое доказательство структурного фазового перехода — процесса, при котором сеть отсекает шумовые степени свободы и сжимает траекторию в компактное подмногообразие. Также для нашего метода в принципе не нужна валидационная выборка.

6 Заключение

В данной работе предложен и верифицирован новый статистический метод ранней диагностики гроккинга, основанный на топологической реконструкции фазового пространства нейронной сети. Рассматривая стохастический градиентный спуск как вынужденную динамическую систему, мы эмпирически доказали, что феномен отложенной генерализации представляет собой структурный фазовый переход к низкоразмерному состоянию. Отслеживание этого процесса с помощью оценки Левиной-Бикеля (MLE Intrinsic Dimension) позволяет зафиксировать коллапс эффективной размерности аттрактора задолго до скачка валидационной точности, выступая надежным опережающим предиктором генерализации.

Предложенный подход отличается высокой универсальностью и практической применимостью. Показано, что топологический коллапс уверенно детектируется по внутренним скалярным логам оптимизатора (например, норме весов), что позволяет мониторить обобщающую способность без выделения валидационной выборки. Кроме того, эксперименты на задачах модульного сложения и композиции в неабелевой группе S_5 подтвердили, что остаточная размерность аттрактора строго согласуется с теоретической алгебраической сложностью выученного алгоритма при использовании типичного наблюдателя ($E \approx 2$ и $E \approx 4 \dots 6$ соответственно). Поскольку метод работает по принципу «черного ящика» и оперирует исключительно 1D-логами, он легко переносится на любые архитектуры и задачи без адаптации.

Главный итог исследования заключается в том, что одномерные скалярные ряды содержат исчерпывающую информацию для диагностики скрытых фазовых переходов в процессе обучения. Это открывает путь к созданию вычислительно дешевых методов мониторинга и структурной оптимизации глубоких моделей без необходимости ресурсоемкого анализа скрытых представлений или матриц Гессеана.

Список литературы

- [1] Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. Grokking: Generalization beyond overfitting on small algorithmic datasets. *arXiv preprint arXiv:2201.02177*, 2022.
- [2] Neel Nanda, Lawrence Chan, Tom Lieberum, Jess Smith, and Jacob Steinhardt. Progress measures for grokking via mechanistic interpretability. In *International Conference on Learning Representations (ICLR)*, 2023.
- [3] Bilal Chughtai, Lawrence Chan, and Neel Nanda. A toy model of universality: Reverse engineering how networks learn group operations. In *International Conference on Machine Learning (ICML)*, 2023. URL <https://arxiv.org/abs/2302.03025>.
- [4] Paul J T Notsawo, Hattie Zhou, Mohammad Pezeshki, Irina Rish, and Guillaume Dumas. Predicting grokking long before it happens: A look into the loss landscape of models which grok. *arXiv preprint arXiv:2306.13253*, 2023.
- [5] Floris Takens. Detecting strange attractors in turbulence. In *Dynamical systems and turbulence, Warwick 1980*, pages 366–381. Springer, 1981. doi: 10.1007/BFb0091924.
- [6] Jaroslav Stark. Delay embeddings for forced systems. i. deterministic forcing. *Journal of Nonlinear Science*, 9(3):255–332, 1999. doi: 10.1007/s003329900072.
- [7] Jaroslav Stark, David S Broomhead, ME Davies, and J Huke. Delay embeddings for forced systems. ii. stochastic forcing. *Journal of Nonlinear Science*, 13(6):519–577, 2003. doi: 10.1007/s00332-003-0534-4.
- [8] Elizaveta Levina and Peter J. Bickel. Maximum likelihood estimation of intrinsic dimension. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 17, 2004. URL <https://proceedings.neurips.cc/paper/2004/file/74934548253bcab8490ebd74afecebb5-Paper.pdf>.
- [9] Stephan Mandt, Matthew D Hoffman, and David M Blei. Stochastic gradient descent as approximate bayesian inference. *Journal of Machine Learning Research*, 18(1):4873–4907, 2017.
- [10] Matthew B Kennel, Reggie Brown, and Henry DI Abarbanel. Determining embedding dimension for phase-space reconstruction using a geometrical construction. *Physical review A*, 45(6):3403, 1992. doi: 10.1103/PhysRevA.45.3403.
- [11] Liang Cao. Practical method for determining the minimum embedding dimension of a scalar time series. *Physica D: Nonlinear Phenomena*, 110(1-2):43–50, 1997. doi: 10.1016/S0167-2789(97)00118-8.
- [12] George Sugihara and Robert M May. Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series. *Nature*, 344(6268):734–741, 1990. doi: 10.1038/344734a0.

7 Appendix / supplemental material

7.1 Базовый эксперимент с полнопакетным градиентным спуском (Full-Batch)


В данном приложении приведены результаты первоначальных экспериментов, которые проводились на задаче модульного сложения с использованием полнопакетного градиентного спуска (Full-Batch GD). Этот эксперимент выступал в качестве базового (baseline) для подтверждения изначальной гипотезы.

Как видно на Рис. 4, в этом сеттинге нам удалось зафиксировать падение эффективной размерности (MLE ID) ряда $\mathcal{L}_{train}$ непосредственно перед скачком валидационной точности (с $E \approx 4 - 5$ до $E \approx 2.8$).


Однако этот эксперимент выявил важную методологическую проблему. При полнопакетной оптимизации корреляция между размером фазового пространства E и эффектом гроккинга

становилась менее очевидной. С теоретической точки зрения это объясняется проблемой «вырожденного наблюдателя»: в отсутствие стохастического шума мини-батчей траектория оптимизатора вырождается в детерминированную гладкую кривую, а обучающий лосс падает практически до нуля, лишая метод MLE необходимой дисперсии для оценки истинной размерности пространства $d^*(t)$.

Именно это наблюдение послужило мотивацией для перехода к стохастической оптимизации (mini-batch) и использованию нетипичного наблюдателя (нормы весов), результаты которых представлены в основном разделе 4.



(a) Динамика Train/Val Accuracy



(b) Коллапс размерности (MLE ID)

Рис. 4: Феномен гроккинга на базовом эксперименте (Full-Batch). Переход от запоминания к обобщению сопровождается снижением топологической сложности траектории $\mathcal{L}_{train}$, однако оценка страдает от недостатка дисперсии из-за вырождения ряда.