
Предсказание гроккинга за счёт вычисления размерности аттрактора нейросети

Nickolay Karlov
MIPT
Moscow, Russia
karlov.na@phystech.edu

Alexey Kravatskiy
MIRIAI
Moscow, Russia
kravatskii.a@miriai.org

Abstract

Обучение глубоких моделей сопровождается генерацией множества взаимосвязанных временных рядов (loss, accuracy, weight parameters, learning rate). В данной работе выдвигается гипотеза о том, что процесс оптимизации нейронной сети может быть рассмотрен как вынужденная динамическая система обладающая аттрактором, соответствующим локальному минимуму функции потерь, а феномен отложенной генерализации (гроккинг) представляет собой структурный фазовый переход на низкоразмерный аттрактор. Предложен статистический метод, использующий оценку размерности Левиной-Бикеля (MLE Intrinsic Dimension), способный осуществлять раннее предсказание гроккинга и оценивать истинную алгебраическую сложность выученного алгоритма через отслеживание коллапса размерности 1-D логов обучения. Метод был проверен на задачах модульного сложения и композиции в группе перестановок S_5 с использованием архитектуры Omnigrok. Результаты демонстрируют, что гроккинг сопровождается устойчивым снижением размерности аттрактора, что подтверждает гипотезу о топологическом коллапсе как механизме отложенной генерализации.

Keywords: гроккинг, метод Левиной-Бикеля, фазовое пространство, динамические системы, оптимизация нейросетей.

1 Введение

В классической статистической теории обучения центральной парадигмой является баланс между смещением и дисперсией (bias-variance tradeoff). Долгое время считалось, что если в процессе оптимизации эмпирический риск (ошибка на обучающей выборке) падает до нуля, а зазор обобщения остается большим или начинает расти, модель безвозвратно переобучается, что требует остановки обучения. Однако в 2022 году был открыт феномен гроккинга [1] — эффекта отложенной генерализации, при котором модель, находясь в состоянии переобучения на протяжении тысяч итераций, совершает фазовый переход и достигает идеальной точности на тестовой выборке. Этот феномен ставит под сомнение классические подходы к мониторингу обучения и порождает необходимость в новых методах раннего предсказания обобщающей способности.

В современной литературе сформировалось несколько подходов к изучению гроккинга. Первое направление, основанное на механистической интерпретируемости (mechanistic interpretability) [2, 3], исследует гроккинг как процесс формирования структурированных алгебраических представлений (например, Фурье-базисов) внутри матриц весов. Хотя этот «white-box» подход дает глубокое понимание механики, он вычислительно немасштабируем и требует создания уникальных метрик (progress measures) под каждую новую задачу. Второе направление фокусируется на макроскопической динамике ландшафта функции потерь («black-box» подход). В

работах [4, 5] анализируется влияние нормы весов и эффекта «рогатки» (slingshot effect), а авторы [6] предлагают использовать спектральные сигнатуры лосса (параметры Йорта) для предсказания феномена.

Однако существующие макроскопические методы обладают существенным ограничением: они фиксируют лишь статистические изменения параметров системы, но не отражают изменения *количества степеней свободы* (внутренней сложности) самой модели в процессе обучения.

В данной работе предлагается новый статистический метод, опирающийся на статистическую оценку размерности аттрактора для предсказания и структурного описания гроккинга. Траектория оптимизации формализуется как неавтономная (вынужденная) динамическая система $\mathbf{w}_{t+1} = F(\mathbf{w}_t, \xi_t)$. Здесь $\mathbf{w}_t \in \mathbb{R}^D$ — вектор параметров модели, случайная величина ξ_t описывает стохастический выбор конкретного мини-батча данных на итерации t , а F задает детерминированный шаг оптимизатора (например, SGD или AdamW), вычисленный исключительно на батче ξ_t . Выбор мини-батчей выступает в роли внешнего стохастического воздействия (форсинга), отклоняющего траекторию от идеального градиентного спуска по полной выборке и заставляющего оптимизатор непрерывно исследовать локальную геометрию ландшафта функции потерь. Для восстановления свойств этой высокоразмерной системы по скалярным логам $y_t \in \mathbb{R}$ используется теорема Такенса о вложении [7]. Чтобы учесть нестационарность и стохастичность градиентного спуска, теоретическая база расширяется за счет теорем Старка о delay embeddings для систем с детерминированным и стохастическим форсингом [8, 9].

Предлагаемая нами модель явления заключается в том, что гроккинг — это структурный топологический переход. В фазе меморизации траектория оптимизатора представляет собой высокоразмерное стохастическое блуждание, в ходе которого система затрачивает избыточные степени свободы на простую интерполяцию обучающей выборки. В фазе генерализации L_2 -регуляризация (weight decay) заставляет систему сбросить шумовые степени свободы и выстроить компактную алгебраическую структуру в весах. Топологически это эквивалентно сжатию аттрактора оптимизатора в подмногообразии низкой размерности.

Для проверки предложенной гипотезы и анализа феномена гроккинга в работе проводится серия вычислительных экспериментов. В качестве основного математического инструмента применяется оценка внутренней размерности фазового пространства методом максимального правдоподобия Левиной-Бикеля (MLE Intrinsic Dimension) [10]. Обучение проводится на алгебраических датасетах с использованием однослойного Трансформера, предложенной в исследовании Omnigrok [4]. В первом эксперименте решается задача модульного сложения (коммутативная группа), во втором — задача операции композиции в группе перестановок S_5 (неабелева группа). Подобный выбор тестовых сред позволяет протестировать предложенный метод как на способность осуществлять раннее предсказание отложенной генерализации, так и на чувствительность к изменению скрытой алгебраической сложности задачи.

2 Постановка задачи

В данной работе процесс обучения нейросетевой модели $\mathcal{M}$ рассматривается как неавтономная стохастическая динамическая система. Пусть $\mathbf{w}_t \in \mathbb{W} \subset \mathbb{R}^D$ — вектор параметров (весов) модели на шаге оптимизации $t \in \{1, \dots, T\}$. Эволюция системы описывается рекуррентным правилом:

$$\mathbf{w}_{t+1} = F(\mathbf{w}_t, \xi_t), \quad (1)$$

где F — оператор оптимизатора (например, SGD с импульсом или AdamW), а ξ_t — внешнее воздействие (стохастический форсинг), обусловленное случайным выбором мини-батча и применением расписаний гиперпараметров.

На практике полное высокоразмерное состояние системы $\mathbf{w}_t$ ($D \gg 1$) недоступно для вычислительно эффективного анализа. Вместо этого мы наблюдаем набор одномерных скалярных временных рядов $\mathbf{m}_t = [m_1(t), \dots, m_K(t)]^\top$, таких как функция потерь, норма весов или норма градиентов. Каждая макроскопическая метрика выступает в роли функции наблюдения $m_i(t) = \phi_i(\mathbf{w}_t, \xi_t) \in \mathbb{R}$. В связи с этим, **глобальная задача исследования** заключается в том, чтобы, опираясь исключительно на одномерные ряды наблюдений $m_i(t)$, реконструировать топологические свойства скрытого аттрактора $\mathbf{w}_t$ и разработать ранний предиктор фазовых переходов оптимизатора.

В качестве основного целевого фазового перехода в нашей работе выступает феномен отложенной генерализации. Введем его формальное описание.

Definition 1 (Гроккинг). Пусть $\text{Acc}_{\text{train}}(\mathbf{w}_t)$ и $\text{Acc}_{\text{val}}(\mathbf{w}_t)$ — метрики точности модели на обучающей и валидационной выборках соответственно. Из-за наличия стохастического шума оптимизатора мгновенные значения метрик подвержены случайным отклонениям (например, ложным выбросам точности в начале обучения). Обозначим через $\overline{\text{Acc}}(t)$ сглаженное значение метрики (скользящее среднее по локальному временному окну). Для заданного малого порога ошибки $\epsilon > 0$, который в данной работе мы полагаем равным 0.05, определим два критических момента времени оптимизации:

- **Момент меморизации** (t_{mem}): минимальный шаг t , начиная с которого сеть устойчиво интерполирует обучающую выборку:

$$t_{\text{mem}} = \min \{t \mid \forall \tau \geq t, \overline{\text{Acc}}_{\text{train}}(\mathbf{w}_\tau) \geq 1 - \epsilon\}.$$

Как правило, в этот момент валидационная точность всё ещё остается на уровне случайного угадывания ($\overline{\text{Acc}}_{\text{val}}(\mathbf{w}_{t_{\text{mem}}}) \approx 0$).

- **Момент генерализации** (t_{gen}): минимальный шаг t , начиная с которого фиксируется устойчивый рост обобщающей способности:

$$t_{\text{gen}} = \min \{t \mid \forall \tau \geq t, \overline{\text{Acc}}_{\text{val}}(\mathbf{w}_\tau) \geq 1 - \epsilon\}.$$

Процесс оптимизации классифицируется как *гроккинг* при условии аномальной задержки между этими событиями: $t_{\text{gen}} \gg t_{\text{mem}}$.

Как следует из Определения 1, на интервале $t \in (t_{\text{mem}}, t_{\text{gen}})$ классические макроскопические метрики точности находятся на квазистационарном плато. В этот период оптимизатор внешне выглядит застрявшим в режиме переобучения, однако внутри него происходят скрытые структурные перестройки. Наша гипотеза состоит в том, что переход от меморизации к генерализации представляет собой топологическое схлопывание степеней свободы оптимизатора.

Для детекции этого схлопывания мы вводим метрику $\hat{d}(t)$ — оценку эффективной (внутренней) размерности реконструированного аттрактора в момент времени t . Исходя из этого, сформулируем формальный критерий успешного прогнозирования.

Definition 2 (Критерий предсказания гроккинга). Успешным ранним предсказанием (*early warning signal*) гроккинга считается формирование устойчивого нисходящего тренда эффективной размерности аттрактора $\hat{d}(t)$, завершающегося её стабилизацией на новом низкоразмерном уровне строго до фактического роста валидационной точности:

$$\exists t_{\text{drop}} \in (t_{\text{mem}}, t_{\text{gen}}) \text{ такое, что } \forall t \in [t_{\text{drop}}, t_{\text{gen}}]: \hat{d}(t) \ll \hat{d}(t_{\text{mem}}). \quad (2)$$

При этом на интервале $(t_{\text{mem}}, t_{\text{drop}})$ должно наблюдаться, в среднем, монотонное падение $\hat{d}(t)$ без значимых возвратных выбросов вверх.

Выполнение условий Определения 2 на практике будет означать, что топологический коллапс размерности действительно предшествует генерализации, а скалярные функции наблюдения $m_i(t)$ содержат достаточно информации для его заблаговременной регистрации.

3 Теоретическое обоснование и предлагаемый метод

Для решения поставленной задачи предложен метод, опирающийся на теорию нелинейных динамических систем. В данном разделе обосновывается возможность извлечения геометрии многомерной системы из 1D-лога и приводится алгоритм оценки эффективной размерности $\hat{d}(t)$.

3.1 Обучение как вынужденная динамическая система (Теоремы о вложении)

В теории нелинейной динамики под **аттрактором** $\mathcal{A} \subset \mathbb{W}$ понимается компактное инвариантное подмножество фазового пространства, к которому асимптотически притягиваются траектории

системы. В контексте машинного обучения процесс градиентной оптимизации стремится минимизировать функцию потерь. В связи с этим мы опираемся на допущение, что с течением времени траектория весов w_t теряет избыточные степени свободы и сходится к некоторому локальному аттрактору (например, стационарному стохастическому облаку вокруг плоского минимума). Пусть истинная размерность этого аттрактора равна m , где $m \ll D$.

Согласно классической теореме Такенса [7], для автономных систем топологию всего многомерного аттрактора $\mathcal{A}$ можно реконструировать по одному скалярному ряду наблюдений $X(t) \in \{m_i(t)\}$, используя векторы запаздывания (delay embeddings):

$$\mathbf{x}_t = [X(t), X(t - \tau), \dots, X(t - (E - 1)\tau)]^\top \in \mathbb{R}^E, \quad (3)$$

при условии, что размерность пространства вложения $E \geq 2m + 1$.

Для формализации алгоритмов введем оператор построения вложения DelayEmbedding, который сопоставляет исходному одномерному временному ряду $\{X(t)\}_{t=1}^N$ множество векторов в реконструированном фазовом пространстве:

$$\text{DelayEmbedding}(\{X(t)\}_{t=1}^N, E, \tau) = \{\mathbf{x}_t\}_{t=(E-1)\tau+1}^N, \quad (4)$$

где каждый вектор $\mathbf{x}_t \in \mathbb{R}^E$ сконструирован согласно формуле (3). Результатом работы данного оператора является восстановленное фазовое многообразие $M \subset \mathbb{R}^E$, состоящее из $|M| = N - (E - 1)\tau$ точек.

Фундаментальным математическим требованием теорем о вложении является «типичность» (genericity) функции наблюдения $\phi(\cdot)$. С точки зрения дифференциальной топологии это означает, что функция метрики не должна обладать вырожденными симметриями, которые склеивают различные точки фазового пространства при проекции. Например, агрегированная норма весов $\|w_t\|_2$ обладает сферической симметрией, измеряя лишь радиальное расстояние от начала координат. В определенных режимах она может выступать в роли «вырожденного наблюдателя» (degenerate observer), теряющего информацию об алгебраической структуре (угловых координатах) весов. В то же время, нелинейные метрики, например напрямую зависящие от распределения логитов (такие как функция потерь $\mathcal{L}$), выступают в роли типичных наблюдателей, сохраняющих многомерную топологию системы.

Однако градиентный спуск в глубоком обучении не является автономной системой. Влияние случайного выбора мини-батчей, а также использование расписаний гиперпараметров (learning rate schedulers) формально нарушают классические условия Такенса. Для математического обоснования нашего подхода мы опираемся на теоремы Старка о вложениях для вынужденных систем со смешанным воздействием [8, 9].

В современной теории оптимизации процесс обучения $w_{t+1} = F(w_t, \omega_t, \xi_t)$ рассматривается под воздействием двух типов форсинга. Детерминированный форсинг ω_t (расписание шага обучения) подчиняется теореме Старка для детерминированных систем [8], гарантирующей сохранение топологии при гладком внешнем драйвере. В свою очередь, стохастический форсинг ξ_t (градиентный шум мини-батчей) аппроксимируется многомерным Гауссовским процессом, а выбор батча из конечного набора описывается в терминах систем итерируемых функций (Iterated Function Systems) [9]. Для обоих случаев Старк с соавторами доказал, что отображение задержки сохраняет свойства диффеоморфизма. Это фундаментально обосновывает правомерность измерения размерности скрытого аттрактора в пространстве параметров $\mathbb{W}$, оперируя исключительно скалярными логитами в реконструированном фазовом пространстве $\mathbb{R}^E$, независимо от наличия детерминированных расписаний или стохастического шума.

3.2 Оценка эффективной размерности фазового пространства

Для детекции фазового перехода нам необходимо оценивать размерность аттрактора системы. В нашем методе мы рассмотрели как классические, так и современные методы, ранжировав их по устойчивости к специфике нейросетевой оптимизации (шуму мини-батчей):

1. Метод ложных ближайших соседей (FNN) [11] и Метод Цао [12]. Суть классического метода FNN заключается в последовательном «развертывании» аттрактора. При недостаточной размерности вложения удаленные участки многомерной траектории проецируются близко друг к другу, образуя так называемых «ложных» соседей. Метод измеряет расстояние между точкой

и её ближайшим пространственным соседом в размерности d , а затем проверяет, насколько сильно они отдалятся друг от друга при переходе к размерности $d + 1$. Если точки разлетаются (расстояние превышает эвристический порог R_{tol}), сосед признается ложным. Метод Цао является строгим математическим развитием этого подхода: он анализирует усредненное отношение расстояний при росте размерности, что позволяет отказаться от ручного подбора порогов.

Однако фундаментальным ограничением обоих геометрических методов является жесткое требование *глобальной возвратности (рекуррентности)* траектории. Чтобы алгоритм мог выявить сложную форму аттрактора, динамическая система должна регулярно возвращаться в окрестности своих прошлых состояний (пересекать саму себя в проекции). При обучении нейросети мы часто имеем дело с транзитными (переходными) процессами — например, когда функция потерь монотонно падает. В отсутствие возвратности ближайшим пространственным соседом точки x_t становится её же временной сосед с предыдущего шага x_{t-1} . Поскольку такие точки не «разлетаются» ни в какой размерности, геометрические методы вырождаются, ошибочно воспринимая многомерную траекторию спуска как простую 1D-линию, и выдают тривиальную оценку $\hat{d} = 1$.

2. Метод максимизации симплексной проекции [13]: Оптимальное E ищется как аргумент, максимизирующий авторегрессионную корреляцию ρ при предсказании будущего состояния y_{t+1} по его соседям в $\mathbb{R}^E$. Метод топологически гарантирует наилучшее развертывание аттрактора, однако его разрешение является целочисленным (дискретным), что затрудняет детекцию плавных фазовых переходов.

3. Метод максимального правдоподобия (MLE Intrinsic Dimension) [10]: Выбран в качестве основного аналитического инструмента в нашем методе. В отличие от геометрических методов, подход Левиной-Бикеля проецирует временной ряд сразу в избыточное высокоразмерное пространство (например, $E = 15$) и оценивает локальную внутреннюю размерность $\hat{d}_x$ статистически, по Пуассоновскому распределению расстояний до k ближайших соседей. Процесс формализован в Алгоритме 1.

Algorithm 1 Оценка динамической размерности MLE (Levina-Bickel)

Input: Временной ряд наблюдений $\mathcal{D}_{obs}$, задержка τ , избыточная размерность E_{max} , окно W , соседи k

Output: Эффективная размерность $\hat{d}(t)$

- 1: $M \leftarrow \text{DelayEmbedding}(\mathcal{D}_{obs}, E_{max}, \tau)$ ▷ Вложение в $\mathbb{R}^{E_{max}}$
- 2: **for** каждой точки $x_t \in M$ внутри скользящего окна W **do**
- 3: Найти k ближайших соседей с расстояниями $r_1 \leq r_2 \leq \dots \leq r_k$
- 4: $\hat{d}_{x_t} \leftarrow \left[\frac{1}{k-1} \sum_{j=1}^{k-1} \log \left(\frac{r_k}{r_j} \right) \right]^{-1}$ ▷ Локальная оценка по радиусу r_k
- 5: **end for**
- 6: $\hat{d}(t) \leftarrow \frac{1}{|W|} \sum_{x_t \in W} \hat{d}_{x_t}$ ▷ Усреднение размерности на окне W
- 7: **return** $\hat{d}(t)$

Данный метод возвращает *непрерывную* величину, которая вычисляется локально, не требует глобальной возвратности траектории и демонстрирует устойчивость к шуму мини-батчей.

3.3 Физика Гроккинга как топологического коллапса

Применяя описанный математический аппарат, мы формализуем гроккинг как структурный фазовый переход в ландшафте потерь.

- **Фаза меморизации:** Сеть "заучивает" данные как несвязанный шум. Траектория оптимизатора w_t блуждает по высокоразмерному многообразию. В этот период эффективная размерность $\hat{d}(t)$, вычисляемая алгоритмом MLE, будет максимальной.
- **Фаза генерализации (Гроккинг):** Под воздействием L_2 -регуляризации (weight decay) сеть отбрасывает шумовые признаки и «кристаллизует» оптимальный алгебраический алгоритм в структуре своих весов.

Нахождение обобщающего решения строго ограничивает степени свободы системы. Геометрически это означает, что аттрактор динамической системы стягивается в низкоразмерное подмногообразие. Следовательно, отслеживание эффективной размерности $\hat{d}(t)$ на скользящем окне должно действовать как опережающий индикатор топологического упрощения системы.

4 Вычислительный эксперимент

Для проверки гипотезы о гроккинге как о структурном переходе, сопровождающемся понижением размерности аттрактора, и валидации статистического метода как раннего предиктора гроккинга была проведена серия вычислительных экспериментов.

Во всех экспериментах использовалась архитектура однослойного Трансформера Omnigrok, которая была специально разработана для демонстрации более плавного и отчетливого эффекта гроккинга. Обучение проводилось с помощью оптимизатора AdamW со стохастикой (mini-batch), поскольку это является стандартом в глубоком обучении, а стохастический шум увеличивает дисперсию рядов скалярных метрик, позволяя алгоритмам фазовой реконструкции более точно оценивать истинную размерность фазового пространства. Отметим, что базовые эксперименты с полнопакетным градиентным спуском (Full-Batch GD) выявили проблему «вырожденного наблюдателя» из-за падения лосса в ноль и отсутствия дисперсии; эти результаты и их анализ вынесены в Приложение 7.1.

Помимо базовых метрик ($\mathcal{L}$, точность), алгоритм отслеживает норму градиента $\|g\|_2$, норму весов $\|w\|_2$, а также скалярное произведение между градиентами на соседних итерациях. Задержка τ подбирается эмпирически, а размерность вложения E вычисляется динамически с помощью метода MLE.

4.1 Эксперимент 1: Модульное сложение и нетипичный наблюдатель

В первом эксперименте использовался датасет модульного сложения по модулю $p = 113$. В качестве целевой метрики для метода MLE была выбрана норма весов ($\|w\|_2$), так как она сохраняет дисперсию на протяжении всей фазы меморизации и, что не менее важно, никак не зависит от валидационной выборки.

На Рис. 1 представлены результаты эксперимента. В верхней строке (с включенной L_2 -регуляризацией, $WD = 1.0$) наблюдается топологический коллапс: эффективная размерность (а точнее её оценка $\hat{d}^*(t)$, полученная MLE методом) заканчивает падение быстрее нормы весов задолго до того, как метрика Ассигасу фиксирует генерализацию. В нижней строке (без регуляризации, $WD = 0.0$) гроккинг не наступает, сеть уходит в вечную меморизацию, и метод MLE корректно показывает не спадающую размерность фазового пространства. Это доказывает отсутствие ложноположительных срабатываний.

Как итог, наш метод успешно предсказывает гроккинг, фиксируя топологический коллапс размерности аттрактора. Однако, как мы видим, норма весов не является типичным наблюдателем: она имеет симметрии, из-за чего не передает истинную размерность аттрактора, но зато довольно чётко передает падение размерности и не зависит от валидационной выборки. Также наш предиктор на данной задаче не превосходит по точности предсказания предиктор, основанный напрямую на норме весов и $\mathcal{L}_{val}$, что связано с простотой самой задачи.




Рис. 1: Анализ гроккинга на модульном сложении при наличии стохастического шума. Сравнение динамики размерности E , построенной по ряду `weight_norm`, относительно Accuracy, Loss и `weight_norm` в режимах с генерализацией (верхний ряд) и без нее (нижний ряд).

4.2 Эксперимент 2: Неабелевы группы и сложные алгебраические представления (S_5)

Для верификации универсальности метода задача была усложнена до композиции перестановок неабелевой (некоммутативной) группы S_5 . С точки зрения механистической интерпретируемости [3], нейронные сети обобщают задачи на конечных группах путем выучивания их линейных неприводимых представлений (отображения элементов группы в матрицы весов).

В то время как коммутативное модульное сложение проецируется сетью в 2D-окружности (вещественный Фурье-базис, размерность представления равна 2 [2]), структура неабелевой группы S_5 значительно сложнее. Согласно алгебраической теории представлений, размерности неприводимых представлений группы S_5 составляют 1, 1, 4, 4, 5, 5 и 6. Поскольку одномерные представления теряют информацию о самих перестановках (являются неточными, *unfaithful*), для безошибочного вычисления композиции любых элементов сети математически необходимо задействовать подпространства весов размерности как минимум 4.

В контексте нелинейной динамики это означает, что минимальное количество степеней свободы, которое оптимизатор обязан сохранить для удержания обобщающего правила S_5 , равно 4. Следовательно, истинная размерность аттрактора лосса после гроккинга должна коллапсировать, но остановиться на уровне не ниже 4 компонент, что позволяет проверить способность нашего метода «вслепую» измерять алгебраическую сложность задачи.

Как видно на Рис. 2, предложенный метод успешно справился с этой задачей при анализе нормы весов. В фазе хаотичного поиска размерность E держится на более высоком уровне. При формировании сетью обобщающего алгебраического правила, размерность предсказуемо коллапсирует. Эксперимент без `Weight Decay` (нижний ряд) вновь подтверждает, что размерность не падает в случае, когда нет гроккинга.




Рис. 2: Анализ композиции в группе S_5 . Коллапс размерности аттрактора, построенного по ряду `weight_norm`, надежно фиксирует структурную перестройку сети даже при более сложной структуре скрытых представлений.

Особый интерес представляет оценка размерности по валидационной функции потерь (Рис. 3). Это доказывает, что данный эффект не зависит от выбранной метрики и не является субъективным. Взяв типичную метрику (`validation loss`), мы можем смотреть не только на коллапс её размерности, но и на её абсолютные значения, что полезно для понимания количества активных компонентов в модели. В случае S_5 мы видим, что размерность коллапсирует примерно до 4, что напрямую связано с тем, что для представления S_5 требуется как минимум 4 компонента. При этом в случае $WD = 0$ размерность не падает, а даже растет, что показывает переобучение модели и уход в вечную меморизацию.




Рис. 3: Анализ композиции в группе S_5 . Размерность E , восстановленная по `validation loss`, позволяет оценивать количество активных компонентов.

4.3 Теоретическая интерпретация результатов

Анализ полученных графиков позволяет сделать следующие теоретические выводы:

1. **Природа гроккинга:** Зафиксированный коллапс размерности доказывает, что гроккинг — это не просто уменьшение ошибки, а качественная перестройка динамической системы: переход с высокоэнтропийного аттрактора "запоминания" на низкоразмерный аттрактор "алгебраического правила".
2. **Метрики оптимизатора:** Эксперименты показали, что мы можем диагностировать гроккинг, не используя валидационную выборку (через норму весов). Это доказывает,

что данное явление не является субъективным артефактом конкретной отложенной выборки.

3. **Размерность при $WD = 0$:** При типичном наблюдателе ($\mathcal{L}_{val}$) размерность при $WD = 0$ не падает, а даже растет. Это подтверждает, что при переобучении модель заучивает выборку, используя большое количество активных компонент, и показывает важность выбора типичного наблюдателя для оценки алгебраической сложности алгоритма. В случае нетипичного наблюдателя (weight norm) размерность на протяжении всего обучения остается низкой, так как модель просто находит тривиальное решение и в силу устройства кросс-энтропии просто начинает наращивать масштаб весов, из-за чего эффективная размерность не растет.

5 Обсуждение результатов (Discussion)

Результаты проведенных вычислительных экспериментов подтверждают фундаментальную гипотезу работы: процесс оптимизации глубоких нейронных сетей может быть исследован с точки зрения теории нелинейных динамических систем и отслеживая размерность аттрактора можно предсказывать и качественно описывать гроккинг. Однако перенос методов фазовой реконструкции в ML выявил ряд специфических ограничений и физических эффектов, требующих отдельного осмысления.

1. Проблема вырожденного наблюдателя и роль стохастичности. В ходе экспериментов с полнопакетным градиентным спуском (Full-Batch GD) мы столкнулись с сложностью оценки размерности аттрактора: все используемые нами 1-D скалярные метрики вырождались в константу. С точки зрения нелинейной динамики, идеальная оптимизация без шума схлопывает траекторию в прямолинейный луч, лишая методы (такие как MLE) необходимой дисперсии для оценки кривизны ландшафта. Таким образом при анализе размерности стоит следить за тем, чтобы ряд не выражался. Это можно делать за счёт прореживания ряда, но это может негативно сказаться на точности оценки. Таким образом этот метод работает лучше всего в системах где ряды не выражаются, то есть в системах со стохастикой. Высокочастотный шум SGD заставляет оптимизатор исследовать локальную геометрию аттрактора. Кроме того, эксперименты показали, что норма весов ($\|w\|_2$) является гораздо более информативным и стабильным «наблюдателем» скрытой динамики, чем склонный к вырождению обучающий лосс.

3. Зависимость топологии от выбора наблюдателя (Observability). Одним из важнейших эмпирических результатов нашей работы стало выявление зависимости реконструированной размерности E от выбора скалярной метрики (функции наблюдения). В теории динамических систем теорема Такенса требует, чтобы функция наблюдения была «типичной» (generic) и не имела вырожденных симметрий.

Наши эксперименты показали, что норма весов ($\|w\|_2$) является симметричным наблюдателем. Динамика нормы определяется преимущественно балансом двух глобальных сил: градиентом ошибки (увеличивающим веса) и L_2 -регуляризацией (сжимающей веса). Из-за этого эффективная размерность ряда $\|w\|_2$ всегда коллапсирует до низких значений ($E \approx 2 \dots 4$), независимо от сложности решаемой задачи, так как эта метрика «слепа» к сложной угловой структуре представлений.

В противовес этому, функция потерь ($\mathcal{L}_{val}$ или зашумленный $\mathcal{L}_{train}$) напрямую зависит от логитов и чувствительна к внутренней алгебраической структуре сети. Работы по прямому спектральному анализу весов [2] показывают, что для модульного сложения сеть формирует 2D-окружности (Фурье-базисы). Оценка MLE по ряду лосса подтверждает это топологически: коллапс траектории останавливается на $E \approx 2$. В свою очередь, для неабелевой группы S_5 , неприводимые представления которой требуют пространств большей размерности [3], коллапс размерности, измеряемый именно по ряду лосса, предсказуемо останавливается на более высоком уровне $E \approx 4 \dots 6$. Таким образом, мы доказали, что для «слепой» оценки алгебраической сложности выученного алгоритма необходимо использовать метрики, напрямую связанные с распределением выходов сети, или более аккуратно агрегировать статистики параметров. Также стоит отметить, что лучше использовать именно $\mathcal{L}_{val}$, так как $\mathcal{L}_{train}$ быстрее выражается.

4. Независимость от валидационной выборки и количество активных компонент. С практической точки зрения, мониторинг валидационной функции потерь ($\mathcal{L}_{val}$) остается более

быстрым и дешевым предиктором наступления гроккинга, по крайней мере в простых проведенных экспериментах. Однако метрики являются лишь симптомами улучшения обобщающей способности. В свою очередь, обвал эффективной размерности E предоставляет строгое математическое доказательство структурного фазового перехода — процесса, при котором сеть отсекает шумовые степени свободы и сжимает траекторию в компактное подмногообразие. Также для нашего метода в принципе не нужна валидационная выборка.

6 Заключение

В данной работе предложен и верифицирован новый статистический метод ранней диагностики гроккинга, основанный на топологической реконструкции фазового пространства нейронной сети. Рассматривая стохастический градиентный спуск как вынужденную динамическую систему, мы эмпирически доказали, что феномен отложенной генерализации представляет собой структурный фазовый переход к низкоразмерному состоянию. Отслеживание этого процесса с помощью оценки Левиной-Бикеля (MLE Intrinsic Dimension) позволяет зафиксировать коллапс эффективной размерности аттрактора задолго до скачка валидационной точности, выступая надежным опережающим предиктором генерализации.

Предложенный подход отличается высокой универсальностью и практической применимостью. Показано, что топологический коллапс уверенно детектируется по внутренним скалярным логам оптимизатора (например, норме весов), что позволяет мониторить обобщающую способность без выделения валидационной выборки. Кроме того, эксперименты на задачах модульного сложения и композиции в неабелевой группе S_5 подтвердили, что остаточная размерность аттрактора строго согласуется с теоретической алгебраической сложностью выученного алгоритма при использовании типичного наблюдателя ($E \approx 2$ и $E \approx 4 \dots 6$ соответственно). Поскольку метод работает по принципу «черного ящика» и оперирует исключительно 1D-логами, он легко переносится на любые архитектуры и задачи без адаптации.

Главный итог исследования заключается в том, что одномерные скалярные ряды содержат исчерпывающую информацию для диагностики скрытых фазовых переходов в процессе обучения. Это открывает путь к созданию вычислительно дешевых методов мониторинга и структурной оптимизации глубоких моделей без необходимости ресурсоемкого анализа скрытых представлений или матриц Гессiana.

Список литературы

- [1] Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. Grokking: Generalization beyond overfitting on small algorithmic datasets. *arXiv preprint arXiv:2201.02177*, 2022.
- [2] Neel Nanda, Lawrence Chan, Tom Lieberum, Jess Smith, and Jacob Steinhardt. Progress measures for grokking via mechanistic interpretability. In *International Conference on Learning Representations (ICLR)*, 2023.
- [3] Bilal Chughtai, Lawrence Chan, and Neel Nanda. A toy model of universality: Reverse engineering how networks learn group operations. In *International Conference on Machine Learning (ICML)*, 2023. URL <https://arxiv.org/abs/2302.03025>.
- [4] Ziming Liu, Ouail Kitovich, and Max Tegmark. Omnigrok: Grokking beyond algorithmic data. In *International Conference on Learning Representations (ICLR)*, 2023. URL <https://openreview.net/forum?id=zDiHoIWa0nq>.
- [5] Vimal Thilak, Eyal Littwin, Shuangfei Zhai, Omid Saremi, Roni Puhon, and Joshua M Susskind. The slingshot mechanism: An empirical study of adaptive optimizers and the loss landscape. *arXiv preprint arXiv:2206.04817*, 2022. URL <https://arxiv.org/abs/2206.04817>.
- [6] Paul J T Notsawo, Hattie Zhou, Mohammad Pezeshki, Irina Rish, and Guillaume Dumas. Predicting grokking long before it happens: A look into the loss landscape of models which grok. *arXiv preprint arXiv:2306.13253*, 2023.
- [7] Floris Takens. Detecting strange attractors in turbulence. In *Dynamical systems and turbulence, Warwick 1980*, pages 366–381. Springer, 1981. doi: 10.1007/BFb0091924.

- [8] Jaroslav Stark. Delay embeddings for forced systems. i. deterministic forcing. *Journal of Nonlinear Science*, 9(3):255–332, 1999. doi: 10.1007/s003329900072.
- [9] Jaroslav Stark, David S Broomhead, ME Davies, and J Huke. Delay embeddings for forced systems. ii. stochastic forcing. *Journal of Nonlinear Science*, 13(6):519–577, 2003. doi: 10.1007/s00332-003-0534-4.
- [10] Elizaveta Levina and Peter J. Bickel. Maximum likelihood estimation of intrinsic dimension. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 17, 2004. URL <https://proceedings.neurips.cc/paper/2004/file/74934548253bcab8490ebd74afecebb5-Paper.pdf>.
- [11] Matthew B Kennel, Reggie Brown, and Henry DI Abarbanel. Determining embedding dimension for phase-space reconstruction using a geometrical construction. *Physical review A*, 45(6):3403, 1992. doi: 10.1103/PhysRevA.45.3403.
- [12] Liang Cao. Practical method for determining the minimum embedding dimension of a scalar time series. *Physica D: Nonlinear Phenomena*, 110(1-2):43–50, 1997. doi: 10.1016/S0167-2789(97)00118-8.
- [13] George Sugihara and Robert M May. Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series. *Nature*, 344(6268):734–741, 1990. doi: 10.1038/344734a0.

7 Appendix / supplemental material


7.1 Базовый эксперимент с полнопакетным градиентным спуском (Full-Batch)

В данном приложении приведены результаты первоначальных экспериментов, которые проводились на задаче модульного сложения с использованием полнопакетного градиентного спуска (Full-Batch GD). Этот эксперимент выступал в качестве базового (baseline) для подтверждения изначальной гипотезы.


Как видно на Рис. 4, в этом сеттинге нам удалось зафиксировать падение эффективной размерности (MLE ID) ряда $\mathcal{L}_{train}$ непосредственно перед скачком валидационной точности (с $E \approx 4 - 5$ до $E \approx 2.8$).

Однако этот эксперимент выявил важную методологическую проблему. При полнопакетной оптимизации корреляция между размером фазового пространства E и эффектом гроккинга становилась менее очевидной. С теоретической точки зрения это объясняется проблемой «вырожденного наблюдателя»: в отсутствие стохастического шума мини-батчей траектория оптимизатора вырождается в детерминированную гладкую кривую, а обучающий лосс падает практически до нуля, лишая метод MLE необходимой дисперсии для оценки истинной размерности пространства $d^*(t)$.

Именно это наблюдение послужило мотивацией для перехода к стохастической оптимизации (mini-batch) и использованию нетипичного наблюдателя (нормы весов), результаты которых представлены в основном разделе 4.



(a) Динамика Train/Val Accuracy



(b) Коллапс размерности (MLE ID)

Рис. 4: Феномен гроккинга на базовом эксперименте (Full-Batch). Переход от запоминания к обобщению сопровождается снижением топологической сложности траектории $\mathcal{L}_{train}$, однако оценка страдает от недостатка дисперсии из-за вырождения ряда.