Detecting Optimization Regimes via Convergent Cross Mapping

Nickolay Karlov
MIPT
Moscow, Russia
karlov.na@phystech.edu

Alexsey Kravatsky
MIPT
Moscow, Russia

Abstract

Обучение глубоких моделей сопровождается генерацией множества взаимосвязанных временных рядов (loss, accuracy, weight parameters, learning rate). В данной работе предлагается новый метод анализа этих логов. Для выявления причинно-следственных связей в динамике обучения применяются Convergent Cross Mapping (CCM) и его модификации с опорой на теоремы Старка о delay embeddings для систем с детерминированным и стохастическим воздействиями. Исследуется нелинейные взаимосвязи данных рядов, а также предложен фреймворк, способный: анализировать воздействие изменения параметров на loss, детектировать Edge of Stability и осуществлять раннее предсказание эффекта grokking через отслеживание коллапса эффективной размерности вложения.

Keywords: TODO

1 Введение

В настоящее время обучение глубоких нейронных сетей (DNN) представляет собой сложный высокоразмерный и невыпуклый процесс оптимизации. На практике для мониторинга этого процесса используются скалярные метрики: функция потерь (loss), точность (accuracy), нормы градиентов, скорость обучения (learning rate) и другие. Одной из фундаментальных проблем является то, что скрытые, изменяющиеся во времени взаимодействия между этими метриками и внутренним состоянием оптимизатора остаются непрозрачными. Стандартные статистические методы не способны уловить истинные причинно-следственные механизмы, определяющие сходимость модели. В данной работе рассматривается подход к анализу траектории оптимизации как к стохастической динамической системе. Задача заключается в том, чтобы с помощью методов реконструкции фазового пространства извлечь информацию о режимах обучения исключительно из малозатратных скалярных логов, избегая вычислительно тяжелого анализа полных матриц весов.

В литературе представлено несколько подходов к анализу сложной динамики оптимизации нейросетей. Ряд работ фокусируется на изучении границы стабильности (Edge of Stability, EoS), анализируя максимальные собственные значения гессиана [1]. Другие методы направлены на раннее предсказание гроккинга (grokking) [2], с использованием спектральных сигнатур функции потерь [3]. Параллельно в области анализа временных рядов активно развивается метод Convergent Cross Mapping (CCM) [4]. Современный подход заключается в интеграции CCM в гибридные архитектуры машинного обучения, где метод применяется для извлечения каузальных графов из внешних данных (например, биомедицинских сигналов) с последующей их передачей в сверточные или

39th Conference on Neural Information Processing Systems (NeurIPS 2025).

графовые нейросети [5, 6], анализа латентных представлений [7], а также для анализа причинности в задачах прогнозирования [8].

Однако существующие методы обладают рядом ограничений. Подходы, основанные на спектральном анализе и оценке гессиана [1], требуют значительных вычислительных ресурсов и плохо масштабируются на каждую итерацию обучения. Классические линейные меры причинности, такие как тест Грейнджера, выдают ложноположительные результаты при анализе динамических систем, где переменные делят общий скрытый аттрактор. До сих пор методы фазовой реконструкции не применялись напрямую к внутренним скалярным логам нейросети для изучения невыпуклой динамики самого оптимизатора.

В данной работе предлагается новый статистический фреймворк, адаптирующий метод CCM для диагностики процессов глубокого обучения. Траектория оптимизации формализуется как система $\boldsymbol{w}_{t+1} = F(\boldsymbol{w}_t, \xi_t)$, где $\boldsymbol{w}_t$ — многообразие параметров, а ξ_t — внешние воздействия (стохастические батчи, расписания гиперпараметров). Для восстановления свойств этой высокоразмерной системы по скалярным логам $y_t \in \mathbb{R}$ используется теорема Такенса о вложении [9]. Чтобы учесть нестационарность и стохастичность градиентного спуска, теоретическая база расширяется за счет теорем Старка о delay embeddings для систем с детерминированным и стохастическим форсингом [10, 11]. Для устранения косвенных транзитивных влияний применяется метод Partial CCM [12]. В основе работы лежит гипотеза о том, что переходы между режимами обучения (например, от запоминания к генерализации) топологически эквивалентны коллапсу оптимальной размерности вложения, а каузальные драйверы сходимости могут быть выявлены через оценку навыка предсказания (prediction skill) кросс-маппинга.

Для проверки предложенного подхода и валидации гипотез разрабатываются контролируемые среды с известными причинно-следственными вмешательствами: синусоидальным изменением скорости обучения, внедрением «призрачных драйверов» (ghost drivers, форсирующих momentum) и «отравленных батчей» (poisoned batches) со случайными метками. Эксперименты проводятся на наборе данных CIFAR-10 для сверточных сетей (задачи оценки каузальной чувствительности к гиперпараметрам и детекции EoS через simplex projection [13, 14]) и на синтетических данных модульного сложения для однослойного Трансформера (задача предсказания гроккинга). Сравнение классического теста Грейнджера, стандартного CCM и предложенной адаптации на базе теорем Старка призвано подтвердить возможность эффективного и малозатратного предсказания критических режимов оптимизации, что открывает новые перспективы для создания универсальных диагностических инструментов в машинном обучении.

2 Постановка задачи

Рассмотрим нейросетевую модель $\mathcal{M}$, которая обучается в течение T итераций (шагов оптимизатора). В процессе оптимизации генерируются временные ряды различных скалярных метрик $m_i(t)$ (например, $m_1(t)$ — обучающий loss, $m_2(t)$ — валидационная accuracy, $m_3(t)$ — норма градиента, $m_4(t)$ — learning rate). Глобальная цель исследования заключается в том, чтобы понять, как величины, связанные с этими метриками, влияют друг на друга, на функцию потерь и на точность модели, и на основе этих связей диагностировать скрытые нелинейные режимы обучения (такие как Edge of Stability и Grokking).

Обучение нейронной сети представляет собой неавтономную стохастическую динамическую систему. Пусть $\boldsymbol{w}_t \in \mathbb{W} \subset \mathbb{R}^D$ — вектор параметров (весов) модели на шаге $t \in \{1, \ldots, T\}$. Правило обновления весов имеет вид:

$$\boldsymbol{w}_{t+1} = F(\boldsymbol{w}_t, \xi_t), \quad t \in \{1, \ldots, T\}, \tag{1}$$

где F — оператор шага оптимизатора (например, SGD с momentum), а ξ_t — внешнее воздействие (forcing), включающее стохастичность выбора мини-батча и детерминированное изменение гиперпараметров (например, затухание η_t).

Элементы постановки задачи:

- Выборка: Мы не наблюдаем полное высокоразмерное состояние $\boldsymbol{w}_t$. Наша выборка $\mathcal{D} = \{\boldsymbol{m}_t\}_{t=1}^{T}$ состоит из векторов скалярных наблюдений $\boldsymbol{m}_t = [m_1(t), \ldots, m_K(t)]^\top$, где каждая метрика является функцией наблюдения $m_i(t) = \phi_i(\boldsymbol{w}_t, \xi_t) \in \mathbb{R}$.
- Статистические гипотезы: Мы предполагаем, что динамика обучения $\boldsymbol{w}_t$ сходится к некоторому инвариантному многообразию (аттрактору) размерности $m \ll D$. Согласно теоремам Старка [10, 11] для систем с форсингом, временной ряд одной наблюдаемой метрики $X(t) \in \{m_i(t)\}$ содержит достаточную информацию для восстановления топологии всего аттрактора.
- Модель в классе моделей: Мы применяем метод симплексной проекции (Simplex projection [13]). Для переменной $X(t)$ строится вектор задержки (delay embedding) в реконструированном фазовом пространстве:

$$\boldsymbol{x}_t = [X(t), X(t-\tau), \ldots, X(t-(d-1)\tau)]^\top \in \mathbb{R}^d, \tag{2}$$

  где d — размерность вложения, τ — временная задержка. Модель отображения предсказывает значение другой переменной $\hat{Y}(t)$ (на основе кросс-маппинга из X) как экспоненциально взвешенную сумму $d+1$ ближайших соседей вектора $\boldsymbol{x}_t$ на реконструированном многообразии.
- Ограничения класса моделей: Согласно теореме о вложении, размерность должна удовлетворять условию $d \geq 2m + 1$..
- Функция ошибки и критерий качества: Навык предсказания (prediction skill) оценивается коэффициентом корреляции Пирсона ρ между предсказанными значениями $\hat{Y}(t)|M_X$ и истинными наблюдениями $Y(t)$:

$$\rho = \frac{\mathrm{Cov}(Y, \hat{Y})}{\sqrt{\mathrm{Var}(Y)\mathrm{Var}(\hat{Y})}}. \tag{3}$$

  Причинно-следственная связь $X \to Y$ подтверждается, если $\rho(L)$ монотонно сходится к константе > 0 при увеличении размера библиотеки исторических наблюдений $L \leq T$.
- Процедура кросс-валидации: При поиске ближайших соседей в фазовом пространстве используется стратегия Leave-One-Out (вектор $\boldsymbol{x}_t$ исключается из библиотеки при поиске собственных соседей).
- Внешний критерий: Способность предложенной метрики $d^*(t)$ заранее сигнализировать о резком падении валидационной ошибки $m_{valid}(t)$ (эффект гроккинга) до того, как это падение станет статистически значимым.
- Постановка задачи оптимизации: Первичная задача оптимизации в рамках анализа временных рядов — поиск оптимальных гиперпараметров вложения (d^*, τ^*) для конкретной метрики, максимизирующих навык авторегрессионного предсказания:

$$(d^*, \tau^*) = \underset{d \in \mathbb{N}, \tau \in \mathbb{N}}{\arg\max}\, \rho\Big(X(t), \hat{X}(t \mid d, \tau)\Big). \tag{4}$$

  Вторичная задача — выявление матрицы причинно-следственных связей $\mathbf{C} \in \mathbb{R}^{K \times K}$ между метриками m_i, где элемент $C_{i,j}$ пропорционален асимптотическому пределу кросс-маппинга $\lim_{L\to\infty} \rho(\hat{m}_i|M_{m_j})$.

1. Модель: Нелинейное отображение (Simplex projection), которое реконструирует значение одной скалярной метрики по локальной окрестности delay-векторов другой метрики в псевдофазовом пространстве.
2. Алгоритм: Алгоритм Convergent Cross Mapping (CCM) и Partial CCM, вычисляющий матрицу взаимных корреляций ρ при варьировании длины библиотеки L с использованием KD-деревьев для поиска соседей.
3. Решение: Восстановленная топологическая размерность $d^*(t)$ для заданного окна итераций, а также взвешенный ориентированный граф (карта) причинно-следственных связей, показывающий истинное влияние метрик m_i друг на друга (с отсечением ложных транзитивных связей).

Contributions. Our contributions can be summarized as follows:

- We present...
- We demonstrate the validity of our theoretical results through empirical studies...
- We highlight the implications of our findings for...

Outline. The rest of the paper is organized as follows...

3 Related Work

Topic #1. TODO

Topic #2. TODO

4 Preliminaries

4.1 General notation

In this section, we introduce the general notation used in the rest of the paper and the basic assumptions.

4.2 Assumptions

TODO

5 Method

6 Experiments

To verify the theoretical estimates obtained, we conducted a detailed empirical study...

7 Discussion

TODO

8 Conclusion

TODO

Список литературы

[1] Jeremy M Cohen, Simran Kaur, Yuanzhi Li, J Zico Kolter, and Ameet Talwalkar. Gradient descent on neural networks typically occurs at the edge of stability. In International Conference on Learning Representations (ICLR), 2021. URL `https://openreview.net/forum?id=jh-rTtvkGeM`.

[2] Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. Grokking: Generalization beyond overfitting on small algorithmic datasets. arXiv preprint arXiv:2201.02177, 2022.

[3] Paul J T Notsawo et al. Predicting grokking long before it happens: A look into the loss landscape of models which grok. arXiv preprint arXiv:2306.13253, 2023.

[4] George Sugihara, Robert May, Hao Ye, Chih-hao Hsieh, Ethan Deyle, Michael Fogarty, and Stephan Munch. Detecting causality in complex ecosystems. Science, 338(6106): 496–500, 2012. doi: 10.1126/science.1227079.

[5] Kathiravan Sekaran et al. A self-operational convolutional neural networks with convergent cross-mapping and its application in parkinson's disease classification. IEEE Access, 12:84332–84343, 2024. doi: 10.1109/ACCESS.2024.3412808.

[6] Chuan Lin et al. A novel causal graph attention network with convergent cross mapping for short-term photovoltaic power forecasting. Renewable Energy, 227:120000, 2024. doi: 10.1016/j.renene.2024.120000.

[7] Edward Brouwer, Adam Arany, Yves Moreau, and Roland Becker. Latent convergent cross mapping. In International Conference on Learning Representations (ICLR), 2021. URL `https://openreview.net/forum?id=tA_uWdI_Zz5`.

[8] K R Usmanova and V V Strijov. Models of detection relationship between time series in forecasting problems. Systems and Means of Informatics, 29(2):12–30, 2019.

[9] Floris Takens. Detecting strange attractors in turbulence. In Dynamical systems and turbulence, Warwick 1980, pages 366–381. Springer, 1981. doi: 10.1007/BFb0091924.

[10] Jaroslav Stark. Delay embeddings for forced systems. i. deterministic forcing. Journal of Nonlinear Science, 9(3):255–332, 1999. doi: 10.1007/s003329900072.

[11] Jaroslav Stark, David S Broomhead, ME Davies, and J Huke. Delay embeddings for forced systems. ii. stochastic forcing. Journal of Nonlinear Science, 13(6):519–577, 2003. doi: 10.1007/s00332-003-0534-4.

[12] Siyu Leng, Huanfei Ma, Jürgen Kurths, Ying-Cheng Lai, Wei Lin, Kazuyuki Aihara, and Luonan Chen. Partial cross mapping eliminates indirect causal influences. Nature Communications, 11(1):1–9, 2020. doi: 10.1038/s41467-020-16238-0.

[13] George Sugihara and Robert M May. Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series. Nature, 344(6268):734–741, 1990. doi: 10.1038/344734a0.

[14] George Sugihara. Nonlinear forecasting for the classification of natural time series. Philosophical Transactions of the Royal Society of London. Series A: Physical and Engineering Sciences, 348(1688):477–495, 1994. doi: 10.1098/rsta.1994.0106.

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO