
Методы динамического эмпирического моделирования для обучения нейронных сетей

Nickolay Karlov
MIPT
Moscow, Russia
karlov.na@phystech.edu

Alexsey Kravatsky
MIPT
Moscow, Russia

Abstract

Обучение глубоких моделей сопровождается генерацией множества взаимосвязанных временных рядов (loss, accuracy, weight parameters, learning rate). В данной работе предлагается новый метод анализа этих логов. Для выявления причинно-следственных связей в динамике обучения применяются Convergent Cross Mapping (CCM) и его модификации с опорой на теоремы Старка о delay embeddings для систем с детерминированным и стохастическим воздействиями. Исследуется нелинейные взаимосвязи данных рядов, а также предложен фреймворк, способный осуществлять раннее предсказание эффекта grokking через отслеживание коллапса эффективной размерности вложения.

Keywords: EDM, CCM, гроккинг, динамические системы, оптимизация нейросетей, фазовое пространство.

1 Введение

В настоящее время обучение глубоких нейронных сетей (DNN) представляет собой сложный высокоразмерный и невыпуклый процесс оптимизации [1]. На практике для мониторинга этого процесса и оценки обобщающей способности моделей [2, 3] традиционно используются базовые скалярные метрики: функция потерь (loss), точность (accuracy), нормы градиентов и скорость обучения (learning rate). Помимо них, современные исследования выделяют ряд дополнительных информативных сигналов, отслеживаемых в процессе обучения: нормы весовых матриц $\|w\|_2$, масштаб градиентного шума (Gradient Noise Scale, GNS) [4], а также метрики «остроты» минимумов (sharpness) [5]. Одной из фундаментальных проблем является то, что скрытые, изменяющиеся во времени взаимодействия между этими метриками и внутренним состоянием оптимизатора остаются непрозрачными. Стандартные статистические методы, такие как корреляционный анализ и тест Грейнджера, не способны уловить истинные причинно-следственные механизмы, определяющие сходимость модели. В данной работе рассматривается подход к анализу траектории оптимизации как к стохастической динамической системе. Задача заключается в том, чтобы с помощью методов реконструкции фазового пространства извлечь информацию о режимах обучения исключительно из малозатратных скалярных логов, избегая вычислительно тяжелого анализа полных матриц весов.

В литературе представлено несколько подходов к анализу сложной динамики оптимизации нейросетей. Ряд работ фокусируется на изучении границы стабильности (Edge of Stability, EoS), анализируя эволюцию максимального собственного значения гесссиана и немонотонную сходимость градиентного спуска [6–8]. Феномен внезапного обобщения (grokking), впервые описанный в [9], также породил ряд методов для его раннего предсказания: от отслеживания скрытых метрик прогресса (progress measures) [10] до использования спектральных сигнатур

функции потерь [11]. Параллельно в области нелинейного анализа временных рядов активно развивается метод Convergent Cross Mapping (CCM) и в целом фреймворк эмпирического динамического моделирования [12–14]. Современный подход заключается в интеграции CCM в гибридные архитектуры машинного обучения, где метод применяется для извлечения каузальных графов из внешних данных (например, биомедицинских сигналов) с последующей их передачей в сверточные или графовые нейросети [15, 16], анализа латентных представлений [17], а также для анализа причинности в задачах прогнозирования [18].

Однако существующие методы обладают рядом ограничений. Подходы, основанные на спектральном анализе и оценке гессиана [6], требуют значительных вычислительных ресурсов и плохо масштабируются на каждую итерацию обучения. Классические линейные меры причинности, такие как тест Грейнджера, выдают ложноположительные результаты при анализе динамических систем, где переменные делят общий скрытый аттрактор. До сих пор методы фазовой реконструкции не применялись напрямую к внутренним скалярным логам нейросети для изучения невыпуклой динамики самого оптимизатора.

В данной работе предлагается новый статистический фреймворк, адаптирующий метод CCM для диагностики процессов глубокого обучения. Траектория оптимизации формализуется как система $w_{t+1} = F(w_t, \xi_t)$, где w_t — многообразие параметров, а ξ_t — внешние воздействия (стохастические батчи, расписания гиперпараметров). Для восстановления свойств этой высокомерной системы по скалярным логам $y_t \in \mathbb{R}$ используется теорема Такенса о вложении [19]. Чтобы учесть нестационарность и стохастичность градиентного спуска, теоретическая база расширяется за счет теорем Старка о delay embeddings для систем с детерминированным и стохастическим форсингом [20, 21]. Для устранения косвенных транзитивных влияний применяется метод Partial CCM [14]. В основе работы лежит гипотеза о том, что переходы между режимами обучения (например, от запоминания к генерализации) топологически эквивалентны коллапсу оптимальной размерности вложения, а каузальные драйверы сходимости могут быть выявлены через оценку навыка предсказания (prediction skill) кросс-маппинга.

Для проверки предложенного подхода и валидации гипотез разрабатываются контролируемые среды с известными причинно-следственными вмешательствами: синусоидальным изменением скорости обучения, внедрением «призрачных драйверов» (ghost drivers, форсирующих momentum) и «отравленных батчей» (poisoned batches) со случайными метками. Эксперименты проводятся на наборе данных CIFAR-10 для сверточных сетей и на синтетических данных модульного сложения для однослойного Трансформера (задача предсказания гроккинга). Результаты данных экспериментов призваны подтвердить возможность эффективного и мало затратного предсказания критических режимов оптимизации, что открывает новые перспективы для создания универсальных диагностических инструментов в машинном обучении.

2 Постановка задачи

Рассмотрим нейросетевую модель $\mathcal{M}$, которая обучается в течение T итераций (шагов оптимизатора). В процессе оптимизации генерируются временные ряды различных скалярных метрик $m_i(t)$ (например, $m_1(t)$ — loss на обучающей выборке, $m_2(t)$ — ассигасу на валидационной выборке, $m_3(t)$ — норма градиента, $m_4(t)$ — норма весов, $m_5(t)$ — масштаб градиентного шума, $m_6(t)$ — learning rate). Глобальная цель исследования заключается в том, чтобы понять, как величины, связанные с этими метриками, влияют друг на друга, на функцию потерь и на точность модели, и на основе этих связей диагностировать скрытые режимы обучения (такие как Edge of Stability и Grokking).

Обучение нейронной сети представляет собой неавтономную стохастическую динамическую систему. Пусть $w_t \in \mathbb{W} \subset \mathbb{R}^D$ — вектор параметров (весов) модели на шаге $t \in \{1, \dots, T\}$. Правило обновления весов имеет вид:

$$w_{t+1} = F(w_t, \xi_t), \quad t \in \{1, \dots, T\}, \quad (1)$$

где F — оператор шага оптимизатора (например, SGD с momentum), а ξ_t — внешнее воздействие (forcing), включающее стохастичность выбора мини-батча и детерминированное изменение гиперпараметров (например, затухание η_t).

Элементы постановки задачи:

- **Выборка:** Мы не наблюдаем полное высокоразмерное состояние w_t . Наша выборка $\mathcal{D} = \{\mathbf{m}_t\}_{t=1}^T$ состоит из векторов скалярных наблюдений $\mathbf{m}_t = [m_1(t), \dots, m_K(t)]^\top$, где каждая метрика является функцией наблюдения $m_i(t) = \phi_i(w_t, \xi_t) \in \mathbb{R}$.
- **Статистические гипотезы:** Мы предполагаем, что динамика обучения w_t сходится к некоторому инвариантному многообразию (аттрактору) размерности $m \ll D$. Согласно теоремам Старка [20, 21] для систем с внешним воздействием, временной ряд одной наблюдаемой метрики $X(t) \in \{m_i(t)\}$ содержит достаточную информацию для восстановления фазового многообразия системы (аттрактора).
- **Модель в классе моделей:** Мы применяем метод симплексной проекции (Simplex projection [22]). Для переменной $X(t)$ строится вектор задержки (delay embedding) в реконструированном фазовом пространстве:

$$\mathbf{x}_t = [X(t), X(t - \tau), \dots, X(t - (d - 1)\tau)]^\top \in \mathbb{R}^d, \quad (2)$$

где d — размерность вложения, τ — временная задержка. Модель отображения предсказывает значение другой переменной $\hat{Y}(t)$ (на основе кросс-маппинга из X) как экспоненциально взвешенную сумму $d + 1$ ближайших соседей вектора $\mathbf{x}_t$ на реконструированном многообразии.

- **Ограничения класса моделей:** Согласно теореме о вложении, размерность должна удовлетворять условию $d \geq 2m + 1$.
- **Функция ошибки и критерий качества:** Способность к прогнозированию (prediction skill) оценивается коэффициентом корреляции Пирсона ρ между предсказанными значениями $\hat{Y}(t)|M_X$ и истинными наблюдениями $Y(t)$:

$$\rho = \frac{\text{Cov}(Y, \hat{Y})}{\sqrt{\text{Var}(Y)\text{Var}(\hat{Y})}}. \quad (3)$$

Причинно-следственная связь $X \rightarrow Y$ подтверждается, если $\rho(L)$ монотонно сходится к константе > 0 при увеличении размера библиотеки исторических наблюдений $L \leq T$.

- **Процедура кросс-валидации:** При поиске ближайших соседей в фазовом пространстве используется стратегия Leave-One-Out (вектор $\mathbf{x}_t$ исключается из библиотеки при поиске собственных соседей).
- **Внешний критерий:** Способность предложенной метрики $d^*(t)$ заранее сигнализировать о резком падении валидационной ошибки $m_{\text{valid}}(t)$ (эффект гроккинга) до того, как это падение станет статистически значимым.
- **Постановка задачи оптимизации:** Первичная задача оптимизации в рамках анализа временных рядов — поиск оптимальных гиперпараметров вложения (d^*, τ^*) для конкретной метрики, максимизирующих навык авторегрессионного предсказания:

$$(d^*, \tau^*) = \arg \max_{d \in \mathbb{N}, \tau \in \mathbb{N}} \rho(X(t), \hat{X}(t | d, \tau)). \quad (4)$$

Вторичная задача — выявление матрицы причинно-следственных связей $\mathbf{C} \in \mathbb{R}^{K \times K}$ между метриками m_i , где элемент $C_{i,j}$ пропорционален асимптотическому пределу кросс-маппинга $\lim_{L \rightarrow \infty} \rho(\hat{m}_i | M_{m_j})$.

1. **Модель:** Нелинейное отображение (Simplex projection), которое реконструирует значение одной скалярной метрики по локальной окрестности delay-векторов другой метрики в псевдофазовом пространстве.
2. **Алгоритм:** Алгоритм Convergent Cross Mapping (CCM) и Partial CCM, вычисляющий матрицу взаимных корреляций ρ при варьировании длины библиотеки L с использованием KD-деревьев для поиска соседей.
3. **Решение:** Восстановленная топологическая размерность $d^*(t)$ для заданного окна итераций, а также взвешенный ориентированный граф (карта) причинно-следственных связей, показывающий истинное влияние метрик m_i друг на друга (с отсечением ложных транзитивных связей).

3 Теоретическое обоснование и предлагаемый метод

Предлагаемый фреймворк опирается на теорию нелинейных динамических систем. В данном разделе мы формализуем процесс обучения нейронной сети, вводим необходимые топологические теоремы, описываем методы оценки эффективной размерности и теоретически обосновываем связь между размерностью фазового пространства и эффектом гроккинга.

3.1 Обучение как вынужденная динамическая система (Теоремы Такенса и Старка)

Траектория весов нейронной сети в процессе оптимизации (например, SGD) задается рекуррентным правилом $\mathbf{w}_{t+1} = F(\mathbf{w}_t, \xi_t)$, где $\mathbf{w}_t \in \mathbb{R}^D$ — параметры модели, а ξ_t — внешнее воздействие (мини-батчи, гиперпараметры). Классическая теорема Такенса [19] утверждает, что для автономных систем (без ξ_t), сходящихся к аттрактору размерности m , можно реконструировать топологию всего аттрактора по одному скалярному ряду наблюдений $y_t = \phi(\mathbf{w}_t)$, используя векторы запаздывания (delay embeddings):

$$\mathbf{x}_t = [y_t, y_{t-\tau}, \dots, y_{t-(E-1)\tau}]^\top \in \mathbb{R}^E, \quad (5)$$

при условии, что размерность вложения $E \geq 2m + 1$.

Однако градиентный спуск не является автономной системой. Влияние стохастических мини-батчей нарушает условия Такенса. Для обоснования нашего подхода мы опираемся на теоремы Старка о вложениях для систем с внешним воздействием (Forced Systems) [20, 21]. Старк доказал, что если внешнее воздействие ξ_t генерируется детерминированным процессом (например, расписанием learning gate) или является ограниченным стохастическим шумом (выбор батчей), то отображение задержки сохраняет свойства диффеоморфизма. Это фундаментально обосновывает возможность применения метода Convergent Cross Mapping (CCM) к зашумленным логам $\mathcal{L}_t$ для выявления истинных причинно-следственных связей.

3.2 Теоретическая модель форсинга: Poisoned Batch Scenario

Для валидации способности алгоритма извлекать каузальность из логов $\mathcal{L}_t$, необходимо внедрить в систему контролируемый драйвер α_t (доля отравленных данных). С точки зрения динамики мы искусственно модифицируем оператор обновления $F(\mathbf{w}_t, \alpha_t, \xi_t)$. Строгая формализация этого процесса представлена в Алгоритме 1. Все сценарии отравления, которые были имплементированы и использованы в экспериментах, описаны в разделе Вычислительный эксперимент 5.

Algorithm 1 Универсальный сценарий контролируемого форсинга (Poison Batch)

Require: Чистый батч $(\mathbf{X}, \mathbf{y})$, шаг t , стратегия P (Синусоида, Меандр, Логистическая карта)

Ensure: Модифицированный батч $(\mathbf{X}', \mathbf{y}')$, фактическая доля искажения α_t

```

1:  $\alpha_t \leftarrow P.\text{calc\_fraction}(t)$  ▷ Генерация внешнего драйвера аттрактора
2:  $N \leftarrow \text{size}(\mathbf{X})$ 
3:  $n_{\text{poison}} \leftarrow \lfloor \alpha_t \cdot N \rfloor$ 
4: if  $n_{\text{poison}} == 0$  then
5:   return  $(\mathbf{X}, \mathbf{y}, 0.0)$ 
6: end if
7:  $\text{idx} \leftarrow \text{rand\_perm}(N)[1 \dots n_{\text{poison}}]$  ▷ Определение подпространства воздействия
8:  $\mathbf{X}' \leftarrow \mathbf{X}.\text{clone}()$ ,  $\mathbf{y}' \leftarrow \mathbf{y}.\text{clone}()$ 
9: if  $P$  modifies features then
10:   $\sigma_t \leftarrow P.\text{get\_noise\_level}(t)$ 
11:   $\mathbf{X}'[\text{idx}] \leftarrow \mathbf{X}[\text{idx}] + \mathcal{N}(0, \sigma_t^2)$  ▷ Инъекция гауссовского шума
12: else
13:   $\mathbf{y}'[\text{idx}] \leftarrow \text{randint}(0, n_{\text{cls}}, n_{\text{poison}})$  ▷ Искажение топологии классов
14: end if
15: return  $(\mathbf{X}', \mathbf{y}', \alpha_t)$ 
```

3.3 Методы оценки эффективной размерности фазового пространства

Для применения метода ССМ и выявления фазовых переходов критически важно определить оптимальную размерность вложения E (внутреннюю сложность системы). В нашем фреймворке мы рассматриваем как классический подход, так и современные методы, более устойчивые к специфике нейросетевой оптимизации:

1. Классический метод ложных ближайших соседей (False Nearest Neighbors, FNN) [23]: Основан на геометрическом «развертывании» аттрактора. При недостаточной размерности пространства удалённые точки траектории проецируются близко друг к другу, образуя «ложных» соседей. Метод измеряет расстояние между точкой и её ближайшим соседом в пространстве размерности d , а затем проверяет, насколько сильно это расстояние увеличивается при переходе к размерности $d + 1$. Если относительное изменение превышает заданный порог (эвристика R_{tol}), сосед считается ложным. Оптимальное E достигается, когда доля ложных соседей падает практически до нуля. Основным ограничением метода для нашей задачи является высокая чувствительность к стохастическому шуму SGD и необходимость ручного подбора порогов.

2. Метод максимизации симплексной проекции (Simplex Projection Skill) [22]: Оптимальное E ищется как аргумент, максимизирующий авторегрессионную корреляцию ρ при предсказании y_{t+1} по его $E + 1$ ближайшим соседям в реконструированном фазовом пространстве. Это топологическое гарантирует наилучшее «развертывание» аттрактора без переобучения на высокочастотный шум. Однако он слишком грубый и часто просто возвращает размерность равную единице.

3. Метод Цао (Cao's Method) [24]: Является строгим математическим развитием FNN. Основан на вычислении усредненного отношения расстояний между ближайшими соседями при переходе от размерности d к $d + 1$: $a(i, d) = R_{d+1}(i)/R_d(i)$. Глобальный критерий $E_1(d) = \bar{a}(d+1)/\bar{a}(d)$ полностью избавляет от необходимости задания пороговых значений (R_{tol}) и выходит на устойчивое плато ($E_1 \approx 2$), когда все ложные пересечения траекторий устранены. Однако тоже довольно грубый и плохо себя проявляет в сценарии с гроккингом.

4. Метод максимального правдоподобия (MLE Intrinsic Dimension) [25]: В отличие от геометрических методов «снизу-вверх» метод Левиной-Бикеля проецирует ряд сразу в избыточное высокоразмерное пространство и оценивает локальную внутреннюю размерность $\hat{d}_x$ по Пуассоновскому распределению расстояний до k ближайших соседей. Мы формализуем этот процесс в Алгоритме 2. Этот метод возвращает *непрерывное* значение размерности, что делает его идеальным инструментом для отслеживания гладких топологических изменений на скользящем окне (например, коллапса размерности при гроккинге).

Algorithm 2 Оценка размерности MLE Intrinsic Dimension (Levina-Bickel)

Require: Временной ряд $\mathcal{L} = \{y_1, \dots, y_N\}$, задержка τ , макс. размерность E_{max} , соседи k

Ensure: Эффективная внутренняя размерность $\hat{D}$

- 1: $M \leftarrow \text{DelayEmbedding}(\mathcal{L}, E_{max}, \tau)$ ▷ Построение избыточного вложения
 - 2: **for** каждой точки $x_i \in M$ **do**
 - 3: Найти k ближайших соседей с расстояниями $r_1 \leq r_2 \leq \dots \leq r_k$
 - 4: $\hat{d}_{x_i} \leftarrow \left[\frac{1}{k-1} \sum_{j=1}^{k-1} \log \left(\frac{r_k}{r_j} \right) \right]^{-1}$ ▷ Локальная оценка по радиусу r_k
 - 5: **end for**
 - 6: $\hat{D} \leftarrow \frac{1}{|M|} \sum_i \hat{d}_{x_i}$ ▷ Глобальное усреднение размерности аттрактора
 - 7: **return** $\hat{D}$
-

3.4 Теоретическое обоснование Гроккинга как топологического перехода

Гроккинг (Grokking) представляет собой феномен отложенной генерализации [9]: валидационная точность модели внезапно возрастает до 100% спустя тысячи итераций после того, как обучающая ошибка достигла нуля, хотя в оригинальной статье выделяют несколько типов гроккингов, то есть иногда валидационная точность модели возрастает всё же не резко а довольно плавно, когда обучающая ошибка достигла нуля.

С точки зрения теории динамических систем, мы формализуем гроккинг как фазовый переход (топологический коллапс) в ландшафте потерь.

- **Фаза меморизации (Меморизация):** Нейронная сеть "заучивает" данные как несвязанный шум. Траектория оптимизатора w_t блуждает по плоскому высокоразмерному многообразию (high-entropy state). В этот период эффективная размерность временного ряда лосса $\mathcal{L}_t$, вычисленная по Алгоритму 2, будет максимальной ($\hat{D} \gg 1$).
- **Фаза генерализации (Гроккинг):** Под воздействием L_2 -регуляризации (weight decay) сеть отбрасывает шумовые признаки и «кристаллизует» оптимальный алгебраический алгоритм в структуре своих весов.

Ключевая гипотеза исследования: Нахождение обобщающего решения строго ограничивает степени свободы системы. Геометрически это означает, что аттрактор динамической системы стягивается в низкоразмерное подмногообразие. Следовательно, отслеживание эффективной размерности $d^*(t)$ с использованием метода MLE (коллапс размерности) на скользящем окне скалярного ряда $\mathcal{L}_t$ должно действовать как опережающий индикатор предстоящего скачка точности (генерализации), не требуя анализа тяжелых матриц Гесса.

4 Вычислительный эксперимент

4.1 Планирование эксперимента

Цели эксперимента. Глобальной целью вычислительного эксперимента является валидация статистического фреймворка на основе метода ССМ для извлечения каузальной информации из логов оптимизации. Исследование разделено на три ключевых направления:

1. **Базовый сценарий (Baseline - Poisoned Batch):** Искусственное отравление обучающей выборки разными способами для верификации способности алгоритма восстанавливать причинно-следственную связь из скалярных логов полученных в ходе обучения модели в контролируемой среде, где заранее известен ожидаемый результат.
2. **Детекция гроккинга (Grokking Detecting):** Мы выдвигаем гипотезу о том, что фазовый переход от запоминания (memorization) к обобщению (generalization) топологически соответствует коллапсу эффективной размерности вложения $d^*(t)$ нашего фазового пространства системы. Отслеживание этой размерности позволит предсказывать наступление гроккинга до его фактического проявления в валидационном loss.

Наборы данных и конфигурация алгоритма. Для базового сценария (Poisoned Batch) используется набор данных CIFAR-10 для сверточной архитектуры ResNet-18. Для изучения эффекта гроккинга (Grokking Detecting) применяется алгоритмический датасет задачи модульного сложения [9] на базе 1-слойного Трансформера, а также датасет задачи композиции в S_5 [9].

Помимо базовых метрик (функция потерь $\mathcal{L}$, точность), согласно современным подходам к анализу обобщающей способности [2] и нелинейной динамики [26], алгоритм отслеживает дополнительные скалярные сигналы: норму градиента $\|g\|_2$, нормы весов $\|w\|_2$, а также скалярное произведение между градиентами на соседних итерациях. Гиперпараметры фазовой реконструкции (задержка τ и размерность вложения E) вычисляются динамически на основе минимума взаимной информации (DMI) [27] и метода MLE соответственно.

Ожидаемые графики и таблицы. Планируется получить следующие результаты: (1) Таблица сравнения асимптотической каузальности ρ_∞ для различных типов искусственного форсинга; (2) График динамики размерности вложения $d^*(t)$ с явно выраженным спадом в момент, предшествующий резкому росту валидационной точности (гроккинг).

4.2 Базовый алгоритм и сценарии отравления (Run Basic Code)

В качестве базового алгоритма (baseline) для валидации фреймворка реализована унифицированная среда внедрения контролируемых внешних воздействий (форсингов) в процесс обучения. Это позволяет создать искусственный драйвер α_t (доля искаженных данных в батче на шаге t),

че влияние на функцию потерь математически гарантировано. Для тестирования способности ССМ восстанавливать причинность из сигналов различной природы (стохастических, гладких, разрывных и хаотических) разработаны пять независимых сценариев:

1. **Случайный шум (Random Label Poisoning):** Базовый стохастический контроль. Доля отравленных меток α_t на каждом шаге сэмплируется из равномерного распределения: $\alpha_t \sim \mathcal{U}(\alpha_{min}, \alpha_{max})$.
2. **Прогрессивный гауссовский шум (Progressive Image Noise):** Искажаются не метки y , а сами входные изображения X . К случайно выбранной части батча добавляется нормальный шум $\mathcal{N}(0, \sigma_t^2)$, где амплитуда линейно возрастает на этапе прогрева: $\sigma_t = \sigma_{max} \min(1, \frac{t}{T_{warmup}})$.
3. **Синусоидальный форсинг (Sinusoidal Forcing):** Гладкое детерминированное воздействие. Доля отравленных меток изменяется по гармоническому закону: $\alpha_t = \alpha_{base} + A \sin(2\pi t / T_{period})$, где A — амплитуда, а T_{period} — период осцилляции.
4. **Дискретный импульсный сигнал (Discrete Square Wave):** Разрывное детерминированное воздействие. Батчи отравляются фиксированной долей c только в активные фазы (чередование каждые Δ шагов): $\alpha_t = c$ при $(\lfloor t / \Delta \rfloor \bmod 2 \neq 0)$, иначе $\alpha_t = 0$.
5. **Детерминированный хаос (Logistic Map):** Псевдослучайный сигнал, генерируемый логистическим отображением. Доля отравления $\alpha_t = c \cdot x_t$, где состояние x_t обновляется по рекуррентному правилу: $x_{t+1} = r x_t (1 - x_t)$. При параметре $r = 3.9$ система находится в режиме детерминированного хаоса, который стандартными тестами неотличим от белого шума, но топологически распознается алгоритмом ССМ.


Оригинальная нейронная сеть обрабатывает модифицированный батч, что неизбежно отражается на значениях валидационных loss и ассигасы. Алгоритм ССМ получает на вход исключительно два скалярных временных ряда: драйвер $\{\alpha_t\}$ и отклик $\{\mathcal{L}_t\}$, и решает задачу восстановления истинной причинно-следственной связи в условиях сильного стохастического шума SGD, не имея доступа к матрицам весов модели.

4.3 Результаты экспериментов (Preliminary Report)


На текущем этапе проведен полный цикл экспериментов для сценариев "отравленного батча" (Poisoned Batch) и детекции гроккинга. Полученные данные подтверждают работоспособность предложенного фреймворка.

Результаты сценария Poisoning. Наилучшие показатели каузальной связности зафиксированы в детерминированных сценариях и при использовании дискретного отравления с переменной длиной волны. На Рис. 1 представлены кривые сходимости для *Sinusoidal Forcing* и *Discrete Square Wave Randomness*. Коэффициент корреляции ρ при восстановлении драйвера α_t по тени $\mathcal{L}_{val}$ достигает 0.75, демонстрируя классическую для ССМ монотонную сходимость при росте длины библиотеки L .

Эксперименты выявили важную асимметрию в выборе целевой метрики (Рис. 2). Каузальность $\alpha \rightarrow \mathcal{L}$ фиксируется значительно надежнее, чем связь с точностью (*accuracy*) (хотя порой ассигасу отрабатывает немного лучше, за счёт более качественно подобранных параметров аттрактора). Это подтверждает гипотезу о том, что непрерывная функция потерь лучше отражает геометрию аттрактора системы. В то же время сценарии с высокой долей стохастичности, такие как *Logistic Map* и *Progressive Image Noise*, на текущих параметрах не показали стабильной конвергенции (Рис. 2), что иллюстрирует предел чувствительности метода при наложении хаоса драйвера на стохастику оптимизатора. Также была отмечена критическая роль выбора задержки τ : отклонение от оптимального значения, найденного через DMI, приводит к резкому падению качества восстановления, хотя бывали и случаи где за счёт более качественной настройки DMI удавалось улавливать более сильный уровень конвергенции.




(a) Sinusoidal Forcing ($\rho \approx 0.75$)




(b) Discrete Square Wave Randomness


Рис. 1: Примеры успешной конвергенции CSM в сценариях с детерминированным и драйвером со стохастикой.



(a) Poison → Loss



(b) Poison → Accuracy




(c) Logistic Map (провал)

Рис. 2: Анализ чувствительности и границ применимости: (a, b) демонстрация асимметрии отклика — непрерывная функция потерь восстанавливает каузальность значительно точнее, чем дискретная метрика точности; (c) деградация метода при наложении хаотического драйвера на стохастичку SGD.


Результаты сценария Grokking. Исследование феномена отложенной генерализации проводилось в несколько этапов: от базового подтверждения гипотезы до тестирования метода в условиях сложной алгебраической структуры данных и стохастического шума.

Этап 1: Базовый эксперимент и проблема вырожденного наблюдателя. Первоначальные эксперименты проводились на задаче модульного сложения с использованием полнопакетного градиентного спуска (Full-Batch GD) (Рис. 3). Нам удалось зафиксировать падение эффективной размерности (MLE ID) ряда $\mathcal{L}_{train}$ непосредственно перед скачком валидационной точности (с $E \approx 4 - 5$ до $E \approx 2.8$).

Однако этот эксперимент выявил важную методологическую проблему. При полнопакетной оптимизации или замене Adam на SGD корреляция между размером фазового пространства E и эффектом гроккинга становилась менее очевидной. С теоретической точки зрения это объясняется проблемой «вырожденного наблюдателя»: в отсутствие стохастического шума мини-батчей траектория оптимизатора вырождается в детерминированную гладкую кривую, а обучающий лосс падает практически до нуля, лишая метод MLE необходимой дисперсии для оценки истинной размерности пространства $d^*(t)$.



(a) Динамика Train/Val Accuracy




(b) Коллапс размерности (MLE ID)


Рис. 3: Этап 1: Феномен гроккинга на базовом эксперименте. Переход от запоминания к обобщению сопровождается снижением топологической сложности траектории $\mathcal{L}_{train}$.

Этап 2: Стохастическая оптимизация (Модульное сложение). Для решения описанной проблемы мы перешли к стохастической оптимизации (Mini-batch AdamW) и расширили спектр анализируемых 1-D скалярных метрик. Стохастический шум (Stochastic Forcing) увеличил дисперсию рядов скалярных метрик, что позволило алгоритмам фазовой реконструкции более точно оценивать истинную размерность фазового пространства аттрактора. В качестве целевой метрики была выбрана норма весов ($\|w\|_2$), так как она сохраняет богатую дисперсию на протяжении всей фазы меморизации и что не менее важно, ни как не зависит от валидационной выборки.


На Рис. 4 представлены результаты эксперимента. В верхней строке (с включенной L_2 -регуляризацией, $WD = 1.0$) наблюдается идеальный топологический коллапс: эффективная размерность E (а точнее её оценка $d^*(t)$ полученная MLE методом) обваливается синхронно с нормой весов задолго до того, как метрика Аккурасу фиксирует генерализацию. В нижней строке (без регуляризации, $WD = 0.0$) гроккинг не наступает, сеть уходит в вечную меморизацию, и метод MLE корректно показывает не спадающую размерность фазового пространства. Это доказывает отсутствие ложноположительных срабатываний.




(a) WD=1: EDM & Accuracy




(b) WD=1: EDM & Loss




(c) WD=1: EDM & Norm



(d) WD=0: EDM & Accuracy



(e) WD=0: EDM & Loss



(f) WD=0: EDM & Norm

Рис. 4: Этап 2: Анализ гроккинга на модульном сложении при наличии стохастического шума. Сравнение динамики E относительно Accuracy, Loss и Нормы весов в режимах с генерализацией (верхний ряд) и без нее (нижний ряд).

Этап 3: Неабелевы группы и сложные алгебраические представления (S_5). Для верификации универсальности фреймворка задача была усложнена до композиции перестановок неабелевой группы S_5 . Согласно теории представлений, данная математическая структура

требует более высоких размерностей для вложения в весовые матрицы трансформера, чем коммутативное сложение.

Как видно на Рис. 5, предложенный EDM-фреймворк успешно справился с этой задачей. В фазе хаотичного поиска размерность E держится на высоком уровне. При формировании сетью обобщающего алгебраического правила (гроккинг), размерность предсказуемо коллапсирует. Эксперимент без Weight Decay (нижний ряд) вновь подтверждает, что размерность не падает в случае когда нет гроккинга.




Рис. 5: Этап 3: Анализ композиции в группе S_5 . Коллапс размерности E надежно фиксирует структурную перестройку сети даже при более сложной многомерной структуре скрытых представлений неабелевой группы.

4.4 Теоретическая интерпретация результатов

Анализ полученных графиков позволяет сделать следующие теоретические выводы:

1. **Фильтрация стохастического шума:** Успех CCM в сценарии *Sinusoidal Forcing* подтверждает, что метод способен реконструировать фазовое пространство системы и качественно предсказывать влияние одних признаков на другие, даже при наличии высокочастотного шума мини-батчей (Stochastic Forcing [21]).
2. **Чувствительность к типу драйвера:** Неудача с *Logistic Map* свидетельствует о том, что при наложении двух хаотических процессов (внешнего и внутреннего) "тень" системы становится неразличимой в одномерном логге без существенного увеличения размерности вложения E , особенно если процесс драйвера слишком хаотичен.
3. **Природа гроккинга:** Зафиксированный коллапс размерности (Рис. 3b) доказывает, что гроккинг — это не просто уменьшение ошибки, а качественная перестройка динамической системы: переход с высокоэнтропийного аттрактора "запоминания" на низкоразмерный аттрактор "алгебраического правила".
4. **Метрики оптимизатора:** Более сложные эксперименты показали, что мы можем диагностировать гроккинг не используя валидационную выборку. Это показывает, что данное явление не является субъективным и не зависит напрямую от выбранной валидационной выборки.
5. **Размерность при $wd = 0$:** Размерность при переобучении изначально низкая. Изначально может показаться, это значит, что модель уловила сложную алгебраическую структуру данных, но как мы видим по качеству на валидационной выборке это не так. На самом деле модель переобучилась, а потом в силу особенности ошибки (используется кросс-энтропия) просто начала наращивать норму весов, тем самым повышая логиты и уменьшая ошибку, таким образом аттрактор скотился в пространство размерности 1. Это доказывает, что важно смотреть на динамику поведения размерности, а не на её абсолютные значения.




Рис. 6: Оригинальный эскиз гипотезы коллапса размерности, подтвержденный в ходе экспериментов (см. Рис. 3b).

5 Обсуждение результатов (Discussion)

Результаты проведенных вычислительных экспериментов подтверждают фундаментальную гипотезу работы: процесс оптимизации глубоких нейронных сетей может быть исследован с точки зрения теории нелинейных динамических систем и эмпирического динамического моделирования (EDM). Однако перенос методов фазовой реконструкции в ML выявил ряд специфических ограничений и физических эффектов, требующих отдельного осмысления.

1. Проблема вырожденного наблюдателя и роль стохастичности. В ходе экспериментов с полнопакетным градиентным спуском (Full-Batch GD) мы столкнулись с невозможностью оценки размерности аттрактора: все используемые нами 1-D скалярные метрики вырождались в константу. С точки зрения нелинейной динамики, идеальная оптимизация без шума схлопывает траекторию в прямолинейный луч, лишая методы (такие как MLE) необходимой дисперсии для оценки кривизны ландшафта. Таким образом при анализе размерности стоит следить за тем, чтобы ряд не выражался. Это можно делать за счёт прореживания ряда, но это может негативно сказаться на точности оценки. Таким образом этот метод работает лучше всего в системах где ряды не выражаются, то есть в системах со стохастикой. Высокочастотный шум SGD заставляет оптимизатор исследовать локальную геометрию аттрактора. Кроме того, эксперименты показали, что норма весов ($\|w\|_2$) является гораздо более информативным и стабильным «наблюдателем» скрытой динамики, чем склонный к вырождению обучающий лосс.

2. Границы применимости ССМ и предел чувствительности. Успешное восстановление причинно-следственной связи в сценариях с синусоидальным и дискретным драйвером доказало способность ССМ фильтровать внутренний шум нейросети. Однако провал метода на Логистическом отображении (Logistic Map) говорит об ограниченности применимости фреймворка. При наложении двух хаотических процессов — внутреннего (SGD) и внешнего (детерминированный хаос драйвера) — проекция системы в 1D-пространство становится слишком запутанной.

3. Зависимость топологии от выбора наблюдателя (Observability). Одним из важнейших эмпирических результатов нашей работы стало выявление зависимости реконструированной размерности E от выбора скалярной метрики (функции наблюдения). В теории динамических систем теорема Такенса требует, чтобы функция наблюдения была «типичной» (generic) и не имела вырожденных симметрий.

Наши эксперименты показали, что норма весов ($\|w\|_2$) является симметричным макроскопическим наблюдателем. Динамика нормы определяется преимущественно балансом двух глобальных сил: градиентом ошибки (увеличивающим веса) и L_2 -регуляризацией (сжимающей веса). Из-за этого эффективная размерность ряда $\|w\|_2$ всегда коллапсирует до низких значений ($E \approx 2 \dots 4$), независимо от сложности решаемой задачи, так как эта метрика «слепая» к сложной угловой структуре представлений.

В противовес этому, функция потерь (L_{val} или зашумленный L_{strain}) напрямую зависит от логитов и чувствительна к внутренней алгебраической структуре сети. Работы по прямому спектральному анализу весов [10] показывают, что для модульного сложения сеть формирует 2D-окружности (Фурье-базисы). Оценка MLE по ряду лосса подтверждает это топологически: коллапс траектории останавливается на $E \approx 2$. В свою очередь, для неабелевой группы

S_5 , неприводимые представления которой требуют пространств большей размерности [28], коллапс размерности, измеряемый именно по ряду лосса, предсказуемо останавливается на более высоком уровне $E \approx 4 \dots 6$. Таким образом, мы доказали, что для «слепой» оценки алгебраической сложности выученного алгоритма необходимо использовать метрики, напрямую связанные с распределением выходов сети, а не агрегированные статистики параметров.

Более того, при переходе к неабелевой группе перестановок S_5 , неприводимые представления которой требуют пространств размерности 4, 5 и 6 [28], наш метод безошибочно зафиксировал остановку топологического коллапса на уровне $E \approx 4 \dots 5$. Таким образом, предложенный фреймворк позволяет измерять скрытую алгебраическую структуру представлений исключительно по одномерному логу обучения. Также стоит отметить, что лучше использовать именно L_{sval} , так как L_{strain} быстро выражается.

4. Топология против прагматики. С практической точки зрения, мониторинг валидационной функции потерь (L_{sval}) остается более быстрым и дешевым предиктором наступления гроккинга, по крайней мере в проведенных экспериментах. Однако метрики являются лишь симптомами улучшения обобщающей способности. В свою очередь, обвал эффективной размерности E предоставляет строгое математическое доказательство структурного фазового перехода — процесса, при котором сеть отсекает шумовые степени свободы и сжимает траекторию в компактное подмногообразие. Также для нашего метода в принципе не нужна валидационная выборка. Это наблюдение открывает путь к принципиально новым методам прунинга (network pruning) и сжатия моделей (например, выбора ранга для LoRA), основанным на истинном количестве степеней свободы обученной сети, вычисленном динамически.

6 Заключение (Conclusion)

В данной работе был предложен и верифицирован новый статистический фреймворк для диагностики режимов оптимизации глубоких нейронных сетей, основанный на методах эмпирического динамического моделирования (EDM) и топологической реконструкции фазового пространства. Относясь к процессу градиентного спуска как к вынужденной динамической системе, мы пришли к следующим основным результатам:

- **Применимость фазовой реконструкции к SGD:** На контролируемых сценариях искусственного вмешательства (Poisoned Batch) экспериментально доказана применимость теорем Старка. Установлено, что метод Convergent Cross Mapping (CCM) способен извлекать скрытые причинно-следственные связи из одномерных логов даже в условиях сильного стохастического шума мини-батчей.
- **Гроккинг как топологический переход:** Эмпирически доказано, что феномен отложенной генерализации представляет собой структурный фазовый переход системы к низкоразмерному состоянию.
- **Раннее предсказание генерализации:** Использование метода максимального правдоподобия (MLE Intrinsic Dimension) позволило зафиксировать коллапс эффективной размерности аттрактора E задолго до фактического скачка валидационной точности, что утверждает E в качестве предиктора генерализации.

Главный итог исследования заключается в том, что одномерные скалярные логи (такие как функция потерь, норма весов и другие) содержат достаточную топологическую информацию для глубокой диагностики состояний нейросети. Предложенный подход позволяет оценивать истинную алгебраическую сложность выученных алгоритмов исключительно по скалярным рядам, открывая путь к созданию вычислительно дешевых методов мониторинга и структурной оптимизации моделей без необходимости анализа тяжелых весовых матриц или Гессаiana.

Список литературы

- [1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT press, 2016.
- [2] Yiding Jiang, Behnam Neyshabur, Hossein Mobahi, Dilip Krishnan, and Samy Bengio. Fantastic generalization measures and where to find them. In *International Conference on Learning Representations (ICLR)*, 2020.

- [3] Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [4] Sam McCandlish, Jared Kaplan, Dario Amodei, and OpenAI Dota Team. An empirical model of large-batch training. *arXiv preprint arXiv:1812.06162*, 2018.
- [5] Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, and Ping Tak Peter Tang. On large-batch training for deep learning: Generalization gap and sharp minima. In *International Conference on Learning Representations (ICLR)*, 2017.
- [6] Jeremy M Cohen, Simran Kaur, Yanzhi Li, J Zico Kolter, and Ameet Talwalkar. Gradient descent on neural networks typically occurs at the edge of stability. In *International Conference on Learning Representations (ICLR)*, 2021. URL <https://openreview.net/forum?id=jh-rTtvkGeM>.
- [7] Kwangjun Ahn, Sébastien Bubeck, Sebastien Chewi, Yin Tat Lee, Felipe Nayak, and Matthew Stephens. Understanding gradient descent on the edge of stability in deep learning. In *International Conference on Machine Learning (ICML)*, 2022.
- [8] Xingyu Zhu, Zixuan Wang, Xiang Wang, Mo Zhou, and Rong Ge. Understanding edge-of-stability training dynamics with a minimalist example. In *International Conference on Learning Representations (ICLR)*, 2023.
- [9] Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. Grokking: Generalization beyond overfitting on small algorithmic datasets. *arXiv preprint arXiv:2201.02177*, 2022.
- [10] Neel Nanda, Lawrence Chan, Tom Lieberum, Jess Smith, and Jacob Steinhardt. Progress measures for grokking via mechanistic interpretability. In *International Conference on Learning Representations (ICLR)*, 2023.
- [11] Paul J T Notsawo, Hattie Zhou, Mohammad Pezeshki, Irina Rish, and Guillaume Dumas. Predicting grokking long before it happens: A look into the loss landscape of models which grok. *arXiv preprint arXiv:2306.13253*, 2023.
- [12] George Sugihara, Robert May, Hao Ye, Chih-hao Hsieh, Ethan Deyle, Michael Fogarty, and Stephan Munch. Detecting causality in complex ecosystems. *Science*, 338(6106):496–500, 2012. doi: 10.1126/science.1227079.
- [13] Hao Ye, Richard J Beamish, Sarah M Glaser, Sue C Grant, Chih-hao Hsieh, Laura J Richards, Jon T Schnute, and George Sugihara. Equation-free mechanistic ecosystem forecasting using empirical dynamic modeling. *Proceedings of the National Academy of Sciences (PNAS)*, 112(13):E1569–E1576, 2015.
- [14] Siyu Leng, Huanfei Ma, Jürgen Kurths, Ying-Cheng Lai, Wei Lin, Kazuyuki Aihara, and Luonan Chen. Partial cross mapping eliminates indirect causal influences. *Nature Communications*, 11(1):1–9, 2020. doi: 10.1038/s41467-020-16238-0.
- [15] Kaushik Sekaran, A Harshvardhan, N Sandhya, C Sudha, G Nagaraju, Hanumanthu Bukya, Rashmi Sahay, and J Kalaivani. A self-operational convolutional neural networks with convergent cross-mapping and its application in Parkinson’s disease classification. *IEEE Access*, 12:84332–84343, 2024. doi: 10.1109/ACCESS.2024.3412808.
- [16] Chuan Lin, Zhihui Yu, Wenhao Chen, Qinghua Lin, and Cheng Zhang. A novel causal graph attention network with convergent cross mapping for short-term photovoltaic power forecasting. *Renewable Energy*, 227:120000, 2024. doi: 10.1016/j.renene.2024.120000.
- [17] Edward Brouwer, Adam Arany, Yves Moreau, and Roland Becker. Latent convergent cross mapping. In *International Conference on Learning Representations (ICLR)*, 2021. URL https://openreview.net/forum?id=tA_uWdI_Zz5.
- [18] K R Usmanova and V V Strijov. Models of detection relationship between time series in forecasting problems. *Systems and Means of Informatics*, 29(2):12–30, 2019.

- [19] Floris Takens. Detecting strange attractors in turbulence. In *Dynamical systems and turbulence, Warwick 1980*, pages 366–381. Springer, 1981. doi: 10.1007/BFb0091924.
- [20] Jaroslav Stark. Delay embeddings for forced systems. i. deterministic forcing. *Journal of Nonlinear Science*, 9(3):255–332, 1999. doi: 10.1007/s003329900072.
- [21] Jaroslav Stark, David S Broomhead, ME Davies, and J Huke. Delay embeddings for forced systems. ii. stochastic forcing. *Journal of Nonlinear Science*, 13(6):519–577, 2003. doi: 10.1007/s00332-003-0534-4.
- [22] George Sugihara and Robert M May. Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series. *Nature*, 344(6268):734–741, 1990. doi: 10.1038/344734a0.
- [23] Matthew B Kennel, Reggie Brown, and Henry DI Abarbanel. Determining embedding dimension for phase-space reconstruction using a geometrical construction. *Physical review A*, 45(6):3403, 1992. doi: 10.1103/PhysRevA.45.3403.
- [24] Liang Cao. Practical method for determining the minimum embedding dimension of a scalar time series. *Physica D: Nonlinear Phenomena*, 110(1-2):43–50, 1997. doi: 10.1016/S0167-2789(97)00118-8.
- [25] Elizaveta Levina and Peter J. Bickel. Maximum likelihood estimation of intrinsic dimension. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 17, 2004. URL <https://proceedings.neurips.cc/paper/2004/file/74934548253bcab8490ebd74afecebb5-Paper.pdf>.
- [26] Holger Kantz and Thomas Schreiber. *Nonlinear Time Series Analysis*. Cambridge university press, 2004.
- [27] Andrew M Fraser and Harry L Swinney. Independent coordinates for strange attractors from mutual information. *Physical review A*, 33(2):1134, 1986. doi: 10.1103/PhysRevA.33.1134.
- [28] Bilal Chughtai, Lawrence Chan, and Neel Nanda. A toy model of universality: Reverse engineering how networks learn group operations. In *International Conference on Machine Learning (ICML)*, 2023. URL <https://arxiv.org/abs/2302.03025>.