

Отчёт по трём пилотным экспериментам

25 сентября 2026 г.

Короткий вывод

Наиболее содержательный результат дала плотная low-rank matrix factorization с momentum без внешнего forcing. При $\beta = 1$ полные матрицы факторов сами порождают длительную эндогенную динамику, а оценка по скалярным логам возрастает при переходе от задач ранга 1 к рангам 2 и 4. Контроль с $\beta = 0.9$ даёт затухающую траекторию и менее устойчивую оценку.

Эксперимент с двухслойной линейной сетью пока не подтвердил переносимость метода на нейросетевую оптимизацию: оценка почти не зависела от ранга учителя и не прошла проверку идентифицируемости. Автоматический выбор лага после смены постановки требует отдельного пересчёта.

1. Плотная matrix factorization с momentum

1.1. Постановка

Мы проверяем метод на эндогенной оптимизационной траектории, для которой известна контрольная сложность задачи. Учится обычная плотная факторизация:

$$\min_{U,V} \frac{1}{2} \|UV^T - M_\star\|_F^2, \quad \text{rank}(M_\star) = r.$$

Целевая матрица строится как

$$M_\star = P \text{diag}(\sigma_1, \dots, \sigma_r) Q^T,$$

где P и Q — случайные ортогональные матрицы, а σ_i — ненулевые сингулярные значения. Поэтому $M_\star$ плотная и не диагональна в координатах обучения. Обучаются полные плотные матрицы U и V ширины 8; диагонального ограничения на факторы нет. Варьируется ранг цели $r \in \{1, 2, 4\}$.

Здесь r — известный контроль сложности задачи. Мы не утверждаем, что estimator обязан вернуть ровно r : у плотной факторизации есть дополнительные параметрические направления и симметрии. Проверяется, реагирует ли оценка на изменение ранга и сохраняет ли устойчивую динамику.

Обучение full-batch, без шума, случайных мини-батчей и внешнего forcing. Используется обновление

$$v_{t+1} = \beta v_t + \nabla L(\theta_t), \quad \theta_{t+1} = \theta_t - \eta v_{t+1}.$$

Для основного эксперимента $\eta = 0.02$, $\beta = 1$, 4000 шагов и два random seed. Для контроля используется $\beta = 0.9$, при котором движение затухает. Сохраняются loss, нормы параметров и velocity, а также случайная линейная проекция полной траектории.

Оценка выполняется с embedding dimension до 6, $k = 4$, Theiler window в embedding-режиме и локальным окном длиной 500 наблюдений. Проверяются лаги $\tau = 4$, $\tau = 8$ и лаг по автокорреляции.

1.2. Что измеряется

Контрольный ориентир — ранг целевой матрицы r . Для каждого scalar log вычисляются MG , идентифицируемость, число пересечений тренда и флаг вырожденного окна.

Оценка считается пригодной только вместе с диагностикой, а не по одному числу MG .

1.3. Результат

В recurrent-режиме ни один из проверенных вариантов не помечен как вырожденный. Медианные значения MG :

Ранг цели r	MG по loss	MG по velocity
1	3.5	3.5
2	5.5	5.5
4	5.9	5.9

Оценка возрастает при переходе от ранга 1 к рангу 2 и далее к рангу 4. Абсолютное значение не совпадает с r , что ожидаемо: размерность траектории факторов определяется не только рангом цели, но и параметризацией, momentum и выбранным scalar observable.

В контроле с $\beta = 0.9$ движение затухает, а оценки становятся заметно выше: медианный MG составляет примерно 17–18 против 4–6 в recurrent-режиме. Текущая диагностика не всегда помечает такие окна как вырожденные, что показывает слабость reject-механизма для затухающих плотных траекторий.

1.4. Вывод

Плотная factorization является более содержательной controlled validation, чем диагональная версия: координаты мод не заданы заранее, а факторы обучаются как обычные плотные матрицы. Результат показывает реакцию scalar-log protocol на увеличение ранга задачи на эндогенной траектории без внешнего forcing.

Это не точное восстановление active dimension по рангу матрицы. Результат остаётся пилотным: два seed, искусственная задача и недостаточно строгий reject-механизм для затухающих траекторий.

2. Teacher–student с двухслойной линейной сетью

2.1. Постановка

Учится двухслойная линейная сеть $f(x) = W_2 W_1 x$ размерности 8–8–8. Данные генерируются фиксированным линейным учителем с $r \in \{1, 2, 4\}$ ненулевыми сингулярными значениями. Обучение full-batch с momentum $\beta = 1$, $\eta = 0.02$, 3000 шагов и двумя seed; обучаются все элементы W_1 и W_2 .

2.2. Результат

Диагностика не объявляет окна вырожденными, но проверка идентифицируемости неудовлетворительна: отношение оценок обычно находится в диапазоне 1.7–2.1. Медианный MG почти не зависит от ранга учителя:

Ранг учителя	MG по loss	MG по velocity
1	6.1	6.0
2	6.0	6.1
4	6.2	5.9

Этот запуск не подтверждает метод на нейросетевой оптимизации. Вероятные причины — недостаточно выраженная recurrent-динамика, параметры learning rate/momentum и симметрии двухслойной факторизации.

3. Автоматический выбор лага и окна

Проверялись фиксированные лаги $\tau = 4, \tau = 8$, лаг по автокорреляции и пилотный выбор лага по доминирующему периоду periodogram scalar log.

После изменения первой постановки автоматический выбор лага ещё не пересчитан для плотной factorization. Поэтому старые числа periodogram-пилота не используются как результат новой controlled validation.

Для новой постановки нужно выбирать устойчивый диапазон лагов, проверять стабильность MG по этому диапазону и иметь явный исход «режим не удалось идентифицировать».

Итоговая оценка

1. Плотная matrix factorization + momentum — наиболее содержательная новая controlled validation. Она показывает рост оценки при увеличении ранга на эндогенной recurrent-траектории, но выявляет слабость текущего reject-механизма для затухающих траекторий.
2. Teacher–student — отрицательный результат для выбранных параметров и мотивация для более тщательно настроенного neural-network эксперимента.
3. Automatic lag selection — открытая часть эксперимента; старые результаты диагональной постановки нельзя переносить на плотную factorization без пересчёта.

Данные экспериментов находятся в raw_scores.csv и summary.csv.