

MG при мониторинге обучения decoder-only Transformer

26 сентября 2026 г.

Итог. Проведён локальный proof of concept на небольшом decoder-only Transformer, обучаемом предсказывать следующий символ в Tiny Shakespeare. После десятикратного снижения learning rate в середине обучения MG по фиксированному validation probe loss снизился во всех трёх seed примерно на 30%. Это показывает, что MG чувствителен к упрощению наблюдаемой динамики после стабилизации обучения. Однако строгую трактовку этого числа как абсолютной active dimension пока давать нельзя: на языковой задаче диагностика идентифицируемости остаётся далека от единицы, а validation-loss — стохастический и в основном транзиентный сигнал.

1. Что именно обучалось

Обучался decoder-only Transformer с двумя блоками, шириной 64, четырьмя attention heads, контекстом 64 и примерно 108 тысячами параметров. Модель решала стандартную задачу next-character prediction. Использовался корпус Tiny Shakespeare; его SHA-256: 86c4e6aa9db7c042ec79f339dcb96d42b0075e16b8fc2e86bf0ca57e2

В основном практическом эксперименте использовался AdamW, три seed и два режима. Корпус и его SHA-256 зафиксированы в v2/*/metadata.json: Tiny Shakespeare, digest 86c4e6aa...565ed.

В эксперименте использовались:

- постоянный learning rate 0.003;
- learning rate 0.003 до шага 1536 и 0.0003 после него.

На каждом шаге сохранялись training loss, loss на фиксированном validation probe и норма градиента. На 21 checkpoint дополнительно измерялись верхнее собственное число Hessian, participation ratio активаций и gradient-variance proxy.

Отдельно был сделан контрольный запуск с обычным full-batch gradient descent. Только для этого запуска рассматривалась величина

$$\eta \lambda_{\max}(H)/2,$$

поскольку этот критерий относится к обычному GD и не переносится напрямую на AdamW.

2. Как сравнивались методы

MG применялся к одному scalar log в скользящем окне из 512 точек. Для каждой точки считались также MG при удвоенном embedding dimension, identifiability ratio и флаг degeneracy. Hessian оценивался методом Lanczos с проверкой Ritz residual; измерялось реальное число HVP. Это существенно дороже обработки уже записанного scalar log.

3. Результаты AdamW

Падение MG по probe loss воспроизводится по seed: отношения post/pre равны 0.696, 0.713 и 0.672. Для постоянного LR отношения равны 0.997, 1.053 и 1.020. При этом медианный Hessian top eigenvalue меняется с 81.8 до 89.1, а activation PR — с 9.60 до 11.25. Поэтому наблюдение нельзя объяснить простым падением curvature или активационного effective rank: MG реагирует именно на изменение динамики scalar log.

Таблица 1: Медианные результаты по трём seed. Pre — вторая половина до смены LR, post — последняя часть после смены LR.

Сигнал	pre MG	post MG	post/pre
Постоянный LR, probe loss	5.42	5.65	1.02
Смена LR, probe loss	5.42	3.77	0.70
Постоянный LR, gradient norm	12.16	12.75	1.05
Смена LR, gradient norm	12.16	12.75	1.05

4. Вычислительная стоимость

Время измерялось на CPU при четырёх потоках, на одинаковых 21 checkpoint.

Таблица 2: Медианная стоимость для трёх AdamW seed.

Метод	Время, с	Hessian / метод	Комментарий
Hessian top eigenvalue	12.24	1.0	Lanczos, HVP
MG	0.16	79.7	только scalar-log postprocessing
MG + validity checks	0.37	33.0	MG(40), ratio, diagnostics
Gradient proxy	0.27	45.5	четыре microbatch
Activation PR	0.06	204.0	только для этой маленькой модели

Если validation probe уже логируется во время обучения, полная стоимость MG по этому логу остаётся примерно 0.37 с против 12.24 с для Hessian. Если считать также дополнительный forward на probe на каждом шаге, преимущество уменьшается примерно до 1.6 раза. Поэтому корректное сильное утверждение здесь — ускорение по сравнению с Hessian-анализом при наличии scalar log, а не преимущество над любой дешёвой статистикой.

5. Ограничения и решение о публикации

Этот эксперимент пока нельзя вставлять в статью как доказательство того, что MG даёт теоретически гарантированную active dimension в LLM training. Валидационный лог не является явно рекуррентным, а identifiability ratio после изменения LR находится примерно в диапазоне 1.34–1.48. Это делает интерпретацию результата exploratory: MG надёжно фиксирует переход к более гладкой и менее изменчивой динамике probe loss, но абсолютное значение нельзя автоматически называть числом активных компонент всей модели.

Для публикационного эксперимента нужен Colab GPU. Следующий запуск должен использовать модель хотя бы 10–50M параметров, 4–5 seed, несколько тысяч шагов и validation loss, который уже считается обычным мониторингом обучения. Нужно заранее зафиксировать: окно, задержку, Theiler exclusion, критерии валидности и способ сравнения с Hessian. Основной claim следует формулировать как дешёвое обнаружение смены динамического режима; claim об абсолютной dimensionality допустим только если diagnostics проходят на контролируемом recurrent или quasi-recurrent benchmark.

6. Артефакты

Скрипты и результаты находятся в каталоге research_llm_eos/. Основные файлы: run_v2.py, analyze_v2.py, PROTOCOL.md, v2/adam_same_seed.pdf, v2/effects.csv, v2/timing.csv; контрольный GD находится в gd_v2/.




Рис. 1: Один и тот же seed: loss, MG по probe loss, Hessian top eigenvalue и identifiability ratio. Вертикальная линия — смена learning rate.