

Где MG приносит практическую пользу: итог расширенного поиска

Главный результат

Найден применимый вариант: выбирать модель короткого прогноза активности обученной рекуррентной сети по MG одного нейрона. Полный MG показывает хорошую среднюю точность, но дорог. Приближённый MG по 128 опорным точкам сохранил все решения полного метода на отдельной новой серии и ускорил этот выбор примерно в 16 раз. При этом нельзя утверждать, что MG статистически превосходит всех конкурентов: у более сложных обученных правил средняя ошибка бывает меньше.

Что обучается и зачем

Сначала FORCE/RLS обучает рекуррентную сеть с 256 нейронами генерировать заданные колебания. Есть семь заданий: одна—четыре независимые частоты, два/четыре гармонических выхода и две независимые частоты с гармониками. Восьмая группа — необученная сеть с большим recurrent gain; она может прийти и к постоянному сигналу, поэтому название chaos не означает доказанного хаоса. Все группы сохраняются, даже если сеть плохо воспроизводит цель.

После обучения веса фиксируются. Доступна только активность третьего нейрона. Нужно прогнозировать следующие 32 отсчёта по предыдущим 2048. Прикладное действие — выбрать прогнозную модель, чтобы получить меньшую ошибку без перебора всех моделей на каждом новом сигнале. Это контролируемая задача прогнозирования нейронной активности, а не обучение LLM, ранняя остановка PPO или реальная робототехника.

Восемь кандидатов: последнее значение, среднее, повтор последнего приблизительного цикла, Ridge с 8/48 лагами, 5 ближайших соседей с 8/48 лагами и Ridge на 64 случайных Fourier-признаках с 48 лагами. Все прогнозы прямые многомерные, с одинаковой нормировкой по известному прошлому. Модели обучаются только по префиксу. Ошибка — MSE будущего блока, делённая на дисперсию префикса; это не RMSE.

MG вычисляется при $E=20$, адаптивном лаге, 20 соседях и Theiler exclusion с пределом 150. Небольшое дерево учится предсказывать ошибки кандидатов по MG и выбирает наименьшую. На простых циклах оно обычно выбирает локальный прогноз ближайшими соседями; при более сложной динамике — Ridge. Это эмпирическое правило, не теорема о единственно правильной прогнозной модели.

Как разделены поиск и проверка

Исходные пять больших генераторов по каждой задаче уже использовались в прошлой работе. Они послужили только для поиска. Затем сохранено 100 новых seed-групп 601–700: в каждой семь обучений по 40000 шагов и одна необученная контрольная сеть. До этого запроса группы 601–618 уже существовали; в данном продолжении проведено 574 новых обучения и добавлено 82 контрольных сети.

Seeds 601–618 обучают правила выбора. Seeds 619–630 выявили перспективный короткий горизонт. На следующей серии 631–650 правила уже фиксированы; затем добавлены более сильные геометрические конкуренты. Seeds 651–680 являются отдельной проверкой полного набора сравнений. На ней полный MG получил ошибку 0.03139 против 0.03224 у validation и 0.03540 у TwoNN. В разнице с validation интервал включает ноль. Результат на предыдущих 20 сдвиге был заметно сильнее, поэтому его нельзя выдавать за окончательную оценку эффекта.

После замера высокой стоимости полного MG предложено фиксировать 128 равномерно распределённых опорных delay-векторов. Всё облако сохраняется как кандидаты в соседи; временное исключение не меняется. Два других бюджета 64/256 — проверки чувствительности, основной 128 выбран заранее. Эту новую аппроксимацию проверяют отдельные seeds 681–700, без изменения уже обученного дерева.


Итог на последних 20 seed-группах

Серия содержит 160 прогнозных задач, но независимая единица статистики — 20 seed-групп, а не 160 записей. Все восемь режимов учтены. На постоянных сигналах все алгоритмы используют одно правило: последний отсчёт; NaN не превращается в нулевую размерность.

Правило выбора	Ошибка, меньше лучше
MG, 128 опорных точек	0.03637
Полный MG	0.03637
Обычный validation-перебор	0.04074
TwoNN	0.04364
Levina–Bickel	0.04732
Ранг ковариации delay-облака	0.06098
Permutation entropy	0.05384
Sample entropy	0.05954
Дешёвые признаки	0.05923
Дешёвые признаки + validation	0.03379
Validation errors + MG	0.03167
Все признаки без MG	0.03939
Oracle с будущими ответами	0.00847

У 128-query MG ошибка примерно на 10.7% ниже обычного validation-перебора, но 95%-й bootstrap-интервал парной разницы равен $[-0.00729; 0.01758]$ и включает ноль. В 9 из 20 групп MG лучше validation; преимущества по каждому сиду нет. Наиболее точное из показанных обученных правил использует validation errors вместе с MG и имеет ошибку 0.03167. Дешёвые признаки+validation без MG дают 0.03379, также лучше отдельного MG. Поэтому утверждение «лучше всех аналогов» данными не подтверждается.

Зато все 160 решений 128-query версии совпали с полным MG, и все ошибки совпали. В этой серии результаты 64/256query также совпали; это наблюдение на данной семье, не гарантия для других данных. Доверительные интервалы и индивидуальные seed находятся в query_intervals.csv и query_fresh_comparisons.csv.



Вычислительный выигрыш

Метод	Медиана времени, мс
Полный MG	199.06
MG:128queries	12.22
Validation-перебор	45.30

Здесь время включает вычисление признака, выбор и обучение выбранного прогнозатора. Validation четыре раза проверяет каждый из восьми кандидатов на известных последних 128 точках и затем обучает выбранного на всём префиксе: 33 fit/predict операции. В замере нет загрузки файлов, обучения исходных нейросетей и обучения дерева выбора. Стоимость первого обучения дерева и сбора его calibration-ошибок должна амортизироваться на множестве последующих прогнозов.

Замеры выполнялись последовательно, с одним численным потоком, на одних входах: seeds 681,690,700, четыре задачи в каждом, семь повторов, перемешанный порядок методов. Это 12 входных рядов, а не 160 независимых замеров времени. Полный MG здесь медленнее дешёвых признаков; ускорение относится к новой аппроксимации. Скорость зависит от реализации и оборудования.

Аппроксимация использует тот же estimator kernel, но вместо n запросов делает q запросов и возвращает $(q(k-1)-1)/\text{сумма локальных логарифмов расстояний}$. Проверено точное совпадение с исходным MG при $q=n$, совпадение расстояний KDTree и блочного поиска, affine invariance, отклонение констант и нечисловых значений. Это новое приближение; название «исходный MG без изменений» было бы неверным.

Что ещё проверено и почему не объявлено успехом

Доработанное сравнение гармонической модели с несколькими независимыми частотами проиграло обычной валидации: ошибки 0.2084 у MG, 0.1640 у holdout и 0.1909 у фиксированной многочастотной модели. Перед запуском исправлены общая нормировка прошлого/будущего и поиск раздельных спектральных пиков; это необходимые исправления, не подбор положительного результата.

В новой серии классификации проверены 16 официальных UCR-наборов. Сравнивались 20 временных/спектральных признаков, 8 participation ratio, 8 MG, одинаковые SVC/ExtraTrees и raw-waveform модели. Классификатор выбирался только по training CV. Для перспективных задач добавлены DTW и независимая реализация 1000 случайных convolution kernels (ROCKET-style), но это не полный оригинальный benchmark ROCKET.

На TwoLeadECG добавление MG дало 91.31% balanced accuracy против 82.19% у того же классификатора без MG. Однако ROCKET-style достиг 99.91%: компактная модель улучшилась, общего превосходства нет. На ToeSegmentation1 добавление MG дало 87.78% против 83.61%, но ROCKET-style получил 96.11%. На Earthquakes MG-признаки дали 64.59% против 61.65% в matched ablation; этот небольшой тест 139 записей остаётся exploratory, а поправка на 16 исследованных наборов не поддерживает сильный вывод. Классификация ЭКГ здесь не является медицинской рекомендацией.

На Wafer сначала получился почти идеальный результат даже при 20 размеченных примерах. Аудит показал, что нормальные сигналы имеют много повторяющихся значений, а модель использует отсутствие оценки MG. Три простых признака повторов дают 100% balanced accuracy. Поэтому это найденный артефакт dataset/измерения, а не достоинство MG. На ItalyPowerDemand длины 24 недостаточно для большинства MG-конфигураций; отсутствующие оценки сохранены, а benchmark не годится для выводов о размерности. В ECG5000 одна training-категория содержит 2 примера, что ограничивает 3-fold CV.

Предыдущие UCI traffic/energy, 12 сенсорных forecasting-сценариев, HAR и certification stopping не превзошли сильные baseline. Старые файлы сохранены; сценарии не исчезают из отчёта при смене гипотезы. Выигрыш нейросетевого forecast routing не означает доказанного уменьшения active dimension и не доказывает, когда завершать обучение.

Литература и дальнейшее использование

FFORMA мотивирует выбор и усреднение прогнозных моделей по признакам ряда: <https://www.monash.edu/business/ebs/research/publications/ebs/wp19-2018.pdf>. Catch22 даёт сильный компактный контекст для временных признаков: <https://arxiv.org/abs/1901.10200>. Попытка установить rycatch22 не удалась из-за отсутствия MSVC; наши handcrafted20 не называются catch22. Данные: UCR/UEA <https://www.timeseriesclassification.com/>, все downloadURL и SHA256 сохранены в source.json. Оценивание следовало официальным train/testsplit; там, где ID людей/станков отсутствуют, независимость по ним не доказана.

Практическая формулировка результата: «В контролируемом прогнозировании активности обученных рекуррентных сетей MG выбирает прогнозную модель по одному сигналу. Аппроксимация по 128 опорным точкам на новой серии сохранила 160/160 решений полного метода и ускорила маршрутизацию примерно в 16 раз; по средней ошибке она сопоставима с более дорогим validation-перебором». Для утверждения о преимуществе над всеми методами данных недостаточно. Эта серия пока не добавлялась в статью.