

Neural collapse и MG при обучении классификатора изображений

29 сентября 2026. Выполненный CPU-пилот на CIFAR-10.

Результат: упрощение представлений независимо подтверждено в трёх запусках, но MG истории loss не стал надёжным индикатором этого упрощения. Преимущество над простыми альтернативами не обнаружено. Этот эксперимент пока не подходит в качестве положительного примера для статьи.

Зачем этот эксперимент

Проверяем прикладную гипотезу: можно ли по одному числу на шаг обучения дешёво следить за формированием более простой геометрии признаков. Не требуем восстановления точного числа активных компонент. Neural collapse [1] даёт независимый ориентир: признаки изображений одного класса сближаются относительно расстояния между классами; расположение центров становится регулярнее.

Кто учится, на чём и как

Обучается классификатор десяти классов CIFAR-10 [2], который получает RGB-изображение 32×32 и предсказывает класс. Это реальная задача распознавания, но уменьшенный эксперимент: 2 000 изображений для обучения и 1 000 из официальной тестовой части, строго по 200 и 100 на класс. Разбиение фиксировано, seed 20260929; подбор по качеству или MG не проводился. Дополнительные тестовые наблюдения не участвуют в градиентах.

Модель: небольшой ResNet с 78 032 параметрами. Начальная свёртка 3×3 , ширина 16; три residual-блока по две свёртки с ширинами 16/32/64, downsampling во втором и третьем блоках; BatchNorm, ReLU, global average pooling; линейная голова без bias из 64 признаков в 10 классов. Все веса обучаются с нуля.

Cross-entropy, SGD с momentum 0,9, weight decay 0,0005, **постоянный** learning rate 0,03. Batch 64, независимая равномерная выборка с возвращением на каждом шаге. 4 096 шагов, примерно 131 эквивалент прохода по подвыборке; seeds 0/1/2. Изображения нормированы, без аугментаций, без искусственного ограничения ранга и без штрафа за collapse. Нормировка RGB: mean=(0,4914; 0,4822; 0,4465), std=(0,2470; 0,2435; 0,2616).

Что получает MG и что измеряется независимо

Время — шаг SGD. MG анализирует три отдельных ряда: loss случайного обучающего batch до обновления; loss фиксированных 100 обучающих изображений после обновления; loss фиксированных 100 тестовых изображений. Оба фиксированных набора сбалансированы. Их обработка идёт в eval-режиме и не изменяет BatchNorm.

Каждые 128 шагов извлекаем все 64-мерные признаки 2 000 обучающих изображений. Пусть h_i — признак, y_i — класс, μ_c — средний признак класса, μ — среднее десяти центров; $K=10$ и $n=2000$. Вычисляем:


$$\Sigma_W = \frac{1}{n} \sum_i (h_i - \mu_{y_i})(h_i - \mu_{y_i})^\top, \quad \Sigma_B = \frac{1}{K} \sum_c (\mu_c - \mu)(\mu_c - \mu)^\top, \quad \text{NC1} = \frac{1}{K} \text{tr}(\Sigma_W \Sigma_B^\dagger).$$

Меньший NC1 означает меньший относительный внутриклассовый разброс в данной метрике. Дополнительно сохранено $\text{tr}(\Sigma_W)/\text{tr}(\Sigma_B)$. NC2 — нормированное расстояние матрицы косинусов центрированных центров до правильного симплекса; NC3 — расстояние между нормированными матрицами весов головы и центров; NC4 — доля разногласий классификатора и ближайшего центра. NC1–NC3 лучше при уменьшении, NC4 лучше при приближении к нулю. Полные определения и допуски — в коде и PROTOCOL.md.

Упрощение действительно произошло

Seed	Первый шаг с train accuracy 100%	NC1 на этом шаге → в конце	NC2 на этом шаге → в конце	Test accuracy в конце
0	1152	0,626 → 0,237	0,866 → 0,624	51,7%
1	1280	0,586 → 0,364	0,850 → 0,712	51,5%
2	1280	0,537 → 0,250	0,875 → 0,724	50,5%

После первого достижения нулевой тренировочной ошибки NC1 дополнительно уменьшился на 38–62%. К концу NC4=0 во всех трёх запусках, NC3=0,309–0,320. Это подтверждает **тенденцию к neural collapse**, но не достижение идеального симплекса: NC2 остаётся заметно выше нуля. Улучшение обобщения не продемонстрировано: тестовая точность находится около 51%.



Сплошные линии точности — train, пунктир — test. На нижней панели сплошные линии MG относятся к фиксированному обучающему набору, пунктирные — к случайным batch. У seed 1 на шагах 3328–3584 есть временный срыв train accuracy и геометрии; он сохранён в анализе, а не удалён. Поэтому период после первого нуля ошибки нельзя целиком считать устойчивой терминальной фазой.


MG не отслеживает это упрощение надёжно

Основная конфигурация зафиксирована до анализа: $W=512$ шагов, $E=20$, $\tau=1$, $k=20$ соседей, исключение Theiler=39 шагов, расчёт раз в 128 шагов. Используется исходный pooled MG из проекта. Для проверки устойчивости считаем $E=40$ при тех же τ и исключении. Ранний интервал — окна с концами на шагах 512–1024; поздний — последние 1024 шага. Таблица: поздняя медиана, делённая на раннюю.

Запуск	MG фиксированного train loss	MG фиксированного test loss	MG batch loss
Обучение, seed 0	0,788	0,735	1,233
Обучение, seed 1	0,989	0,949	1,111
Обучение, seed 2	0,924	0,768	1,130
Замороженные признаки, seed 0	0,815	0,592	1,061

В обучаемых запусках MG фиксированного train loss падает в среднем на 9,9%, но корреляции с NC1 равны 0,259; $-0,024$; $-0,158$. Среднее того же loss согласуется с NC1 сильнее: 0,741; 0,862; 0,942. У MG тестового loss корреляции 0,845; 0,110; 0,481, но корреляции первых разностей всего 0,008; 0,149; 0,018. Общего тренда недостаточно для утверждения, что MG следит за изменениями геометрии.

Главный отрицательный контроль: обучаем только линейную голову, замораживая признаки и статистики BatchNorm. Аудит сохранённых признаков даёт точное нулевое изменение. NC1=91,183 и NC2=1,972 постоянны, но MG фиксированного train loss уменьшается на 18,5%, а test loss — на 40,8%. Это не исключает изменений динамики головы; это показывает неспецифичность MG к neural collapse признаков.



Проверки $W=256/1024$ и $\tau=4$ не устранили проблему: например, при $W=1024$ поздний/ранний MG train-probe равен 0,973; 1,143; 1,001. В этом варианте раннее окно только одно, поэтому сравнение описательное. Для основного варианта позднее $MG(40)/MG(20)=1,34\text{--}1,50$; численно вырожденных окон нет. Это не даёт гарантии абсолютной размерностной интерпретации.

Стоимость и сильный дешёвый конкурент

Измерения проведены последовательно на CPU Intel Core i5-12500H; PyTorch 2.10.0+cpu, NumPy 2.4.3. Обучение и извлечение признаков: 8 потоков PyTorch, BLAS=1; MG и его соседи: 1 поток. GPU не использовался. Для MG сохранены три повтора на основное окно; для итогового контроля времени — семь вызовов, первые два исключены. Все числа ниже округлены.

Измерение	Время
MG уже записанного train-probe loss, одно окно	9–10 мс
MG с E40 и диагностикой, 29 окон	0,61–0,66 с
Полная NC-геометрия 2000 изображений, один checkpoint	257 мс
NC-геометрия 100 изображений, один checkpoint	13 мс
Простые статистики одного scalar-окна	0,2–0,5 мс

Чистый MG примерно в 26–29 раз быстрее полной проверки NC на сопоставленном checkpoint; с диагностикой — в 11–12 раз. Но для его фиксированного loss нужен forward на каждом из 4 096 шагов. Если такого лога ещё нет, сбор добавляет примерно 49–52 с; весь MG-monitor занимает около 50–53 с против 7,4–7,8 с для 29 полных проверок NC. Это **оценка полной стоимости** по повторным замерам одиночного probe-forward; фактически в обучении два probe вычислялись совместно, их измеренное время сохранено отдельно. Сам training loss дополнительного forward не требует, но его MG растёт, а не следует снижению NC1.

Ещё важнее контроль по маленькой выборке: NC1 по 100 изображениям коррелирует с полной оценкой на уровне 0,988–0,999. Его абсолютные значения смещены, однако динамика воспроизводится хорошо. Такой контроль достаточно считать только на 29 checkpoint: около 0,38 с вместе с извлечением признаков. В данной задаче он практичнее непрерывного probe-log и специфичнее MG. Победа только над полной выборкой была бы неполным сравнением.

Что следует для статьи

Положительный факт: на реальных изображениях независимо наблюдается упрощение обучаемых представлений. **Проверяемая гипотеза о MG не получила достаточной поддержки:** направление и сила отклика зависят от наблюдаемого loss и окна, похожее падение есть при неизменной геометрии, а простые альтернативы сильнее. Поэтому этот запуск нельзя добавлять как подтверждение «MG надёжно и дешевле отслеживает neural collapse».

Это не опровержение MG как анализатора других видов динамики. Neural collapse характеризует распределение признаков разных изображений в один момент; MG здесь характеризует временную последовательность loss. Связь этих объектов оказалась слабой. Следующий осмысленный шаг — отдельно проверить наблюдение, ближе связанное с представлениями, либо другую прикладную задачу; настройка окна по этим же результатам не будет независимой валидацией.

Ограничения: одна небольшая архитектура, 2 000 обучающих изображений, три инициализации на одном разбиении; только один frozen-control. CIFAR-100 и полный CIFAR-10 не запускались. Нет независимой проверки выбранных гиперпараметров на новых seeds. Перекрывающиеся окна не считаются независимыми наблюдениями; корреляции описательные, статистическая значимость не заявляется. Полную идентификацию active dimension целью не ставили.

Воспроизводимость и проверка

Исходники и результаты находятся в research_neural_collapse. PROTOCOL.md фиксирует постановку; run.py обучает, analyze.py строит MG и таблицы, benchmark.py проверяет время, build_report.py собирает отчёт. В results сохранены логи всех 4 × 4096 шагов, признаки всех checkpoint, финальные веса, индексы изображений и SHA-256 исходных batch-файлов. Для повторения команд см. README.md.

Проверены нулевые NC-метрики для идеального симплекса, инвариантность к общему масштабу и вращению, повторный расчёт финальной геометрии из сохранённых признаков, неизменность признаков frozen-control. Результаты аудита — results/audit.json. Статья и её шесть PDF не изменялись.

[1] Papayan V., Han X. Y., Donoho D. L. Prevalence of Neural Collapse during the Terminal Phase of Deep Learning Training. PNAS, 2020. DOI: 10.1073/pnas.2015509117.

[2] Krizhevsky A. Learning Multiple Layers of Features from Tiny Images, 2009. Официальные CIFAR-10 Python batches, University of Toronto.