

MG при потере информации в текстовом VAE: 10 инициализаций

Расширение серии, 29 сентября 2026. Пилот seed 0; подтверждение seeds 1–9, включая семь добавленных запусков 3–9. Все пары и исходные логи сохранены.

Основной результат: независимое событие подтверждено в 9/9 подтверждающих запусков. MG на фиксированной ошибке восстановления показал более сильное снижение, чем контроль, в 9/9, в том числе в 7/7 добавленных запусков. Медиана парного отношения $q = 0,517$; диапазон 0,430–0,599. Пилот исключён из этих чисел. Неудачные seed по основному критерию: нет.

1. Что учится и что считаем упрощением

Текстовый VAE восстанавливает предложения: encoder преобразует целое предложение в распределение скрытого кода, decoder предсказывает слова по предыдущим словам и этому коду. Проверяем ослабление роли кода при обучении. Если в коде становится мало информации о предложении, а его подмена почти не меняет предсказания, эта часть модели фактически перестаёт решать исходную задачу представления текста. Это операционное упрощение латентного механизма, не доказательство уменьшения размерности всей системы.

Данные и модель. Penn Treebank, фиксированные 6000 обучающих и 256 проверочных предложений, длина 8–24 слова плюс EOS. Словарь 2000 токенов строится по обучающей части; в проверке около 18,4% токенов представлены UNK. Embedding 48, encoder GRU 64, Gaussian latent 16, decoder GRU 64; 276016 параметров. Код подаётся в начальное состояние decoder и на каждом шаге. Teacher forcing, без dropout. Adam: learning rate 0,001, batch 32, clipping нормы градиента 5.

Loss — сумма NLL слов предложения плюс $\beta \text{KL}(q(z | x) \| \mathcal{N}(0, I))$, затем среднее по батчу. После общих 1024 обновлений при $\beta = 0,01$ создаются две ветви: **base** сохраняет коэффициент, **regularized** повышает его до 1. Обе обучаются до 3072 шагов. Веса, Adam и генератор батчей/латентного шума совпадают при развилке. Learning rate и размер кода не меняются; координаты вручную не выключаются.

2. Независимое подтверждение и наблюдатель MG

На фиксированных 256 предложениях каждые 128 шагов измеряем **взаимную информацию предложения и кода**: Monte Carlo, четыре фиксированные выборки на предложение, явная смесь 256 posterior. Это информация для конечной эмпирической смеси с потолком $\log 256 \approx 5,545$ нат, не известная популяционная величина. Вторая проверка — **перестановка кодов между предложениями** при согласованном шуме: симметризованный KL предсказаний и ухудшение reconstruction NLL.

Событие считается независимо подтверждённым, если информация и реакция на перестановку обе снижаются относительно base более чем вдвое; исходно информация выше 0,1 нат, а KL предсказаний выше 0,0001 нат/токен. Критерий не использует MG. Контроль с одинаковыми нулевыми posterior даёт нулевую информацию и нулевую реакцию на перестановку.

Вход MG: reconstruction NLL на токен на фиксированных 16 предложениях и фиксированном Gaussian noise. KL, информация и коэффициент β в ряд не входят. Окно 512, stride 128, embedding 20, delay 1, 20 соседей, Theiler 39; тренд не удаляется. Префиксы и первое наблюдение при развилке совпадают.


Сравниваем медианы пяти окон с концами 512–1024 и девяти поздних окон с концами 2048–3072. Поздние окна целиком лежат после перехода. Парный показатель q — отношение поздней медианы MG в regularized к поздней медиане в base; при общей предыстории это также отношение двух изменений «после/до». $q < 1$ означает более сильное снижение относительно контроля.

Что варьировали. Только инициализацию и случайные батчи/латентный шум обучения. Корпус, probe, модель, расписание и анализ сохранены. Seed 0 — исследовательский пилот; seeds 1–2 — первоначальное подтверждение; seeds 3–9 добавлены после запроса расширить серию. Запуски не отбирались по исходу. Статистика ниже относится к seeds 1–9; перекрывающиеся окна не считаются независимыми повторами.

3. Все десять пар и разброс эффекта

Seed	Информация: до / после, нат	MG: до / после	MG после в base	q
0 (пилот)	5,48 / 0,26	6,52 / 3,79	7,78	0,487
1	5,36 / 0,21	6,09 / 4,59	7,67	0,599
2	5,50 / 0,22	5,99 / 4,04	8,43	0,480
3 (новый)	5,50 / 0,33	6,64 / 4,14	7,87	0,527
4 (новый)	5,51 / 0,47	4,95 / 4,21	8,13	0,517
5 (новый)	5,53 / 0,43	5,62 / 4,35	8,02	0,542
6 (новый)	5,49 / 0,19	5,61 / 3,75	8,72	0,430
7 (новый)	5,52 / 0,58	5,21 / 4,36	8,15	0,535
8 (новый)	5,54 / 0,65	5,66 / 4,17	8,42	0,495
9 (новый)	5,49 / 0,16	5,90 / 3,96	7,99	0,496

«После» без уточнения относится к regularized. В девяти подтверждающих запусках информация уменьшается на 88,3–97,0%, реакция на перестановку — на 89,2–99,2%. MG в regularized снижается на 15,1–37,6%; изменение MG в base составляет +18,4–+64,2%.




Линия — медиана по seeds 1–9, полоса — межквартильный диапазон, не доверительный интервал. Серый — base, синий — regularized; вертикаль — развилка. Сверху независимые показатели, снизу входной скаляр и MG. На каждом шаге объединяются одни и те же девять seed; пилот не включён. Отдельные графики каждой пары сохранены.

Оценка разброса: медиана q по девяти подтверждающим seed — 0,517; 95% percentile bootstrap-интервал медианы — [0,480; 0,542], 20000 ресэмплирований пар seed. Для семи добавленных seed медиана — 0,517. Интервал описывает вариацию инициализаций/батчей при фиксированных данных и probe; перенос на другие корпуса им не проверяется.

4. Устойчивость, альтернативы и границы вывода

Окно, delay	Медиана q [минимум; максимум]	$q < 1$, seeds 1–9
256, 1	0,499 [0,454; 0,553]	9 / 9
512, 1	0,517 [0,430; 0,599]	9 / 9
1024, 1	0,536 [0,452; 0,594]	9 / 9
512, 4	0,898 [0,707; 1,084]	7 / 9

Основной вариант — 512, delay 1. Окно 1024 имеет только одно окно до перехода, поэтому это более слабая проверка. При delay 4 эффект может существенно ослабевать. Ни один вариант не заменял основной после просмотра результатов; полная таблица по каждому seed сохранена отдельно.



Каждая точка — одна парная инициализация. Seed 0 показан серым как пилот; пунктир после seed 2 отделяет семь добавленных запусков. Красная линия $q = 1$ соответствует отсутствию дополнительного снижения относительно base.

Наблюдатель важен. Для обычного minibatch loss диапазон q равен 0,973–1,028; $q < 1$ в 4/9 случаев. Эти значения нельзя подменять результатом фиксированного probe. Для стандартного отклонения того же фиксированного loss медиана парного отношения — 0,579, снижение относительно base в 9/9; для спектральной энтропии — 0,645, в 9/9. Это дешёвые конкуренты, поэтому преимущество MG перед существующей диагностикой пока не установлено.

Не абсолютная размерность. В основном варианте у подтверждающих seed численно вырожденных окон: 0. Отношение оценок embedding 40/20: 0,97–2,03. Численная невырожденность сама по себе не подтверждает условия размерностной интерпретации. Рекуррентность здесь не установлена. Проверка масштаба $\times 10$ пройдена; IAAFT-суррогаты не дают основания приписывать сигналу доказанное восстановление особой нелинейной геометрии.

Что подтверждено: воспроизводимость сопутствующего сигнала MG при независимо измеренном ослаблении использования кода в данной NLP-постановке. **Что ещё не проверено:** специфичность детектора, преимущество перед KL и простыми статистиками, улучшение генеративного качества, другие корпуса и LLM. Reconstruction NLL не является marginal likelihood или perplexity генерации из prior: encoder видит восстанавливаемое предложение. Следующий содержательный контроль — то же изменение регуляризации с защитой от потери использования кода.

Расчёты выполнены на CPU; часть запусков шла параллельно, поэтому времена этих запусков не используются для сравнительного benchmark. Дополнительный forward фиксированного probe имеет стоимость. Корпус и наблюдатель во всей серии одни и те же: десять seed расширяют проверку воспроизводимости, но не число независимых задач.

Источники постановки: Bowman et al., Generating Sentences from a Continuous Space, CoNLL 2016, K16-1002; He et al., Lagging Inference Networks and Posterior Collapse in Variational Autoencoders, ICLR 2019, arXiv 1901.05534. Все численные результаты получены нашими запусками. Исходный отчёт по трём seed сохранён в initial_three; основной manuscript не менялся.