

Сигнал MG при потере информации в текстовом VAE

29 сентября 2026. Один пилот и две новые инициализации; все результаты сохранены.

Результат: независимые признаки потери информации в коде подтвердились в 3 из 3 запусков. Основной MG показал более сильное снижение, чем контроль, в 3 из 3, включая 2 из 2 новых запусков. Медианное отношение к контролю — 0,487. Это проверка практического диагностического сигнала на реальном тексте; не измерение точной размерности всей модели.

1. Что учится и зачем

Текстовый VAE учится восстанавливать предложение. Encoder читает его целиком и выдаёт распределение скрытого кода; decoder предсказывает слова по предыдущим словам и коду. Код потенциально позволяет представлять предложение компактно и управлять генерацией. Если decoder обходится без информации в коде, этот механизм теряет смысл: возникает проблема posterior collapse. Проверяем, замечает ли MG такой переход по одному ряду ошибки восстановления.

Данные — реальные предложения Penn Treebank: 6000 для обучения, 256 для проверки, длина 8–24 слова плюс EOS. Словарь — 2000 токенов, построен по обучающей части корпуса; около 18,4% проверочных токенов заменены UNK. Это ограниченный NLP-пилот, не полноразмерный языковой benchmark и не LLM. Перечень предложений и SHA256 исходных файлов сохранены.

Модель: embedding 48, encoder GRU 64, Gaussian latent 16, decoder GRU 64; 276016 параметров. Код подаётся в начальное состояние decoder и на каждом шаге; используется teacher forcing, без dropout. Adam, шаг 0,001, batch 32, clipping нормы градиента 5. Обучаются все параметры.

Минимизируется сумма NLL слов предложения и $\beta \text{KL}(q(z | x) \| \mathcal{N}(0, I))$, усреднённая по батчу. После общих 1024 обновлений при $\beta = 0,01$ обучение продолжается до 3072 шагов в двух ветвях: **base** оставляет коэффициент 0,01, **regularized** повышает его до 1 — обычного веса KL в VAE. Веса, состояние Adam, батчи и случайный шум кодов в точке развилки совпадают. Learning rate не меняется. Никакие координаты кода вручную не выключаются.

2. Независимое подтверждение и вход MG

На фиксированных 256 предложениях каждые 128 обновлений измеряем **взаимную информацию предложения и кода**: Monte Carlo с четырьмя фиксированными выборками на предложение и явной смесью всех 256 posterior. Это оценка для конечной эмпирической смеси, с потолком $\log 256 \approx 5,545$ нат, не известная популяционная информация.

Вторая проверка — **перестановка кодов между предложениями** при согласованном шуме. Измеряем симметризованный KL между предсказаниями с собственным и чужим кодом, а также ухудшение NLL. Если информация падает и подмена кода почти перестаёт влиять на decoder, ослабление роли кода установлено независимо от MG. Это частичная потеря использования кода, не утверждение, что он строго не содержит информации.

MG получает только **среднюю reconstruction NLL на токен** на фиксированных 16 предложениях; выборка Gaussian noise тоже фиксирована. Значения KL, mutual information и коэффициент β в этот ряд не входят. Окно 512 шагов, stride 128, embedding 20, delay 1,20 соседей, Theiler39. Ядро метода прежнее; тренд не удаляется. Префиксы и первое наблюдение после развилки совпали, поэтому скачок коэффициента сам по себе не создаёт скачок входного скаляра.

Для сравнения берём медианы окон с концами 512–1024 и 2048–3072. Поздние окна целиком лежат после перехода. q — отношение «MG после/до» в regularized, делённое на такое же отношение в base; $q < 1$ означает более сильное снижение относительно контроля. Pilotseed0 использован для решения продолжать; seeds 1,2 запущены после фиксации протокола. Все используют один корпус и один probe.


Критерий независимого события зафиксирован заранее: информация и реакция на перестановку должны обе снизиться относительно контроля более чем вдвое; исходно информация выше 0,1 нат, а симметризованный KL выше 0,0001 нат/токен. Этот критерий не использует MG. Для известного нулевого posterior проверено, что все три независимых показателя возвращают ноль.

Источники постановки: Bowman et al., Generating Sentences from a Continuous Space, CoNLL2016, K16-1002; He et al., Lagging Inference Networks and Posterior Collapse in Variational Autoencoders, ICLR2019, arXiv1901.05534. Числа отчёта получены нашими запусками, не взяты из этих работ.

3. Что получилось

Seed	Информация: до / после, нат	MG: до / после	MG после в base	q
0 (пилот)	5,48 / 0,26	6,52 / 3,79	7,78	0,487
1 (новый)	5,36 / 0,21	6,09 / 4,59	7,67	0,599
2 (новый)	5,50 / 0,22	5,99 / 4,04	8,43	0,480

Во всех строках «после» без уточнения относится к regularized. Код теряет информацию, но decoder продолжает предсказывать текст: поздняя reconstruction NLL — около 4,42 нат/токен. Это не marginal likelihood и не perplexity генерации из prior: encoder здесь видит восстанавливаемое предложение. Без изменения β чувствительность к коду сохраняется и усиливается.



Один и тот же новый seed 1: сверху независимые показатели, снизу вход MG и сам MG. Серый — контроль, синий — усиленная регуляризация; вертикаль — развилка. Seed выбран по порядку запуска. Графики остальных запусков также сохранены.

4. Насколько устойчиво и что это даёт

Окно, delay	q для seeds 0 / 1 / 2	Снижение относительно контроля
256, 1	0,474 / 0,518 / 0,499	3 из 3
512, 1	0,487 / 0,599 / 0,480	3 из 3
1024, 1	0,503 / 0,582 / 0,500	3 из 3
512, 4	0,980 / 0,952 / 0,967	3 из 3

Окно 1024 имеет только одно предпереходное окно: его свидетельство слабее. Изменение delay может сильно менять эффект. В основном протоколе численно вырожденных окон: 0; отношение оценок embedding 40/20 лежит в диапазоне 1,00–1,91. Поэтому абсолютные значения MG не интерпретируются как число компонент. Умножение входа на 10 оценку не меняет; сравнение с IAAFT-суррогатами не даёт основания заявлять восстановление особой нелинейной геометрии.

Преимущество перед существующей диагностикой пока не доказано: KL уже вычисляется в VAE, а стандартное отклонение loss тоже различает ветви. MG обычного minibatch loss не выделил событие: $q = 1, 009–1, 015$, во всех случаях выше 1. Следовательно, существенен именно фиксированный probe. Дополнительный forward имеет стоимость; аппаратного преимущества или улучшения качества модели здесь не заявляем.

Допустимый вывод для статьи: MG на фиксированной ошибке восстановления может сопровождать независимо подтверждённое ослабление использования латентного представления при обучении текстового VAE. Нельзя пока утверждать универсальное обнаружение collapse, точное восстановление размерности, улучшение существующих методов или перенос результата на LLM. Для проверки специфичности нужен контроль, который меняет обучение, но сохраняет использование кода, например защита от collapse при том же расписании регуляризации.

Код, полные логи и правила сравнения приложены. Основная статья пока не изменялась.