

Текстовый VAE: итоговый отчёт по всем экспериментам MG

Основной результат. На реальных текстах MG, рассчитанный по одному скалярному логу реконструкции, устойчиво отражает потерю полезной информации в латентном коде. Эффект подтверждён двумя независимыми от MG диагностиками и воспроизведён на всех девяти проверочных сидах. Контроль с сохранением кода дополнительно подтверждает содержательность сигнала. Преимущество здесь — информативный анализ лога без доступа к внутренним представлениям; превосходство над всеми альтернативами не установлено.

1. Что обучается и зачем

Обучается **текстовый вариационный автоэнкодер (VAE)**. Энкодер читает предложение и строит распределение скрытого кода. Декодер получает код и предыдущие правильные слова, после чего предсказывает следующее слово. Цель — реконструировать текст и одновременно приблизить распределение кода к стандартному нормальному. Возможный сбой: декодер начинает обходиться предыдущими словами и почти перестаёт использовать код. Тогда представление теряет информацию о предложении. Именно это, а не уменьшение размера модели, мы называем упрощением в данном сетинге.

Практическая мотивация — замечать потерю полезного латентного представления по доступной кривой обучения, а специализированные проверки выполнять реже. Здесь проверены отдельно связь MG с этим явлением и пригодность MG для назначения дорогих проверок.

Компонент	Точная постановка
Данные	Penn Treebank: фиксированные 6000 обучающих и 256 проверочных предложений длиной 8–24 слова, затем EOS. Словарь 2000 токенов построен только по обучающим данным.
Модель	Общие эмбединги 48; энкодер GRU 64; диагональный гауссовский код размерности 16; декодер GRU 64. Код задаёт начальное состояние декодера и подаётся на каждом шаге. Всего 276 016 параметров.
Обучение	Adam, шаг 0.001, батч 32, ограничение нормы градиента 5; teacher forcing, без dropout. Обучаются все параметры; координаты кода не удаляются.
Функция потерь	Сумма NLL по токенам предложения плюс взвешенный KL, затем усреднение по предложениям. Вес KL обозначен ниже как β .

$$\mathcal{L}_\beta = \frac{1}{B} \sum_{i=1}^B \left[- \sum_t \log p_\theta(x_{it} \mid x_{i,<t}, z_i) + \beta D_{\text{KL}}(q_\phi(z \mid x_i) \parallel \mathcal{N}(0, I)) \right], \quad z_i \sim q_\phi(z \mid x_i).$$

Здесь B — размер батча, x_i — предложение, t — позиция слова; ϕ и θ — параметры энкодера и декодера. **Качество реконструкции с кодом полного предложения не является качеством генерации из априорного распределения или perplexity обычной языковой модели.**

2. Какие эксперименты вошли в сводку

Серия	Проверяемый вопрос	Объём
Подавление кода	Падает ли MG при независимо подтверждённой потере информации?	Пилот 0, проверка 1–9; две парные ветки до 3072 шагов.
Сохранение кода	Отличает ли MG потерю информации от её сохранения при том же весе KL?	Третья ветка тех же 10 инициализаций; неудачный пилот encoder5 также сохранён.
Циклическое обучение	Помогает ли MG назначать проверки потери и восстановления информации?	Новый пилот 100, проверка 101–109; по 7168 шагов.

Всего **20 различных инициализаций**, из них **18 проверочных**, на одном наборе данных и одной архитектуре. Дополнительная ветка сохранения не считается новой независимой выборкой. Первые три запуска и последующее расширение до десяти объединены без повторного учёта; архивные версии отчётов не являются отдельными экспериментами. Новое обучение для этой сводки не запускалось.

3. Что измеряем: один лог и независимые проверки

Вход MG. Перед каждым обновлением записывается средний NLL реконструкции на токен на одних и тех же 16 проверочных предложениях. Гауссовский шум для кода также фиксирован (сид 829). Таким образом, меняется модель, а не состав контрольного батча. В этот скаляр не входят вес регуляризации, KL, взаимная информация или результаты замены кода. Лог не сглаживается и не очищается от тренда.

Конфигурация MG. Окно 512 обновлений; задержка 1; максимальное вложение 20; 20 соседей; исключение временно близких точек в пределах 39 отсчётов (Theiler). Окна сдвигаются на 128 шагов, а в циклической серии — на 64. Вложение 40 служит дополнительной диагностикой. Эти параметры не перенастраивались на проверочных сидах.

Независимое свидетельство упрощения. На 256 проверочных предложениях измеряются две разные вещи: сколько информации код хранит о предложении и насколько предсказания декодера зависят от соответствия кода предложению.

Показатель	Как вычисляется и что означает снижение
Взаимная информация MI	По 4 фиксированным выборкам из каждого из 256 постериоров; плотность смеси рассчитывается явно. Снижение означает меньшую различимость предложений по коду в этой конечной смеси. Потолок — $\log 256 \approx 5.545$ нат; это не MI всей популяции текстов.
Реакция на замену кода	Постериоры циклически переставляются между предложениями при согласованном шуме. Измеряется симметричный KL между предсказаниями правильного и чужого кода, в натах на токен. Снижение означает меньшую зависимость предсказаний от соответствующего кода.
Дополнительные проверки	Штраф NLL за замену кода, KL к априорному распределению и число активных координат по порогу дисперсии 0.01. Последнее не принимается за истинную размерность динамики.

4. Парное обучение: MG отражает потерю информации

Первые 1024 обновления общие, $\beta = 0.01$. Затем из одинаковых весов, состояния Adam и генераторов батчей/шума запускаются две ветки: **базовая** сохраняет $\beta = 0.01$, **регуляризованная** переходит к $\beta = 1$. Обе продолжают до 3072 шагов. Никакие параметры не обнуляются вручную.

Ранний уровень MG — медиана пяти окон с концами 512–1024; поздний — медиана девяти окон с концами 2048–3072. Поздние окна целиком лежат после вмешательства. Для эталонных показателей используются медианы на тех же ранних и поздних интервалах, с измерениями каждые 128 шагов. Благодаря общей предыстории парный контраст равен отношению поздних MG:

$$q = \frac{\text{median}(\text{MG}_{\text{regularized,late}})}{\text{median}(\text{MG}_{\text{base,late}})}.$$

Результат: 9/9. На каждом проверочном сиде MI и реакция на замену кода сократились более чем вдвое относительно базовой ветки. На всех девяти MG также снизился и оказался ниже базовой ветки. Медиана $q = 0.517$, диапазон 0.430–0.599; 95%-й bootstrap-интервал медианы [0.480; 0.542]. Это примерно двукратное различие между ветками, а не заявление о двукратном уменьшении истинной размерности.

Относительно собственной предыстории MI регуляризованной ветки уменьшилась на 88.3–97.0%, реакция на код — на 89.2–99.2%, MG — на 15.1–37.6%. При этом MG базовой ветки вырос на 18.4–64.2%. Все семь дополнительно запущенных сидов 3–9 воспроизвели исходное наблюдение. Интервалы построены по сидами, а не по перекрывающимся окнам: 20 000 bootstrap-повторов при фиксированных данных и контрольном батче.

5. Контроль сохранения: MG различает три режима обучения


Чтобы проверить, не объясняется ли результат одним изменением коэффициента β , добавлена третья ветка из тех же контрольных точек 1024. В ней $\beta = 1$, как при подавлении кода, но применяется **free bits**: средний по батчу KL каждой из 16 координат снизу ограничивается 0.5 нат перед суммированием. Ниже этого уровня KL не создаёт градиент, подавляющий координату. Это изменение функции потерь, а не жёсткая гарантия сохранения MI.

Сначала на пилоте 0 проверили пять дополнительных шагов энкодера на один основной шаг (**encoder5**). Это не защитило код: MI упала с 5.48 до 0.52 нат, реакция на код — с 0.569 до 0.040. После этого free bits выбраны по независимым диагностикам пилота, до просмотра MG этой ветки. Проверка на сидах 1–9 проводилась с фиксированной настройкой.

Критерий сохранения: поздние MI и реакция на код должны составлять хотя бы половину ранних уровней и превышать соответствующие показатели подавленной ветки минимум вдвое. **Все 9/9 сидов прошли этот критерий; на всех 9/9 MG выше подавленной ветки и ближе к базовой.**

Поздняя медиана по 9 сидам	Базовая ветка	Подавление кода	Free bits
MI, нат	5.545	0.327	3.934
Реакция на замену кода, нат/токен	2.087	0.021	0.599
MG	8.129	4.172	5.491
Медиана парного MG / базовый MG	1.000	0.517	0.639


Медиана отношения MG сохранённой ветки к подавленной — **1.286**, 95%-й bootstrap-интервал [1.179; 1.418]. Сохранение частичное: ни независимые показатели, ни MG не возвращаются полностью к базовым уровням. Отношение медиан в таблице не обязано совпадать с медианой парных отношений.



На рисунке показан первый проверочный сид, без выбора «самого красивого». Вертикальная линия — разветвление на шаге 1024. MG получает только скалярный NLL; две левые панели не используются для его вычисления.

Преимущество этого контроля. При одинаковом внешнем весе KL метод различает две ветки с разной сохранностью латентной информации. Это усиливает интерпретацию MG как индикатора содержательного изменения обучения. Контроль не отделяет влияние всех деталей функции потерь и не доказывает причинную связь каждого колебания MG с MI.

6. Воспроизводимость, окна и выбор наблюдаемого лога



Окно / задержка	Подавление: медиана q	Правильное направление	Сохранение: MG / подавление
256 / 1	0.499	9/9	1.299; выше в 9/9
512 / 1 (основная)	0.517	9/9	1.286; выше в 9/9
1024 / 1	0.536	9/9	1.254; выше в 9/9
512 / 4	0.898	7/9	1.285; выше в 9/9

При задержке 4 исключение Theiler также увеличивается до 156; это чувствительность совместной настройки, а не чистый эффект одной задержки. Для окна 1024 есть только одно раннее окно. Устойчивость к размеру окна подтверждена в проверенном диапазоне, устойчивость ко всем задержкам — нет.

Лог важен. На обычном NLL случайного обучающего мини-батча парный MG изменился в нужную сторону лишь на 4/9 сидов; отношения лежат в диапазоне 0.973–1.028. Положительный результат относится к фиксированному контрольному батчу. Перенос на произвольный уже имеющийся loss-log не установлен.

Сильные простые альтернативы. Стандартное отклонение того же контрольного лога и его спектральная энтропия также различили подавление на 9/9 сидов. Для сохранения кода STD выросло на 9/9, энтропия — на 7/9. Поэтому повторяемость результата MG доказана, а его уникальность относительно дешёвых статистик — нет. Контроль умножением лога на 10 пройден; суррогаты IAAFT не установили особого преимущества нелинейной геометрии. В основных окнах не было вырождения, однако рекуррентность и абсолютная размерная интерпретация не подтверждены.

7. Циклический VAE: проверка практического мониторинга

На новых инициализациях 100–109 после 1024 шагов разогрева проведены три цикла по 2048 обновлений: β линейно растёт от 0 до 1 в первой половине и остаётся 1 во второй; затем сбрасывается. Всего 7168 шагов. Free bits здесь нет. MG не управляет обучением: по сохранённым логам воспроизводятся решения наблюдателя, использующего только прошлые данные.

Независимые проверки выполнялись каждые 64 шага. Событие потери — обе диагностики не выше 50% раннего уровня; восстановления — обе не ниже 65%. Требуются два последовательных подтверждения, время события — второе из них. На девяти проверочных сидах получено **41 событие: 23 потери и 18 восстановлений** с полным горизонтом оценки 512 шагов; ещё два поздних события учитываются отдельно.

Наблюдатель запрашивает дорогую проверку при достаточно большом абсолютном изменении логарифма своего признака относительно последнего запроса, с паузой минимум 128 шагов. Пороги выбирались только на пилоте 100 из заранее заданной сетки и отдельно для бюджетов 6, 12, 24; основной бюджет — 12. Все методы получают одну общую начальную проверку. Попадание засчитывается в пределах 512 шагов после подтверждения события и до противоположного перехода. Повторные проверки одного события не дают дополнительных попаданий.

8. Где MG полезен, а где мониторинг пока проигрывает

Метод назначения проверок	Бюджет 6: найдено / 41	Бюджет 12: найдено / 41	Бюджет 24: найдено / 41
MG	18	28	36
STD контрольного лога	13	20	38
Спектральная энтропия	17	28	35
KL из обучения	8	13	31
Изменение расписания β	18	18	26
Равномерные проверки	12	38	40

При шести проверках MG находит больше событий, чем равномерная схема: 18 против 12, включая и потерю (8), и восстановление (10). Но тот же общий результат даёт расписание β за счёт обнаружения восстановлений. При основном бюджете 12 MG находит 28/41, а периодические проверки — 38/41. MG использует в среднем 9.4 запроса; даже при точно таком же числе запросов на каждом сиде периодическая схема находит 34 события. Разница средней по сидам полноты MG и основной периодической схемы — 24.4 процентного пункта, 95%-й bootstrap-интервал $[-36.7; -10.0]$.

Следовательно, **связь MG с потерей информации подтверждена сильнее, чем выгода от его использования для назначения проверок**. На данном регулярном циклическом расписании преимущество по полноте мониторинга не показано.

9. Вычислительная стоимость: обработка и получение лога

Последовательный прогретый CPU-бенчмарк: 40 чередующихся повторов, 2 потока PyTorch и 1 поток оценщика. Медиана расчёта одного окна MG — **12.89 мс**, комплексной проверки MI и замены кода — **209.32 мс**, получения одного контрольного NLL — 7.13 мс. Обработка уже записанного окна MG примерно в **16.2 раза дешевле одной специализированной проверки**. Это сравнение операций, а не равной точности или сквозного ускорения мониторинга.

Затраты на запуск, бюджет 12	С получением лога, с	Если нужный лог уже есть, с
MG и запрошенные проверки	54.68	3.54
STD и запрошенные проверки	53.86	2.73
Энтропия и запрошенные проверки	53.59	2.45
KL и запрошенные проверки	2.72	2.72
Равномерные 12 + 1 проверки	2.72	2.72
Частые 96 + 1 проверки	20.30	20.30

Это расчёт из измеренных стоимостей операций и фактического числа запросов, усреднённого по девяти сидам, без стоимости самого обучения. Получение 7168 контрольных значений стоит около 51.14 с и доминирует. Для MG учтены 105 окон и запрошенные проверки, включая начальную. Оценочные эталонные измерения, нужные для разметки событий, не выдаются за эксплуатационную экономию. На машине могла идти сторонняя работа; параллельные времена обучения не используются для сравнения скорости.

10. Подтверждённые преимущества и вывод для статьи

Информативность одного скаляра: MG отражает независимо установленную потерю информации без чтения скрытых представлений и без включения MI/KL в свой вход. **Воспроизводимость:** направление эффекта сохранено на 9/9 проверочных инициализаций и трёх размерах окна. **Содержательный контроль:** частичная защита кода сопровождается более высоким MG на тех же 9/9 сидах. **Небольшая стоимость обработки:** около 13 мс на окно уже доступного лога в локальном бенчмарке.

Подходящая формулировка для статьи: «В обучении текстового VAE оценка по скалярному логу реконструкции устойчиво отражает потерю латентной информации, подтверждённую взаимной информацией и реакцией декодера на замену кода. Контроль с сохранением информации и повторения по инициализациям поддерживают применение метода как индикатора изменений обучения».

Границы вывода: одна небольшая модель и один корпус; точное число активных компонент не установлено; ухудшение латентного представления не является улучшением модели. Превосходство над простыми статистиками, сквозное ускорение и перенос на LLM не показаны. Все ветки, неудачная защита encoder5, чувствительности и бюджеты включены в эту сводку; подробные числа и происхождение данных приложены в архиве.