

MG по скалярному логу как дешёвый детектор упрощения обучения: что работает. Итоговый отчёт

Проект 202, эксперименты 29 сентября — 1 октября 2026

Коротко

Метод по теории считает число активных компонент детерминированного возвратного режима, и на синтетических системах так и происходит. На реальном обучении его прикладная роль скромнее и практичнее: **дешёвый детектор упрощения**, который работает по одному уже записанному логу. Ниже собрано, что эту роль подтвердили эксперименты этой серии: MLP на digits, свёрточная сеть на CIFAR-10 и ResNet-18 на полном CIFAR-10. Упрощение в каждом случае установлено независимо — построением события или дорогим измерением по всем весам.

1. **Явные события упрощения в обучении CNN.** Заморозка сети, прунинг, сильный спад learning rate дают $-12 \dots -19\%$ MG; контроли без упрощения — $0 \dots +13\%$. Разделение: AUC 0.93, для сильнейших доз 0.99. Простые статистики того же логa дают $AUC \approx 0.5$. Результат повторён на сидах, которые не участвовали в выборе настроек.
2. **Онлайн-детектор.** Порог выбран на одних сидах и проверен на других: **27 из 28** запусков с сильным упрощением пойманы, **0 из 16** ложных тревог, задержка около 1 000 шагов. Детекторы на простых статистиках ложно срабатывают в 31–62 % запусков без упрощения.
3. **Специфичность.** MG не реагирует на масштаб логa и не принимает за упрощение ни сглаживание логa, ни уменьшение шума градиента. На ResNet-18 — **0 ложных тревог в 24** запусках без упрощения при **6 из 6** пойманных заморозках ($-28 \dots -31\%$).
4. **Информация сверх спектра.** На логe нормы параметров MG заметно ниже, чем у суррогата с тем же спектром (отношение 0.78–0.80), и его сдвиг при событиях суррогат не повторяет. В полно-батчевом обучении с большим шагом отношение 0.51–0.66, и MG устойчив к сглаживанию логa, а спектральные статистики — нет.
5. **Цена.** 5–10 мс на окно логa; лог нормы параметров не требует ни одного прохода сети и занимает десятки килобайт. Дорогие эталоны требуют хранить все веса (450–560 МБ на запуск) или десятки произведений Гессияна на вектор на каждый чекпойнт.

1 Что значит «работает» и как это проверялось

Что меряется. Оценка MacKay–Ghahramani по delay-реконструкции одного скаляра (реализация проекта без изменений ядра), в скользящих окнах. Сравнивается её значение до события упрощения и после, либо её ход во времени с независимо измеренным упрощением.

Независимое подтверждение упрощения.

- *по построению* — число обучаемых или ненулевых параметров, шаг оптимизатора;
- *дорогим измерением* — PR ковариации обновлений всех весов (на ResNet-18 через CountSketch); доля движущихся параметров; средний размер обновления.

Контроли, где упрощения нет. Масштаб логa (MG обязан не измениться); сглаживание логa при той же траектории; увеличенный батч — меньше шума градиента при тех же движущихся параметрах. Детектор, который путает эти случаи с упрощением, бесполезен на практике.

Защита от подгонки. Протоколы с предсказаниями записывались до запусков (docstring скриптов, PROTOCOL.md). Выбор наблюдателя и настроек делался на одних сидах, проверка — на других. Сравнение идёт с простыми статистиками того же лога (пересечения тренда, автокорреляция, разброс), откалиброванными тем же способом.

2 Где у MG есть своя информация (MLP, digits)

Первые два эксперимента проверяли, что именно MG видит в логе обучения. Сеть — MLP 64–64–64–10 на sklearn digits. Для каждого окна считалось отношение MG к MG IAAFT-суррогата — ряда с тем же спектром, но без нелинейной структуры.




Рис. 1: Слева и в центре — отношение после/до для PR траектории всех весов и для MG лога loss при событиях под SGD. Справа — отношение MG к MG суррогата: под SGD около 1, в полнобатчевом режиме с большим шагом — заметно ниже 1.

- **Под SGD MG ранжирует события правильно.** Спад lr и заморозка, при которых PR траектории падает вдвое, снижают MG лога loss (AUC 0.99, корреляция отношений с эталоном $\rho = 0.85$). Масштаб лога и меньший шум MG не снижают.
- **В детерминированном режиме у MG есть информация сверх спектра.** При полнобатчевом обучении с большим шагом loss колеблется сам, без шума выборки, и MG в 1.5–2 раза ниже суррогатного. Сглаживание лога меняет MG слабо (0.87–1.15), а MG суррогата и пересечения тренда падают (0.62–0.80 и 0.27–0.56). Здесь MG видит то, чего не видят спектральные статистики.

Эти наблюдения определили следующие шаги: эталоном должно быть движение весов, а наблюдателем — лог, в котором сохраняется нелинейная структура. Таким наблюдателем оказалась норма параметров.

3 Явные события упрощения в обучении CNN (CIFAR-10)

Постановка. Свёрточная сеть (14666 параметров), CIFAR-10 (10 000 изображений), SGD с momentum. На шаге 4000 из 10 000 — одно событие. Наблюдатель — норма всех параметров: считается по уже имеющимся весам за $O(P)$, без прохода сети. Настройки (конфигурация статьи $E = 20$, $k = 20$, окно 1 000 шагов) выбраны на сидах 0–3 и затем проверены на новых сидах 10–13.

событие	MG до → после	изменение (разброс по сидам)	PR обновлений	движется
без события	4.31 → 4.32	+0.4 % (−8.7 ... + 3.3)	+40 %	100 %
батч ×4 (меньше шума)	4.31 → 4.85	+12.8 % (+8.3 ... + 13.9)	−7 %	100 %
лог ×10 / лог сглажен	4.31 → 4.32 / 4.44	+0.4 / +3.4 %	—	—
lr /10	4.31 → 3.95	−8.3 % (−12.1 ... − 2.3)	−22 %	100 %
lr /100	4.31 → 3.85	−11.5 % (−14.4 ... − 7.3)	−21 %	100 %
обучается только голова	4.31 → 3.51	−18.5 % (−24.1 ... − 11.2)	−43 %	2.2 %
обучается только bias головы	4.31 → 3.58	−16.7 % (−23.7 ... − 15.0)	−68 %	0.07 %
прунинг 50 %	4.31 → 3.80	−12.7 % (−14.5 ... − 3.9)	+15 %	50 %
прунинг 80 %	4.31 → 3.59	−17.5 % (−20.7 ... − 12.3)	−10 %	20 %
прунинг 95 %	4.31 → 3.79	−11.5 % (−16.1 ... − 9.5)	−45 %	6 %

Таблица 1: Медиана по 4 новым сидам. PR обновлений и доля движущихся параметров — дорогое независимое подтверждение: для них нужны все веса на каждом шаге.




Рис. 2: Изменение MG после события по каждому запуску. Серый фон — контроли без упрощения. Справа — против изменения PR обновлений всех весов.

Что в этом хорошего.

- **Все сильные события** (lr/10, lr/100, заморозка, прунинг) снижают MG; контроли его не снижают. При этом уменьшение шума (батч×4) сдвигает MG *вверх*, так что метод отличает «меньше направлений» от «меньше шума».
- **Доза и ответ.** Внутри семейства спада lr ($\rho = -0.83$) и заморозки (-0.68) эффект растёт с силой упрощения. Изменение MG согласуется с изменением PR обновлений всех весов ($\rho = 0.59$ по всем запускам).
- **Преимущество над простыми статистиками.** AUC «событие против контроля»: MG 0.93, для сильнейших доз 0.99. Пересечения тренда, автокорреляция и разброс того же логга дают 0.48–0.67.
- **Нелинейная информация.** MG заметно ниже, чем у суррогата с тем же спектром (отношение 0.78), а сдвиг MG при событиях не повторяется у суррогата (AUC 0.68 против 0.93). Метод видит в логге структуру, которой нет в спектре.

4 Онлайн-детектор

На практике момент события неизвестен, поэтому нужен монитор, который сам поднимает тревогу. Правило: медиана MG последних 2 окон сравнивается с медианой 3 окон перед ними, тревога — при падении больше чем на 8.8%. Порог выбран на сидах 0–3 так, чтобы там не было ни одной ложной тревоги, и без изменений применён к сидам 10–13.

детектор на	сильные события пойманы	ложные тревоги без упрощения	задержка
MG	27/28	0/16	1 000 шагов
разброс логга	28/28	10/16	500 шагов
пересечения тренда	15/28	5/16	1 000 шагов
автокорреляция	0/28	0/16	—

Только MG одновременно ловит почти все сильные упрощения и ни разу не срабатывает без причины. Разброс логга ловит всё, но срабатывает и на масштабировании логга, и на обычном обучении.

5 ResNet-18 на полном CIFAR-10: заморозка без ложных тревог

ResNet-18 (11 млн параметров) обучалась на полном CIFAR-10 в двух сценариях: с нуля и дообучение ImageNet-предобученной модели — типичный сценарий transfer learning. Протокол записан до запуска; настройки MG и правило детектора перенесены без изменений с малой CNN.

- Заморозка всего, кроме головы, снижает MG на **27.6 %** при обучении с нуля и на **30.8 %** при дообучении. Детектор с порогом, выбранным ещё на малой CNN, ловит её **в 6 из 6** запусков.




Рис. 3: Статистика детектора по всем тестовым запускам. Пунктир — порог -8.8% , выбранный на других сетах.




Рис. 4: MG лог нормы параметров ResNet-18. Заморозка всего, кроме головы (красная линия), видна сразу и в обоих сценариях.

- Ни одной ложной тревоги в 24 запусках без упрощения (без события, меньший шум, масштаб и сглаживание лог, оба сценария).
- Правило детектора перенеслось с сети в 15 тыс. параметров на сеть в 11 млн без повторной калибровки.

6 Цена

что нужно	цена
MG одного окна лог (500–1 000 точек)	5–10 мс на CPU
лог нормы параметров	$O(P)$ на шаг, без прохода сети; 31–39 КБ на запуск
эффективный ранг / PR траектории или обновлений	все веса на каждом шаге: 450–560 МБ на запуск малой CNN; 180–300 мс на окно
PR обновлений ResNet-18 через CountSketch	1 024 числа на шаг вместо 11 млн, но скетч надо считать на каждом шаге обучения
верхние собственные значения Гессмана	≈ 100 мс и ≈ 60 произведений Гессмана на вектор на чекпойнт

7 Как формулировать в статье

По теории оценка считает число активных компонент детерминированного возвратного режима, и на синтетических системах так и происходит. На реальном обучении та же оценка по одному уже записанному скалярному логу — норме параметров — работает как дешёвый детектор упрощения. При явных событиях упрощения в обучении свёрточной сети (заморозка, прунинг, спад learning rate) она снижается на 12–19%, не реагируя на масштаб лог, его сглаживание и уменьшение шума градиента; простые статистики того же лог эти события не отделяют. Онлайн-детектор с порогом, выбранным на других запусках, ловит 27 из 28 таких событий без ложных тревог, а на ResNet-18 — заморозку сети во всех запусках, тоже без ложных тревог. Теория и синтетика позволяют читать изменение оценки как относительное

изменение числа активных направлений, хотя абсолютное значение размерностью не является.

8 Границы применимости

Чтобы формулировка выдерживала вопросы рецензентов, эти ограничения надо указать явно. Все они описаны подробно в `research_trajectory_reference/report/`.

- **Не размерность.** Абсолютное значение MG на реальном обучении размерностью не является: отношение идентифицируемости ≈ 1.5 . Метод работает как относительный сигнал «до/после».
- **Нужны явные упрощения.** Слабые события ($lr/3$, заморозка двух первых слоёв) не ловятся.
- **Выбор лога важен.** Loss мини-батча бесполезен. MG по loss на фиксированной выборке сводится к спектру и ложно срабатывает при сглаживании. Рабочий наблюдатель — норма параметров.
- **Масштаб.** На ResNet-18 норма всей сети превращается в гладкую кривую, и MG ловит только заморозку. Спад lr и прунинг он не видит, а более шумные наблюдатели (случайные проекции, нормы слоёв) дают ложные тревоги. Пример с CNN — это малая модель.
- **Edge of stability.** Число колеблющихся мод Гессмана MG не считает: связь обратная.

Где лежат материалы

- CNN, детектор, ResNet: `research_trajectory_reference/`
(`cifar_graded.py`, `detector.py`, `colab_resnet/`, `e7b_analyse.py`); полный отчёт по всем экспериментам, включая отрицательные, — `report/report_all_ru.pdf`;