

Walker2d: три попытки обучить более повторяемую походку

Результат и смысл проверки

Продолжено направление управления движением: после неоднозначного опыта со сглаживанием команд проверены имитация эталонной походки без фазы, слежение с известной фазой и исправление масштаба штрафа слежения. Проведено 17 обучений по 1048576 переходов каждое. Пилот расширенного штрафа прошёл отбор; выполнены все пять подтверждающих пар. Все неудачные варианты сохранены; разные настройки одного пилота не являются независимыми подтверждениями.

Главный итог: независимый критерий улучшения выполнен в 2/5 подтверждающих парах. В seed271 MG снизился при всех пяти настройках; в seed275 снижение по правому колену небольшое, по левому наблюдается рост. Получен убедительный отдельный пример, но устойчивое подтверждение для всей серии пока отсутствует.

Цель — получить воспроизводимое движение всего тела при сохранении ходьбы и затем проверить, обнаруживает ли изменение MG по одному углу колена. Ошибка относительно эталона непосредственно оптимизируется; её снижение само по себе не считается независимым подтверждением упрощения. Отдельно проверяются возвраты полного состояния, разброс между циклами, реакция на возмущения и дешёвые скалярные показатели.

Кто и чему обучается

Политика PPO управляет шестью суставными приводами Walker2d-v5. Исходная награда — скорость вперёд плюс 1 за здоровое состояние минус $0.001\|a_t\|^2$. Физическое падение завершает эпизод. К награде добавлен штраф за отклонение от эталона; MG в обучении не используется. Идея обучения по образцу движения известна, например, из DeepMimic (Peng и др., 2018); здесь собственный небольшой опыт, не воспроизведение этого алгоритма.

Эталон взят из старой исходной политики: validation-запись reset41001, seed210, до дообучения. Период 152 шага выбран по минимуму ошибки возврата; среди первых 2048 отсчётов выбран физически наблюдавшийся цикл с минимальным разрывом концов (начало 881, норма разрыва 0.065). Состояние x_t состоит из восьми положений/углов без абсолютного горизонтального положения и девяти скоростей; позиции масштабируются на 1, скорости на 5. Сохранены все точки эталона и хеш исходной записи. Это приближённый цикл, не доказанная периодическая орбита.

А. Имитация без внешней фазы. Политика получает обычные 17 координат наблюдения и стартует из стандартного положения Walker2d. Штраф определяется расстоянием до ближайшей точки эталона. Часов, фильтра действий и принудительной проекции на эталон нет. Пилот seed240: одинаковый контроль $\lambda = 0$ и два штрафа $\lambda = 1, 3$.

В. Слежение с известной фазой. Политика получает ещё sin/cos фазы и стартует около случайной точки эталона. Начальные шумы: ± 0.002 по позициям и ± 0.01 по скоростям. Штраф считается до точки эталона в заданной фазе, а не ближайшей. Это **локальное удержание походки**, другая задача по отношению к разгону из вертикального положения. Обе ветки имеют одинаковую фазу и сбросы. Внешний фазовый сигнал также означает, что система уже не автономная. Пилот seed260: $\lambda = 0, 3$.

В фазовых опытах фаза увеличивается на $\rho = 1/(1 + \sqrt{2}/1000)$ исходного кадра за шаг. Период равен примерно 152.215 шага; небольшая заранее заданная расстройка предотвращает искусственно точные повторы из-за целочисленного периода. Эталон интерполируется линейно, скорости умножаются на ρ . Физика во время исполнения не корректируется по эталону.

С. Исправление масштаба слежения. У В штраф в обучении почти насыщался (около 0.98). Поэтому в отдельном опыте seed270 его масштаб установлен по медиане пяти validation-ошибок контрольной политики В: $\sigma^2 = 38.477$. Сама задача и коэффициенты 0/3 не менялись. Новый масштаб выбран до MG этого опыта, по старой validation-части; тестовые записи не использовались.

Точные условия и измерения

Во всех вариантах обучение использует штраф

$$r'_t = r_t - \lambda \left(1 - \exp \left[-\frac{e_t^2}{2\sigma^2} \right] \right).$$

В А e_t^2 — квадрат расстояния до ближайшего эталонного состояния, в В/С — до эталонного состояния соответствующей фазы после шага физики. В А/В $\sigma^2 = 0.116779$ из старой калибровочной записи. В С штраф стал различать обычные посещаемые состояния; это исправляет насыщение, но не гарантирует успешного слежения.

На запуск: 8 сред, rollout512 на среду, batch256, 5 эпох PPO, learning rate $3 \cdot 10^{-5}$ до $3 \cdot 10^{-6}$, clip0.1, target KL0.01, $\gamma = 0.99$, GAE0.95, entropy0, value weight0.5, gradient clip0.5, лимит 5000 шагов. Actor/critic — отдельные 64–64 tanh сети. В А сохранены старые веса и Adam; в В/С добавлены нулевые входные веса фазы и одинаково сброшен Adam. Начальные действия проверены на совпадение. Статистики нормировки наблюдений и наград заморожены. Снимки каждые 131072 перехода после обновления; финал выбирается по бюджету, не по лучшему MG.

Validation: по 5 новых сбросов на последних трёх снимках; тест —10 других сбросов. А:71001–71005/72001–72010; В:73001–73005/74001–74010; С:75001–75005/76001–76010. На запись:512 шагов разогрева и 4096 измерения, шаг 0.008с. TimeLimit снят, физические падения сохранены. Общая награда равна сумме после разогрева, делённой на 4096; после падения остаток нулевой. Для сравнения MG нужны полный здоровый эпизод, скорость не ниже 0.5, стандартное отклонение правого колена не ниже 0.05 и не менее 8 пиков. Для D нужны не менее 8 пересечений.

Независимые показатели. R — минимум нормированной квадратичной ошибки $x_{t+p} - x_t$ по лагам 20–250 (деление на удвоенную дисперсию полного состояния). D в А — нормированная дисперсия состояния при пересечении фиксированной плоскости через четверть эталонного цикла, в положительном направлении, с фазовым и временным ограничениями. В В/С D — дисперсия состояния при одинаковой известной фазе 0, с линейной интерполяцией между отсчётами. Это проверка повторяемости, не точное число активных компонент. Старый показатель по максимумам колена также сохранён, но не заменяет новое сечение.

Для расширения пилота требовались не менее 4 здоровых общих validation-записей, исходная награда не ниже 90% контроля, обе медианные величины R,D не выше 80% контроля. Дополнительно исходные R не ниже 0.02 и D не ниже 0.01 в А /0.001 в В,С. Сильный тестовый результат требует не менее 8 общих записей, обоих отношений не выше 0.75 и сохранения награды/числа успешных эпизодов. Отсутствие такого события не доказывает отсутствия любого другого вида упрощения.

MG. Измеряется движение фиксированной финальной политики, а не loss во время обучения. Сигнал — угол правого колена, окно 2048, задержка 8,20 координат вложения,20 соседей, исключение соседей ближе 312 шагов по времени. Три окна с концами 2048,3072,4096, seed123. Проверено 40 координат как диагностика. Заранее сохранены варианты: левое колено, задержки 4/16, окно 14 циклов. В А цикл определяется по полному состоянию (диагностика с дополнительной информацией), в В/С задан внешними часами. Ни одна настройка не выбрана по желаемому знаку MG.

Фактические результаты

Все дробные числа — медианные отношения экспериментальной ветки к её контролю по общим пригодным записям; меньше 1 означает снижение. Награда включает все 10 эпизодов и падения. n — число общих пригодных записей; при n меньше 8 сравнение только описательное. Ходьба С/Т — число здоровых завершений из 10 у контроля/вмешательства. Значения D разных постановок имеют разные определения; сравнивать их абсолютную величину нельзя.

Постановка	n	Ходьба С/Т	Награда	R	D	MG
Без фазы, $\lambda=1$	10	10/10	0.991	2.088	6.321	1.022
Без фазы, $\lambda=3$	7	10/9	0.883	1.053	0.691	0.919
Фаза, узкий	9	10/9	0.910	0.746	1.015	1.053
Фаза, широкий s271	10	10/10	1.005	0.532	0.074	0.872
Фаза, широкий s272	9	9/10	1.074	0.546	1.055	1.159
Фаза, широкий s273	10	10/10	0.980	0.297	1.189	0.913
Фаза, широкий s274	9	10/9	0.900	1.119	0.104	1.087
Фаза, широкий s275	10	10/10	0.988	0.682	0.482	0.975

В А слабый штраф дал R в 2.09 раза и D в 6.32 раза выше контроля при практически сохранённой награде. Более сильный штраф уменьшил разброс сечения, но не ошибку возврата и потерял часть награды. Оба варианта не прошли validation-отбор; десять сбросов одного сида не являются десятью независимыми обучениями.

В В на тесте R составил 0.746 от контроля, D — 1.015, MG — 1.053. Это смешанное изменение: один показатель повторяемости улучшился, другой почти не изменился; MG не обязан иметь тот же знак.



В С validation-отношения пилота: R=0.782, D=0.758, ошибка слежения=0.997, награда=0.988. Сильный совместный критерий на тесте выполнен в 2/5 сравнениях. Одинаковая исходная политика означает, что сидами меняется случайность дообучения, а не независимая исходная походка. Этот результат следует оценивать вместе с числом общих записей и сохранением ходьбы, а не только по падению MG.

Дополнительная диагностика по всему циклу. После первых четырёх проверок добавлен С: дисперсия полного состояния между циклами после интерполяции каждого на 64 одинаковые фазы, усреднённая по всему циклу и нормированная на общую дисперсию. Он не использует значения эталонной траектории. D проверяет одну фазу, С — все фазы. Отдельно показан дрейф средней формы между первой и второй половиной записи. Это анализ после просмотра части результатов; он не заменяет исходный критерий успеха.

Сид	С: весь цикл	Дрейф средней формы
271	0.624	2.014
272	1.003	0.132
273	0.998	0.327
274	0.753	0.729
275	0.829	1.271

Чувствительность MG и согласие с независимыми показателями

Постановка	Основной	14 циклов	Левое	Лег 4	Лег 6
Без фазы $\lambda=1$	1.022	1.113	0.881	1.049	1.069
Без фазы $\lambda=3$	0.919	0.874	0.884	0.913	0.773
Фаза, узкий s260	1.053	1.037	0.955	1.030	0.957
Фаза, широкий s271	0.872	0.873	0.919	0.902	0.869
Фаза, широкий s272	1.159	1.138	1.207	1.098	1.148
Фаза, широкий s273	0.913	0.924	1.133	1.062	0.762
Фаза, широкий s274	1.087	1.061	1.120	1.159	1.284
Фаза, широкий s275	0.975	0.972	1.079	0.980	0.906



Согласованный случай — seed271. При сохранении награды R снизился на 47%, D на 93%, разброс по всему циклу на 38%, усиление возмущений на 58%. MG снизился на 8–13% при всех пяти настройках. Но дешёвая спектральная энтропия здесь также снизилась на 13%: уникальное преимущество MG не установлено.

Предел воспроизводимости. В seed275 R и D снизились на 32% и 52%, однако MG основного датчика снизился лишь на 2.5%, а левого вырос на 8%. В seed273 знак MG меняется с настройкой; в seed274 разброс по циклу уменьшается, но R ухудшается и появляются падения при возмущениях. Основной MG снизился в 3/5 пар; во всех пяти настройках — только в 1/5. Это показывает чувствительность к изменению движения, но не универсальное соответствие между MG и улучшением походки. Ни один из показателей не является точным числом активных компонент.

Удвоение числа координат вложения также заметно меняет оценку: максимальное отношение MG40/MG20 по окнам основной настройки составляет 1.33–1.54 в разных парах. Поэтому абсолютные значения здесь не интерпретируются как подтверждённая размерность; проверяется сравнительный диагностический сигнал.

Возмущения, спектры, время и воспроизводимость

На первом общем пригодном тестовом сбросе каждой пары проведены 68 возмущений: 17 физических координат, оба знака, две точки траектории (0 и 1024), величина 0.001 в масштабированных координатах. Продолжение 600 шагов (4.8с) с пересчётом действий. A — медианное расстояние за последние 150 шагов, делённое на исходную величину. В A расстояние выравнивается по фазе в пределах 75 шагов; в В/С внешние фазы одинаковы и используются прямые расстояния полного состояния. Абсолютные A между этими задачами не сопоставимы. Проверяется только одна траектория на пару, не все 10.

Для В/С центральными разностями построена матрица отображения 17 физических координат через 152 шага. Матрицы и сингулярные числа сохранены; полный спектр собственных значений воспроизводится из матриц. Это локальная конечновременная производная: внешняя фаза не включена, траектория не доказана периодической, 152 шага не равны точному периоду 152.215. Это **не подтверждённый спектр Флоке или Ляпунова**. На первой паре и первой точке при уменьшении возмущения до 0.0001 относительное различие матриц составляет 1.002, 1.077 (норма Фробениуса относительно малого шага). Поэтому спектры нельзя использовать как надёжный эталон без такого контроля.

Отношение усиления A в последнем опыте: 0.416, 0.927, 1.494, 0.965, 0.671. A агрегируется по возмущениям без падения. Число падений из 68 (контроль/слежение) по сидам: 271: 0/0, 272: 0/0, 273: 0/0, 274: 0/3, 275: 0/0. Эти падения нельзя скрывать за медианой A . Даже снижение A не доказывает сжатия к периодической орбите: величина конечновременная, возмущения могут покинуть линейную область, а контактная динамика усиливает чувствительность к шагу разностей. Все кривые и матрицы остаются в NPZ/CSV.

Время измерено отдельно после вычислений, CPU, один поток, одинаковые три окна 2048 для MG и дешёвых метрик. Ниже медиана трёх повторов на каждую из двух политик; серия возмущений измерена один раз на политику. Загрузка модели не включена, получение записи указано отдельно.

Операция	Время, с
MG, 20 координат	0.636
MG вместе с диагностикой 40 координат	1.330
R и сечения по полному состоянию	0.043
Дешёвые скалярные показатели	0.004
68 возмущений и конечновременные матрицы	13.670
Получение общей записи	1.405

MG с диагностикой дешевле серии возмущений примерно в 10.3 раза, но дороже дешёвых альтернатив. Сравнение времени не устанавливает одинаковую диагностическую способность. Практическое превосходство MG над всеми доступными подходами этими опытами не доказано.

Проверены: одинаковые начальные политики в каждой паре, разные финальные веса, замороженные нормировки, изменение только заявленных частей задачи, точное невозмущённое воспроизведение с восстановлением фазы, пересчёт метрик по сырым данным. Тесты сечений дают почти нулевой разброс на повторяющемся цикле и ненулевой при различиях между циклами. Все пилоты, включая неудачные, сохранены. Исходные старые результаты и статья не изменялись.

PROTOCOL.md в каждой папке фиксирует решения; selection.json — отбор по validation без MG. trajectory.npz содержит реальные состояния, действия и фазы; MG_windows.csv — все окна и признаки вырождения; probe_eps*.npz — возмущения и матрицы. README.md содержит команды воспроизведения и ограничения. SHA256 файлов и целостность архива проверены отдельно.