

Корректировка эксперимента Walker2d: MG для управляющих сигналов

Зачем нужна корректировка

В исходном опыте PPO обучался со штрафом за изменение среднего действия политики. Поэтому заранее известный эффект эксперимента — упрощение временной структуры **управляющих команд**, а не обязательное уменьшение сложности всей походки. Ранее MG измерялся по углу правого колена. Это смешивало два разных вопроса: упрощается ли выбранный управляющий сигнал и становится ли более повторяемым полное физическое состояние Walker2d.

Здесь MG пересчитан на сохранённых траекториях по шести каналам действий, норме вектора действий, норме приращения действий и среднему действию. Обучение и исходные результаты не изменялись. Использовались те же пять парных сида 221–225, одинаковые начальные политики в каждой паре и общие пригодные тестовые сбросы.

Постановка обучения

Обучалась политика PPO для Walker2d. Контроль продолжал обычное обучение, а вторая политика получала добавку к PPO-loss:

$$L_{\text{smooth}} = \lambda \frac{1}{6|B|} \sum_{(s_t, s_{t+1}) \in B} \|\bar{a}_\theta(s_{t+1}) - \bar{a}_\theta(s_t)\|_2^2,$$

где $\bar{a}_\theta$ — среднее действия гауссовой политики, а B — пары соседних состояний rollout без границ эпизодов. Награда среды не менялась, exploration-noise не штрафовался. В результате ожидаемо уменьшались J1 и J2 — средние квадраты первой и второй разности управляющих команд.

Как считался MG

Для каждого скалярного сигнала использовались окно 2048 шагов, задержка 8, 20 координат вложения и 20 соседей. Значения брались по трём концам окна 2048, 3072 и 4096, затем усреднялись медианой. В таблице приведено отношение MG сглаженной политики к контролю; значение меньше 1 означает снижение.

Результаты

Сигнал	Сиды со снижением	Медианное отношение по пяти сидам
Действие 0	2/5	1.023
Действие 1	5/5	0.766
Действие 2	4/5	0.846
Действие 3	5/5	0.776
Действие 4	5/5	0.657
Действие 5	5/5	0.865
Норма действия	5/5	0.755
Норма приращения действия	5/5	0.717
Среднее действие	5/5	0.758

Норма действия, норма приращения и среднее действие дают согласованное снижение MG на всех пяти сидах. Для отдельных суставов эффект неодинаков: первый канал является контрпримером, а второй и четвёртый каналы наиболее устойчивы. Это ожидаемо для скалярного метода: разные координаты могут содержать разные компоненты движения.

В исходном отчёте J1 уменьшался примерно до 0.35 от контроля, а J2 — до 0.18. Таким образом, независимый от MG показатель плавности команд и MG на агрегированных управляющих сигналах меняются в одном направлении во всех пяти повторах.

Что это показывает

Этот опыт даёт более чистую практическую проверку метода:

1. вмешательство заранее уменьшает временную сложность управляющего сигнала; 2. J1 и J2 подтверждают это напрямую; 3. MG обнаруживает то же упрощение на дешёвых скалярных логах; 4. результат устойчив для агрегированных сигналов на пяти парных повторах.

При этом нельзя заключать, что вся физическая походка стала низкоразмерной. В исходных измерениях MG угла колена снижался, но метрики полного состояния R и D не всегда улучшались. Поэтому корректная формулировка результата — **MG отслеживает упрощение выбранного управляющего сигнала**, а не автоматически доказывает уменьшение активной размерности всей системы.

Проверка совместного воздействия

Чтобы устранить расхождение между управляющим сигналом и полным состоянием, был проведён факторный пилот с четырьмя вариантами: обычное обучение, только сглаживание, только слежение за эталонной фазой и их сочетание. Каждый вариант получил 1048576 переходов, после чего был проверен на пяти validation-сбросах.

Слежение	Сглаживание	R	D	C, весь цикл	J1	Награда
0	0	0.305	0.355	0.746	0.102	4.744
0	1	0.136	1.111	0.963	0.033	4.689
3	0	0.280	1.081	0.932	0.092	4.616
3	1	0.182	1.103	0.948	0.031	4.676

Все четыре варианта сохранили ходьбу и имели по пять пригодных записей. Однако оба варианта со сглаживанием увеличили D , несмотря на сильное снижение $J1$. Совместное воздействие поэтому не прошло критерий улучшения полного состояния; подтверждающие пять сидов для него не запускались.

Это отрицательное управление экспериментом полезно: оно показывает, что уменьшение сложности действий и уменьшение разброса физической траектории — разные свойства. MG следует интерпретировать относительно конкретного скалярного лога, который анализируется.

Практический вывод

Для дальнейших реальных примеров разумно заранее указывать объект анализа: loss, норма градиента, отдельный канал управления, агрегированный control-log или координата состояния. Для управляющих логов текущий результат уже даёт устойчивый proof of concept: MG дешёво и согласованно отслеживает изменение временной сложности в пяти парных повторениях. Для утверждения об упрощении всей динамической системы нужны дополнительные независимые показатели полного состояния и нельзя выбирать единственный сенсор по удобному знаку MG.

Траектории и CSV сохранены в 'action_mg.csv' и 'action_mg_summary.csv'; код пересчёта — в 'action_mg.py'. Факторный пилот сохранён в 'research_walker_combined/pilot_summary.csv'. Статья не изменялась.