

Walker2d: проверка временного масштаба и обучение плавному управлению

Что проверялось и зачем

Обучается политика управления шестью суставными приводами Walker2d. Практическая цель — сохранить быструю устойчивую ходьбу, уменьшая резкие изменения команд. Сравниваются обычный PPO (C) и PPO со штрафом за изменение среднего действия (S). Награда среды: скорость вперёд плюс 1 за здоровое состояние минус $0.001\|a_t\|^2$ за управление; падение завершает эпизод. MG измеряется по углу правого колена при движении замороженной политики. Это анализ её поведения, не размерности весов или динамики оптимизатора.

Результат. В пяти парных повторях медианное отношение S/C для квадрата изменения действия J1 равно 0.350, для второй разности J2 — 0.175. Ходьба без падения: 44/50 у контроля и 46/50 у сглаживания. Независимый совместный критерий улучшения R и D выполнен в 0/5 повторов; основной MG снизился в 5/5. Сглаживание команд, повторяемость всего движения и снижение MG — разные результаты; один не подменяет другой.

Точная постановка обучения

Все запуски начинаются из одной устойчивой политики старого опыта после 655360 переходов. Сохраняются веса, состояние Adam и статистики нормировки; последние заморожены. Поэтому пять сидов — повторы дообучения, а не пять независимо найденных исходных походок. В каждой паре одинаковый сид, бюджет и исходная политика; траектории после обновлений могут различаться.

На запуск: 1048576 дополнительных переходов, 8 сред, 512 шагов на среду, minibatch 256, 5 эпох PPO, learning rate линейно от $3 \cdot 10^{-5}$ до $3 \cdot 10^{-6}$, clip 0.1, target KL 0.01, $\gamma = 0.99$, GAE 0.95, entropy coefficient 0, value coefficient 0.5, gradient clipping 0.5. Actor и critic — отдельные сети 64–64 с tanh. Лимит обучающего эпизода 5000 шагов; снимки каждые 131072 перехода после обновления.

К исходному loss PPO добавлен штраф с $\lambda = 1$:

$$L_{\text{smooth}} = \lambda \frac{1}{6|B|} \sum_{(s_t, s_{t+1}) \in B} \|\bar{a}_\theta(s_{t+1}) - \bar{a}_\theta(s_t)\|_2^2.$$

$\bar{a}_\theta(s)$ — среднее гауссовой политики, обрезанное до границ $[-1, 1]$; B — случайные пары соседних состояний rollout без переходов между эпизодами. Градиент проходит через оба действия; случайный exploration-шум не штрафуются. Награда среды не меняется. Идея темпоральной регуляризации известна из CAPS (Mysore и др., ICRA2021); здесь используется квадрат нормы и нет пространственного штрафа, то есть это не полное воспроизведение CAPS.

Пилот seed220 выбирал коэффициент только по пяти validation reset61001–61005. При $\lambda = 1$ J1 составил 0.215 от контроля, исходная средняя награда — 1.012; последние три снимка прошли [5, 4, 5] из пяти проверок. Запасной $\lambda = 10$ не запускался. Затем коэффициент заморожен; проведены все пары сидов 221–225, без замены неудачных. MG не использовался для выбора коэффициента.

Что измерялось независимо от MG

Каждая финальная политика проверена на десяти новых reset62001–62010: 512 шагов разогрева и 4096 шагов измерения, шаг времени 0.008 с. Сохранены состояния, команды, награды, скорости и состояния симулятора для точного воспроизведения. Ограничение TimeLimit снято, физическое падение завершает эпизод. При подсчёте общей награды остаток после падения заполнен нулями. Основные парные отношения измеряются на общих пригодных записях; падения показаны отдельно.

J1 — средний квадрат первой разности команд по шести приводам; J2 — аналог для второй разности. Это плавность управления, а не физический jerk тела. Полное состояние x_t имеет 17 координат: позиции/углы без абсолютного горизонтального положения и все скорости; первые масштабированы на 1, скорости на 5.

R — минимальная средняя квадратичная ошибка возврата $x_{t+p} - x_t$ при лагах 20–250, делённая на удвоенную полную дисперсию состояния. D — дисперсия полного состояния в локальных максимумах правого колена, нормированная на полную дисперсию. Максимумы: расстояние 20, prominence 0.15, время уточняется параболической интерполяцией. Меньшие R, D означают более повторяемое движение по этим критериям. Несколько разных максимумов за цикл могут превышать D; гарантии точной размерности у R, D нет.

A — усиление малых возмущений полного состояния. Две точки записи (0, 1024), все 17 направлений с обоими знаками, величина 0.001 в масштабированных координатах: 68 продолжений с пересчётом действий политики. Горизонт теперь одинаковый: 600 шагов = 4.8 с. Расстояние до номинальной траектории минимизируется по фазе в пределах ± 75 шагов, с линейной интерполяцией. Для каждого возмущения берётся медиана расстояния за последние 150 шагов, делённая на исходное поперечное расстояние; затем медиана по направлениям. Падения и почти касательные возмущения сохраняются отдельно. Это конечновременная чувствительность, **не спектр Ляпунова и не доказательство асимптотической устойчивости**.

Критерий сильного улучшения повторяемости фиксирован заранее: оба медианных отношения R и D не выше 0.75, не менее 8 общих пригодных записей, исходные R не ниже 0.02 и D не ниже 0.01, сохранено не менее 90% общей награды и потеряно не более одного успешного эпизода относительно контроля. Критерий не охватывает все возможные виды упрощения.

Перепроверка старого опыта

Период выбирался как самый короткий локальный минимум ошибки возврата, не превышающий $1.1R_{\min} + 0.005$. Это рабочее правило, а не гарантия фундаментального периода. Результат проверен отдельно на половинах записи: согласование в пределах 20% есть у 5/10 исходных и 31/47 финальных пригодных траекторий. Например, у anchor/reset51001 ошибка при лаге 76 равна 0.301, при 151 — 0.237: нельзя просто объявить длинный период ошибкой алгоритма.

В таблице — медианные парные отношения финала к общему anchor. Везде три участка записи. «По циклам»: окно 14P, задержка round(P/19); «ресэмплинг»: те же 14 циклов интерполированы в 1792 отсчёта, задержка 7. Период берётся из полного состояния: это ретроспективная диагностика, не автономный скалярный метод. В исходном отчёте было пять фиксированных окон; здесь дополнительно пересчитан контроль по трём, чтобы убрать различие усреднения.

Сид	MG фикс.	MG по циклам	MG + ресэмплинг	Возмущения
211	1.180	1.067	0.994	0.882
212	1.148	1.249	1.101	0.955
213	1.169	0.929	0.990	0.565
214	1.149	0.855	0.878	0.942
215	1.196	0.823	0.853	0.828


После согласования масштаба знак MG изменился, но единого согласия всех показателей нет. При равном физическом горизонте A уменьшился во всех пяти проверенных парах; проверялась лишь одна заранее выбранная общая траектория на сид. Все значения A остаются больше 1. Старые результаты сохранены и не заменены более удобной настройкой.

Результаты нового обучения

Все числа ниже, кроме количества успешных эпизодов, — отношения S/C: меньше 1 означает снижение показателя. MG вычисляется по ближайшим соседям в облаке задержанных значений угла правого колена: 20 координат, 20 соседей, задержка 8 шагов, окно 2048. Соседи в пределах 312 шагов по времени исключены (Theiler); три окна заканчиваются на шагах 2048,3072,4096. Дополнительно проверено вложение в 40 координат (E40); конечность оценки не подтверждает условия теоремы. А проверяется на первом общем пригодном reset пары, остальные показатели — на всех общих пригодных reset. Независимая единица сравнения — сид, не каждая из 50 повторно используемых начальных конфигураций.

Сид (n)	Ходьба C/S	J1	R	D	MG	A
221 (8)	10/10; 8/10	0.354	0.707	0.683	0.783	0.718
222 (6)	7/10; 8/10	0.408	0.603	1.901	0.907	1.563
223 (10)	10/10; 10/10	0.209	2.226	2.813	0.696	1.905
224 (8)	8/10; 10/10	0.313	0.907	1.077	0.848	1.459
225 (9)	9/10; 10/10	0.350	0.873	1.628	0.814	1.648

В скобках после сида указано число общих записей n. Для достаточного покрытия требовалось n не меньше 8: условие выполнено в 4/5 парах; в остальных отношение лишь описательное. Среди пар с достаточным покрытием основной MG снизился в 4/4. По всем пяти описательным сравнениям снижение есть в 5/5 для основного MG, 2/5 для согласованного окна и 4/5 для левого колена. Медианное отношение скорости на общих записях — 0.997, награды с учётом падений — 1.104.



Контрпример: сид 223. J1 уменьшился до 0.209, MG — до 0.696 от контроля, но R вырос в 2.23 раза, D — в 2.81 раза. Обе политики прошли все 10 эпизодов. Это не эффект исключения падений: сигнал MG реагирует иначе, чем выбранные показатели повторяемости всего движения.

Интерпретация. Совместный критерий улучшения R,D с сохранением качества выполнен в 0/5 повторов. Падение MG вместе с J1 здесь не подтверждает снижение активной размерности. Отношение оценок E40/E20 достигает 1.86 даже в основной настройке: абсолютные значения также чувствительны к реконструкции. Изменения шероховатости сигнала, периода и повторяемости не следует смешивать. Пять повторов одной исходной походки не устанавливают перенос на другие походки или роботов.


Полная чувствительность и все индивидуальные reset находятся в paired_traces.csv, all_seeds.csv и MG_windows.csv. Число успешных validation эпизодов в последних трёх снимках (сначала C, затем S): 221: 5/5/5, 3/5/4; 222: 3/5/4, 5/4/4; 223: 5/5/5, 5/5/5; 224: 5/5/3, 5/5/4; 225: 5/5/5, 5/4/5. Финалы не отбирались по наилучшей награде или MG.

Вычислительные затраты и границы вывода

Время измерено последовательно после завершения обучения, на CPU, один поток, на первой подтверждающей паре и одном общем reset. Для MG и простых методов используются одинаковые три окна 2048. Указана медиана шести замеров (три повтора на политику); для серии 68 возмущений — медиана двух замеров, по одному на политику. Загрузка модели не включена; получение записи указано отдельно. Это отдельный benchmark, не параллельная скорость обучения.

Вычисление	Время, с
MG, E=20, три окна	1.010
MG вместе с диагностикой E=40	2.207
R и D по полному состоянию, три окна	0.065
Простые скалярные показатели, три окна	0.013
68 возмущений по 600 шагов	24.945
Общее получение записи, отдельно	2.767

MG без E40 дешевле серии возмущений примерно в 24.7 раза; вместе с E40 — в 11.3 раза. Но MG дороже R,D примерно в 15.6 раза и простых скалярных показателей в 75.8 раза. Спектральная энтропия того же датчика снизилась в 5/5 пар, ошибка скалярного возврата — в 4/5. Если нужна только плавность команд, J1/J2 доступны непосредственно. Методы измеряют разные свойства; отношение времени не доказывает взаимозаменяемость. Преимущество MG над дешёвыми альтернативами здесь не установлено. Стоимость измерения полного состояния в реальной работе не моделировалась.



Контроль корректности. Нулевой штраф воспроизводит исходный PPO побитно на 8192 переходах. Ненулевой штраф изменяет градиентный результат. Проверены общие начальные веса, десять различных финальных политик, неизменные нормировки, пересчёт J1/J2/R/D по сырым данным, полный набор 100 финальных проверок, 17 записей возмущений с одинаковыми горизонтом и фазовым допуском. Невозмущённое воспроизведение совпадает с исходной траекторией. В архиве остаются все неудачи и все заранее заданные настройки.

Что можно утверждать. Проведён контролируемый опыт обучения более плавному управлению и проверена реакция MG вместе с независимыми метриками. Старый вывод о MG оказался чувствителен к временному масштабу; исправление сравнения возмущений не устраняет этого ограничения. Для статьи результаты следует описывать через конкретные измеряемые свойства и все повторы, без утверждения о гарантированном снижении размерности или универсальном превосходстве MG.

Для воспроизведения: `PROTOCOL.md` и `DIAGNOSTIC_ADDENDUM.md` описывают решения; `workflow.py` запускает обучение; `motion.py` сохраняет траектории; `diagnostic.py` и `measure_new.py` считают MG; `perturb_fixed.py` считает A; `benchmark.py` замеряет время; `audit.py` проверяет результаты. Отчёт построен из `summary.json` и CSV, исходные старые опыты и статья не изменены.