

Walker2d: как MG реагирует на силу сглаживания политики

Главный результат

На пяти новых сидах умеренное сглаживание обучаемой политики уменьшает MG нормы управляющего действия: на 20% при $\lambda = 0.25$ и на 40% при $\lambda = 1$ (медианы парных отношений). Знак воспроизводится на всех пяти сидах и трёх агрегированных управляющих логах. При чрезмерном штрафе $\lambda = 4$ команды ещё плавнее, но агент часто падает, а MG нормы действия обычно растёт. Это подтверждает чувствительность MG к изменению структуры управляющего лога, но не доказывает уменьшение размерности всей системы или выигрыш по времени.

Кто учится, чему и зачем

Агент Walker2d получает 17 наблюдений о положении и скорости тела и выдаёт шесть управляющих команд суставам. PPO дообучает уже ходящую политику из одного общего сохранённого состояния. Актор и критик имеют отдельные сети 64–64 с Tanh. Практический мотив постановки: уменьшить резкость команд, сохранив ходьбу и исходную награду среды. Энергопотребление, износ и перенос на реального робота здесь не измерялись.

К стандартной функции потерь PPO добавлен штраф

$$L = L_{\text{PPO}} + \lambda \mathbb{E}_{(s_t, s_{t+1})} \frac{1}{6} \|\bar{a}_\theta(s_{t+1}) - \bar{a}_\theta(s_t)\|_2^2, \quad \bar{a}_\theta(s) = \text{clip}(\mu_\theta(s), -1, 1).$$

Здесь μ_θ — среднее распределения действий политики; пары состояний берутся из текущего rollout без переходов между эпизодами. На каждом минибатче берётся столько случайных пар, сколько в нём действий. Штраф действует на средние команды, а не на шум исследования; награда среды не меняется. Измеряем динамику действий и движения при фиксированной политике каждого чекпоинта, затем сравниваем эти диагностики между этапами обучения. Это не MG по последовательности весов сети или training loss.

План и точные параметры

Пилот: сид 230, четыре значения $\lambda \in \{0, 0.25, 1, 4\}$, пять reset 61001–61005. Сохранены проверки трёх поздних чекпоинтов; решение продолжить принято по финальному, без MG: умеренные штрафы сохранили ходьбу и награду. Подтверждение: все четыре коэффициента, пять новых сидов 231–235, десять одинаковых тестовых reset 62001–62010. Итого 20 новых обучений и 200 финальных тестов; пилот в итоговые числа не включён. Тестовые reset уже использовались в предыдущих опытах этой серии, поэтому это новые обучающие сиды, но не полностью новый набор начальных состояний.

Каждое обучение: 1048576 дополнительных переходов, 8 сред, rollout 512 шагов на среду, batch 256, 5 эпох PPO, learning rate от $3 \cdot 10^{-5}$ до $3 \cdot 10^{-6}$, clip 0.1, target KL 0.01, $\gamma = 0.99$, GAE 0.95, entropy coefficient 0, value coefficient 0.5, gradient clipping 0.5. Статистика нормализации наблюдений и наград заморожена из общего anchor. Среда обучения ограничена 5000 шагами на эпизод.

Тест: детерминированная политика, 512 шагов разогрева, затем 4096 шагов записи, шаг времени 0.008 с. Успех: полная запись без падения и средняя скорость не меньше 0.5. Допуск к анализу требует также стандартного отклонения правого колена не меньше 0.05 и как минимум восьми пиков (расстояние 20, prominence 0.15). Награда усредняется на фиксированных 4096 шагах; после падения остаток получает нулевой вклад. Поэтому короткий эпизод не выглядит успешным.

Что измеряется

$a_t \in \mathbb{R}^6$ — исполненная команда. Независимые от MG показатели плавности:

$$J_1 = \frac{\sum_{t=1}^{T-1} \|a_t - a_{t-1}\|_2^2}{6(T-1)}, \quad J_2 = \frac{\sum_{t=2}^{T-1} \|a_t - 2a_{t-1} + a_{t-2}\|_2^2}{6(T-2)}, \quad T = 4096.$$

J_1 близок к обучающему штрафу; J_2 проверяет вторые разности. Снижение обоих означает более плавные команды, но само по себе не устанавливает уменьшение числа степеней свободы. Их абсолютные значения чувствительны к масштабу действий.

Для проверки всего движения используем $x_t = (q_{t,1}, \dot{q}_t/5) \in \mathbb{R}^{17}$: горизонтальная координата переноса исключена, остальные восемь координат положения и девять скоростей сохранены. Определим $V = T^{-1} \sum_t \|x_t - \bar{x}\|_2^2$. Тогда

$$R = \min_{p \in \{20, \dots, 250\}} \frac{\frac{1}{T-p} \sum_{t=0}^{T-p-1} \|x_{t+p} - x_t\|_2^2}{2V}, \quad D = \frac{\frac{1}{K} \sum_{i=1}^K \|z_i - \bar{z}\|_2^2}{V}.$$


R — ошибка повторения полного состояния через общий лаг; D — разброс K состояний z_i около максимумов угла правого колена. Время пика уточняется параболой по трём точкам, состояние — линейной интерполяцией. Меньшие значения означают лучшую повторяемость по соответствующему критерию. Ни одна из величин не является точной размерностью; повторяемость во времени и повторяемость в выбранной фазе могут расходиться.

Основной скаляр для MG: $\|a_t\|_2$. Дополнительные: $\|a_t - a_{t-1}\|_2$ и среднее шести команд. Настройки перенесены из предыдущего опыта: окно 2048, задержка 8, вложение $E = 20$, 20 соседей, исключение Theiler 312, dither 10^{-9} , seed оценщика 123; дополнительно сохранён результат $E = 40$. По траектории берётся медиана трёх окон с концами 2048, 3072, 4096. Для допуска требуем отсутствия численного вырождения во всех трёх окнах. Все 169 допущенных финальных траекторий прошли эту проверку; она не равнозначна подтверждению всех теоретических предпосылок.

Финальные результаты: все пять новых сидов

Ниже диагностики — отношения к $\lambda = 0$: сначала медиана по общим допустимым reset внутри сида, затем медиана по пяти сидам. Эти пять сидов — повторения обучения; 50 эпизодов не считаются 50 независимыми обучениями. Успех и награда учитывают все эпизоды, включая падения. Награда в таблице — отношение средних по всем 50 эпизодам, а не медиана отношений по сидам.

λ	Успех	Общих пар	Награда	MG нормы	J_1	J_2	R	D
0	48/50	48	1.000	1.000	1.000	1.000	1.000	1.000
0.25	49/50	47	1.020	0.801	0.539	0.385	0.650	1.281
1	47/50	45	0.978	0.604	0.331	0.181	0.508	1.157
4	25/50	24	0.681	1.114	0.180	0.064	2.029	0.971




Для $\lambda = 0.25$ отношения MG нормы по отдельным сидам лежат в диапазоне 0.582–0.845; для $\lambda = 1$ — 0.509–0.781. Все пять уменьшаются. Дополнительные скаляры подтверждают знак: MG нормы приращения равен 0.662 и 0.601; MG среднего действия — 0.742 и 0.651 соответственно. Коэффициенты и основной скаляр не выбирались по этим результатам. Полностью монотонного эффекта по силе штрафа нет: на сиде 235 MG при $\lambda = 1$ выше, чем при 0.25.

R уменьшается на 4/5 сидов при $\lambda = 0.25$ и 5/5 при $\lambda = 1$, но D растёт на 5/5 и 4/5 соответственно. Значит, независимое подтверждение относится прежде всего к плавности команд и одному критерию повторяемости, а не ко всем аспектам динамики. При $\lambda = 4$ MG нормы растёт на 4/5 сидов при ухудшении ходьбы. Это различает сглаживание и деградацию в данном опыте, но не является проверенным универсальным детектором отказов. В этой группе анализ выживших особенно смещён: на сиде 232 осталась только одна общая пригодная пара.

Что происходит по ходу обучения

Дополнительно проверены пять фиксированных чекпоинтов всех 20 политик на одном заранее выбранном reset 62001. Настройки MG и трёх окон те же. Упавшие эпизоды не получают нулевой MG: пары исключены из медианы данного этапа, их число указано в скобках.

Переходы	MG, $\lambda = 0.25$	MG, $\lambda = 1$	MG, $\lambda = 4$
0	1.000 (5)	1.000 (5)	1.000 (5)
262144	0.811 (5)	0.749 (3)	0.796 (4)
524288	0.808 (5)	0.838 (4)	0.731 (2)
786432	0.747 (4)	0.827 (5)	1.022 (3)
1048576	0.745 (5)	0.531 (4)	1.052 (3)



При умеренных штрафах уменьшение MG появляется уже после первого проверенного этапа обучения. При сильном штрафе к концу MG возвращается к контролю или превышает его, хотя J_1/J_2 остаются низкими. Из-за изменения состава выживших пар эти медианные кривые нельзя трактовать как непрерывную траекторию одной системы; данные каждого сида сохранены отдельно.

Вычислительная стоимость

Последовательный CPU-замер на одной сохранённой траектории контроля (сид 231, reset 62001), один численный поток, прогрев и пять повторов, медиана. Чтение файла, симуляция и подготовка скалярного лога не включены. Сравнение R , D доступно как на 2048, так и на 4096 точках; размер состояния здесь всего 17.

Диагностика	Время, с
J_1 и J_2 , 4096 точек	0.000124
R и D , 2048 точек полного состояния	0.0266
R и D , 4096 точек полного состояния	0.0523
MG, одно окно 2048, $E = 20$	0.455
MG плюс проверка $E = 40$, одно окно	0.941
MG плюс проверка $E = 40$, три окна	2.910

В этой реализации MG примерно в 17 раз медленнее R , D на одинаковом числе точек. Он требует один скаляр вместо полного состояния, но уменьшение требований к наблюдениям не означает выигрыш по времени. J_1/J_2 существенно дешевле, если задача — только контроль плавности. Преимущество MG по сравнению со спектрами Ляпунова или высокоразмерными эталонами этот опыт не проверяет.

Вывод для статьи и границы результата

Корректный тезис: при дообучении управляющей политики с умеренной временной регуляризацией MG по одному агрегированному логу устойчиво обнаруживает изменение, сопровождаемое снижением резкости команд и ошибки повторения состояния; эффект подтверждён на пяти новых сидах. При чрезмерной регуляризации связь нарушается, что видно при совместном контроле качества и диагностик.

Вмешательство прямо поощряет гладкость, все политики происходят из одного anchor, а D не подтверждает общего упрощения движения. Отношение MG при $E = 40$ и $E = 20$ не всегда близко к единице. Поэтому точное число компонент, причинная связь MG с качеством и преимущество по скорости не установлены. Для усиления нужны независимо обученные anchor и изменение структуры, не заданное штрафом.

Данные по сидам и команды воспроизведения перечислены в README.md. Отчёт: 30 сентября 2026 года; основная статья не менялась.