

Методы динамического эмпирического моделирования для обучения нейронных сетей

Николай Карлов

Московский физико-технический институт

Курс: Автоматизация научных исследований

Консультант: А. Кравацкий

2026

Основная идея

Обучение нейросети можно описывать как высокоразмерную стохастическую динамическую систему. Экспериментально докажем, что к ней применимы методы эмпирического динамического моделирования (EDM).

Глобальная цель: Диагностика оптимизатора по 1D-логам (без анализа тяжелых матриц весов).

Критерий качества: Совпадение эмпирических результатов EDM с теоретическими предсказаниями в контролируемой среде.

Задачи:

1. Сформулировать модель реконструкции фазового пространства оптимизатора.
2. **Тест 1 (Causality):** Проверить метод CCM на искусственном отравлении батча.
3. **Тест 2 (Grokking):** Отследить топологический коллапс размерности (MLE) перед наступлением генерализации.

Методология базируется на стыке нелинейной динамики и теории Deep Learning:

1. **Takens (1981), Stark (1999)** – *Detecting strange attractors in turbulence / Delay Embeddings for Forced Systems* (Теоремы о вложении).
2. **Sugihara et al. (2012)** – *Detecting Causality in Complex Ecosystems* (Метод Convergent Cross Mapping, CCM).
3. **Levina & Bickel (2004)** – *Maximum likelihood estimation of intrinsic dimension* (Оценка размерности).
4. **Power et al. (2022)** – *Grokking: Generalization beyond overfitting on small algorithmic datasets* (Открытие гроккинга).
5. **Nanda et al. (2023)** – *Progress measures for grokking via mechanistic interpretability* (Формирование алгебраических структур в весах).

Постановка задачи: Гипотеза и Модель

Гипотеза: Динамика обучения нейросети $\mathbf{w}_{t+1} = F(\mathbf{w}_t, \xi_t)$ сходится к низкоразмерному аттрактору. Скалярные логи $\mathcal{L}_t = \phi(\mathbf{w}_t)$ являются 1D-проекциями этого аттрактора, сохраняющими его топологию согласно теоремам Старка.

Модель решения: Реконструкция фазового пространства. Для ряда $X(t)$ строится вектор запаздывания:

$$\mathbf{x}_t = [X(t), X(t - \tau), \dots, X(t - (E - 1)\tau)]^\top \in \mathbb{R}^E \quad (1)$$

Где:

- ▶ E – размерность вложения (оценивается через MLE / FNN).
- ▶ τ – задержка (оценивается через Delayed Mutual Information).

Теоретическое решение (Пайплайн): Сбор скалярных логов $\rightarrow$ Поиск τ (через DMI) и E $\rightarrow$ Построение кривых CCM $\rho(L)$ или отслеживание динамики $d^*(t)$ во времени.

Где:

- ▶ $d^*(t)$ – наша оценка размерности вложения E , зависящая от времени.
- ▶ L – гиперпараметр метода CCM, который отвечает за то, какую часть ряда сейчас рассматривает метод
- ▶ $\rho(L)$ – значение конвергенции полученное методом CCM, зависящее от размера библиотеки.

Постановка задачи: Критерии качества

Логика эксперимента

Предположим, что динамические методы анализа временных рядов (EDM) действительно работают для обучения нейросетей. Мы знаем, что именно они должны предсказать в контролируемых условиях. Давайте проверим, выполняются ли эти предсказания.

Критерии качества:

1. Для **Poisoned Batch**: При внедрении искусственного драйвера α_t , метод CCM обязан показать сходимость корреляции $\rho(L) \rightarrow \text{const} > 0$ для направления $\alpha \rightarrow \mathcal{L}$, и отсутствие сходимости для $\mathcal{L} \rightarrow \alpha$.
2. Для **Grokking**: Переход от случайного запоминания к алгоритмическому правилу должен выражаться в **коллапсе размерности E** (топологическом переходе) задолго до того, как вырастет валидационная точность.

Эксперимент 1: Poisoned Batch (Цели и Статистика)

Цель: Проверить метод на синтетическом вмешательстве, где причинно-следственная связь гарантирована математически. Ожидание: $\rho \rightarrow \text{const} > 0$.

Сеттинг:


- ▶ Датасет: CIFAR-10. Модель: ResNet-18.
- ▶ Длина временного ряда: ~ 8000 шагов (40 эпох, batch=256).
- ▶ Сигнал: Контролируемое отравление батча долей α_t (то есть замена в α_t доли картинках правильной метки класса на не правильную).

Проверяемые модели драйвера α_t :


1. *Sinusoidal*: $\alpha_t = A \sin(\omega t)$ (Гладкий детерминированный).
2. *Discrete Square Wave Randomness*: Импульсы со случайной длиной фазы (сэмплируется из $\mathcal{N}(10, 1)$) и двумя значениями.
3. *Logistic Map*: $\alpha_{t+1} = r \alpha_t (1 - \alpha_t)$ (Детерминированный хаос).

Эксперимент 1: Сырые данные vs. Анализ CCM

Сравнение исходного объекта исследования (временных рядов) и результата их математической обработки.




Сырые логи: Драйвер и Loss.




Анализ CCM: $\rho \rightarrow 0.75$

Вывод: Хотя визуально влияние драйвера тонет в сильном шуме стохастического градиентного спуска, топологическая реконструкция успешно выделяет скрытый причинно-следственный сигнал.

Эксперимент 1: Анализ границ применимости



Stochastic Square Wave with rate 0.0045(Успех): Метод устойчив к прерывистым сигналам.



Logistic Map(Ошибка): Нет сходимости.

Анализ ошибки: Наложение двух хаотических процессов (внутреннего шума SGD и хаоса драйвера) делает проекцию аттрактора неразличимой при малых E . Это определяет эмпирический предел чувствительности метода.

Эксперимент 2: Детекция Гроккинга (Цели)

Цель: Доказать, что отложенная генерализация – это топологический переход. Ожидание: коллапс эффективной размерности E до скачка точности.

Единый Сеттинг (Omnigrok architecture):


- ▶ Датасет: Модульное сложение / Композиция в S_5 .
- ▶ Модель: однослойный (1L) трансформер с Pre-LayerNorm.
- ▶ Обучение: Adam **со стохастикой** (mini-batch), 15000-20000 шагов.

Варьируемый гиперпараметр: Наличие Weight Decay (WD).


- ▶ $WD = 1.0 \implies$ Ожидаем гроккинг и коллапс размерности.
- ▶ $WD = 0.0 \implies$ Ожидаем вечную меморизацию и отсутствие коллапса.

Эксперимент 2: Mod Addition (WD = 1.0, Grokking)


Топологическая динамика при успешном формировании обобщающего правила.



EDM & Accuracy



EDM & Loss




EDM & Weight Norm


Эффективная размерность $d^*(t)$ начинает снижаться с опозданием относительно снижения нормы весов и val_loss, но задолго до резкого роста Аккурэсу. Топологический критерий предсказания выполнен, но также показано, что он не всегда самый эффективный.

Эксперимент 2: Mod Addition (WD = 0.0, No Grokking)


Обучение без L_2 -регуляризации (Меморизация).



EDM & Accuracy



EDM & Loss




EDM & Weight Norm


Точность на тесте остается около нулевой. Норма весов, val_loss и размерность фазового пространства $d^*(t)$ не падают. Метод не выдает ложных срабатываний об обобщении.

Эксперимент 2: Неабелева группа S_5 (WD = 1.0, Grokking)


Проверка метода на алгебраической структуре более высокой сложности.



EDM & Accuracy



EDM & Loss




EDM & Weight Norm


Даже при более сложной алгебраической структуре представлений неабелевой группы S_5 , коллапс размерности $d^*(t)$ успешно диагностирует структурную перестройку сети.

Эксперимент 2: Неабелева группа S_5 (WD = 0.0, No Grokking)


Обучение без L_2 -регуляризации на сложных данных.



EDM & Accuracy



EDM & Loss



EDM & Weight Norm

Без давления Weight Decay нейросеть застревает в фазе хаотичного запоминания (размерность аттрактора $d^*(t)$ не падает), что безошибочно фиксируется методом MLE.

Резюме: Модели, Данные, Критерии

Эксперимент	Модель / Данные	Метод анализа	Критерий качества (Результат)
Poisoned Batch	ResNet-18 CIFAR-10	Convergent Cross Mapping	$\rho(L)$ сходится к плато > 0.5 . (Выполнено для $\sin$ и $DPBR$)
Grokking Detection	однослойный (1L) трансформер S_5 / Mod Addition ($p=113$)	MLE Intrinsic Dimension	Падение размерности E до скачка test accuracy. (Выполнено)

Полученные результаты (Критерии выполнены)

- ▶ **Успешная детекция каузальности (CCM).** Метод смог извлечь истинный причинно-следственный сигнал из 1D-лога в условиях экстремальной размерности нейросети и стохастического шума SGD (в сценарии Poisoned Batch классическая линейная статистика бессильна).
- ▶ **Топологический предиктор гроккинга.** Эмпирически доказано, что отложенная генерализация сопровождается коллапсом эффективной размерности E . Это позволяет предсказывать генерализацию сети до скачка валидационной точности, по 1-D скалярным логам оптимизатора.
- ▶ **Метрики оптимизатора.** В эксперименте с гроккингом удалось получить требуемый результат за счёт метрик связанных с внутренним состоянием оптимизатора (weight norm и другие). Таким образом в данном подходе нет необходимости в использовании валидационной выборки.

Положение, выносимое на защиту

Методы эмпирического динамического моделирования (EDM) применимы к глубокому обучению. Топологическая реконструкция одномерных скалярных логов (loss, weight norm) достаточна для диагностики скрытых состояний оптимизатора и предсказания фазовых переходов, что устраняет необходимость ресурсоемкого анализа матриц весов.