

Подсчёт активной размерности процесса обучения:
что может и чего не может измерить один скалярный лог

Николай Карлов
Консультант: [имя консультанта]
Эксперт: [имя эксперта]

Кафедра интеллектуальных систем, МФТИ
По материалам статьи на ICOMP 2026

2026

Хотим считать степени свободы обучения, не храня траекторию

Что измеряем

Активная размерность d_{act} отрезка обучения — число независимых направлений, вдоль которых параметры реально движутся внутри окна. Обычно $d_{\text{act}} \ll P$, где P — миллионы параметров.


В чём сложность

Измерить d_{act} напрямую — значит хранить всю траекторию, чего обычный запуск не делает. Зато он бесплатно пишет **скалярные логи**: лосс, норму градиента, норму параметров.

Что из активной размерности можно восстановить по одному такому скаляру?



Зачем: grokking

Отложенная генерализация — это реальное сжатие геометрии траектории, или просто вся траектория стала мельче? И можно ли поймать переход по логам, которые запуск пишет и так?




- Розовым помечен один момент: два отсчёта лог (a) на расстоянии 2τ — это одна точка облака (b).
- (c) размерность читается из того, как быстро радиус r_m растёт с m . Соседей ближе W_T по времени не берём.

Выбор конкретного оценщика почти ничего не меняет




- (a) MG и LB неразличимы, TwoNN скачет. (b) те же 4 отложенных ранга, ρ — корреляция Спирмена.
- Работает **схема «задержки + соседи»**: линейный PR без всякого поиска соседей проигрывает лишь вдвое.

На построенной истине оценка попадает — до потолка $r \approx 8$




(b) One point per observer



—●— fast drive -■- same drive, 25 × slower ◆ no drive at all



- Стенд: голова в 10-мерном подпространстве над замороженной сетью на digits; r групп данных модулируем r синусоидами — путь ложится на r -мерный топ.
- **(b)** по отдельным наблюдателям разброс впятеро: от проекции параметров до полнобатчевого лосса.

Зато к самой геометрии оценка чувствительна




- Тот же стенд, меняем на ходу число включённых синусоид: $4 \rightarrow 1 \rightarrow 4$. Серая линия — истина, синяя — оценка.
- Оценка следует за истиной, а шероховатость лога не меняется вовсе.

Что подаём на вход: возвратный запуск и затухающий




- **(b)** дрейф включён: путь снова и снова проходит рядом с тем, где уже был. **(a)** выключен: голову один раз толкнули, $\mathbf{c}^* + 0.8 \mathbf{V}_{:r} \xi$, и она съезжает обратно.
- Занятое множество — **одна кривая, пройденная один раз**, значит $d_{\text{act}} = 1$ при любом r .




- **(a)** меняем *только* W_T : на транзiente оценка идёт от 1.20 до 174, на торе стоит. *Истину 1 возвращает сам оценщик при $W_T = 0$.*
- **(b)** ближайшая точка у тора — в 2554 шагах, у транзientа — в 6. Запрет отнимает у одного всё, у другого ничего.

Шум не отсекается, а считается — зато его видно диагностикой




- **(a)** шум в 2.5 % от амплитуды: при $r = 1$ оценка уезжает на 11.3. Пунктир — истина чистого дрейфа; у шумных ветвей d_{act} не определён вовсе.
- **(b)** выход — не фильтровать, а распознавать: два разных механизма шума дают один вердикт $\rho_{\text{ident}} \approx 1.55$.

У grokking'a оценка на дешёвом логе падает вдвое на переходе



- Трансформер: 4 запуска с weight decay обобщают, 2 без него — нет; всё выровнено по шагу генерализации t_{gen} .
- **(c)** по одному столбцу на запуск, сверху 4 обобщающих: глубина $\times 2-3$ при $p \leq 0.075$ против $\times 1$ при $p \geq 0.95$.


Почему уровень читать нельзя 1: обе постановки вне области




- Точка — один лог. По горизонтали: сколько раз он пересёк линию тренда. По вертикали: ρ_{ident} (велико = оценка следует за E).
- Все 10 полнобатчевых логов пересекают тренд **ровно дважды** (полоса при $x = 2$). В синей области нет никого.

Почему уровень читать нельзя 2: падение бывает без обобщения

(a) The estimate falls fivefold




(b) Yet they never generalise




- (a) два запуска без weight decay: оценка на логе лосса падает впятеро.
- (b) а валидация у них так и остаётся на уровне шума, 0.08–0.09 против 1.00 у обобщающих.

Почему уровень читать нельзя 3: есть механизм без размерности




- Истина всё время одна, $r = 4$; меняем по одному фактору, который размерность не задевает. Серые почти ничего не двигают.
- Два розовых сдвигают оценку на +1.5 компоненты — ровно это делает монотонно растущая норма параметров.

Но это не ложная тревога: система там правда упрощается




- (a) у обоих запусков без weight decay норма растёт на **100 %** логируемых шагов — это и есть скатывание в тупое наращивание нормы.
- (b) у одного из них ранг пути ровно 1.00: всё движение сводится к одному направлению.
Оценка говорит «стало проще» — и не врёт.

Независимый измеритель: CountSketch и эффективный ранг





- Каждый логируемый шаг сжимаем случайной проекцией в $\mathbb{R}^{1024}$; статистика — эффективный ранг ковариации.
- (a)** врёт не больше 0.11; **(b)** памяти в 36 раз меньше при +6 % времени.

Прямое измерение: у перехода траектория сжимается и разжимается



- Ранг коллапсирует у перехода почти до единицы и **снова расширяется** выше плато; у запусков без WD этого нет.
- **(c)** снимает возражение «траектория встала»: путь достигает дна позже и не возвращается.

Запуски разделяет не глубина падения, а его время и возврат




- **(a)** глубина не разделяет: контроль где-то в своём запуске падает так же глубоко (2.37 против 2.24 и 2.39).
- **(b)** время — разделяет: t_{gen} различаются вчетверо, а минимум у каждого рядом с t_{gen} .


1. **Где абсолютное значение честное.** В детерминированном и возвратном режиме с согласованным лагом один скалярный лог считает активную размерность до потолка ≈ 8 . Работает схема «задержки + соседи», а не конкретный оценщик.
2. **В *grokking*'е абсолютного значения нет.** Диагностики отвергают обе постановки, три разных механизма дают устойчивое, но неверное число. Уровень читать нельзя — только изменение внутри запуска.
3. **Но как детектор упрощения метод работает.** И у обобщающих запусков, и при $WD = 0$ он ловит реальное событие: там — временное сжатие у перехода, здесь — скатывание в рост нормы с траекторией ранга 1. Ложных тревог нет; есть неразличение *вида* упрощения.
4. **Вид различает прямое измерение.** Сжатие у *grokking*'а временное и *обращается*, у запуска без WD — постоянное. Разделяют время и возврат, а не глубина.

- Нужен возвратный режим и лаг, согласованный с периодом, которого лог не выдаёт. Выше ≈ 8 компонент оценка только порядковая, и линейный PR по задержкам почти не хуже.
- Нет отбора области скейлинга — для шумного режима это очевидное улучшение протокола, для транзиента бесполезное: там все двадцать расстояний лежат в полосе шириной 13 %.
- Коллапс — четыре запуска против двух, разделённых weight decay, который заодно двигает норму. Метка ставится только *после* перехода.
- В полнобатчевой постановке результат не воспроизводится.

(a) Estimate against the lag τ




(b) A dimension, not a rank




- **(a)** каждый ранг поделён на свою истину. Окно задержки должно покрывать заметную долю периода; лог обучения периода не даёт.
- **(b)** при амплитудах фаз q^l размерность остаётся r , а эффективный ранг падает. Оценка следует за *размерностью*.

Резерв: суррогатный тест для падения на лог



- Запуск сравнивается *сам с собой*: суррогаты хранят спектр, но рвут тонкую структуру. p — доля суррогатов, упавших не мельче.
- У двух запусков без WD на этом окне почти нет динамического диапазона, так что их $\times 1$ — не дименсиональный негатив.



- Плоскость первых двух delay-координат — то множество, по которому идёт поиск. Слева возвратные случаи: заполнено, оценка честна.
- Справа два режима реального обучения. ≈ 16 на транзиенте — величина на пределе исключения, а не размерность.