

Оценка активной размерности динамики обучения по одному скалярному логгу, с приложением к grokking

Николай Карлов

Консультант: [имя консультанта]

Эксперт: [имя эксперта]

Кафедра интеллектуальных систем, МФТИ

По материалам статьи на ICOMP 2026

2026

Что определяется

Возьмём участок обучения, на котором закон обновления не меняется, а траектория параметров возвращается в одну и ту же область. Рассмотрим множество $\mathcal{A}$ тех точек, к которым траектория подходит сколь угодно близко бесконечно много раз.

Активная размерность — размерность множества $\mathcal{A}$: число независимых координат, которыми точка этого множества задаётся однозначно. Эти координаты и называются **активными компонентами**. Формальные определения — на следующих двух слайдах.

Три величины, которые различаются

P — число параметров: у трансформера здесь 226 816;

PR — $(\sum_i \lambda_i)^2 / \sum_i \lambda_i^2$ по спектру $\{\lambda_i\}$ ковариации;

d_{act} — размерность множества $\mathcal{A}$.

Обе записи слайда 12 имеют ковариацию задержек ранга 8. У первой $d_{\text{act}} = 1$ и $PR = 4.1$, у второй $d_{\text{act}} = 4$ и $PR = 2.2$: **порядок PR обратен порядку d_{act}** на всех восьми слайдах.

Определение строго: режим и его мера

Состояние и координаты

Состояние — пара $s_t = (\boldsymbol{\theta}_t, \mathbf{u}_t)$: параметры $\boldsymbol{\theta}_t \in \mathbb{R}^P$ и внутренние переменные оптимизатора $\mathbf{u}_t$ (у AdamW — два накопленных момента, у градиентного спуска их нет).

Если параметры лежат в аффинном подпространстве $\boldsymbol{\theta} = \boldsymbol{\theta}_0 + \mathbf{V}^\top \mathbf{c}$, $\mathbf{V}\mathbf{V}^\top = I_k$, то переход к координатам $\mathbf{c} \in \mathbb{R}^k$ — изометрия и размерность не меняет; дальше пишем $\mathbf{c}$, для трансформера $\mathbf{c} = \boldsymbol{\theta}$.

Режим и мера занятости

Режим R — участок работы, на котором (i) закон обновления и внешние условия неизменны; (ii) у состояния существует инвариантная вероятностная мера ν_R ; (iii) запись успевает её семплировать. Для эргодической детерминированной системы $\nu_R(C)$ — **доля времени в C** :

$$\nu_R(C) = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t < T} \mathbf{1}\{\mathbf{s}_t \in C\}, \quad \mathbf{1}\{\cdot\} \text{ — индикатор.}$$

Мера занятости — образ ν_R при $\pi_c : \mathbf{s} \mapsto \mathbf{c}$: $\mu_R(B) := \nu_R(\pi_c^{-1}(B))$, $B \subseteq \mathbb{R}^k$ борелевское.

Определение строго: размерность и компоненты

$$d_{\mu_R}(\mathbf{c}) := \lim_{r \downarrow 0} \frac{\log \mu_R(B(\mathbf{c}, r))}{\log r}, \quad d_{\text{act}}(R) := d, \text{ если } d_{\mu_R}(\mathbf{c}) = d \text{ для } \mu_R\text{-п.в. } \mathbf{c}.$$

Здесь $B(\mathbf{c}, r) := \{\mathbf{c}' : \|\mathbf{c}' - \mathbf{c}\| < r\}$. Мера с таким d называется *точно размерной*; MG оценивает ровно этот показатель.

Гладкий случай: откуда берутся компоненты

Пусть $\mathcal{A}_R := \text{supp } \mu_R = \{\mathbf{c} : \mu_R(B(\mathbf{c}, r)) > 0 \ \forall r > 0\}$: точки, любой шар вокруг которых посещается с положительной долей времени. Если $\mathcal{A}_R$ — гладкое d -мерное многообразие, а плотность μ_R на нём положительна, то показатель равен d , и у почти всех точек есть карта $\Psi_R : U \subseteq \mathbb{R}^d \rightarrow \mathcal{A}_R$ с $\text{rank } D\Psi_R = d$. Её координаты $z_1, \dots, z_d$ — **активные компоненты**; другая карта даёт другие, *их число d то же*.

Роль окна

Окно $\mathcal{W}$ из L шагов задаёт $\hat{\mu}_{\mathcal{W}} := \frac{1}{L} \sum_{t \in \mathcal{W}} \delta_{\mathbf{c}_t}$, где $\delta_{\mathbf{c}}$ — единичная масса в $\mathbf{c}$. Её носитель — L точек, показатель равен нулю: окно даёт **выборку** из μ_R , по которой оценивают $d_{\text{act}}(R)$.

Шаг 1: из одного скаляра — вектор задержек

Наблюдение

Видим скаляр $x_t = \phi(s_t)$, где s_t — полное состояние оптимизатора, а ϕ фиксирована до запуска. Строим

$$\mathbf{y}_t = (x_t, x_{t-\tau}, \dots, x_{t-(E-1)\tau}) \in \mathbb{R}^E.$$

Почему это законно

Такенс, Сауэр и др.: для *типичной* пары (динамика, наблюдение) на компактном инвариантном множестве размерности d это отображение — вложение при $E > 2d$, то есть замена координат, не меняющая размерности.

Типичность для заранее выбранной ϕ **не проверяема** — отсюда все результаты сразу по семейству из 10 наблюдателей.

Шаг 2: показатель массы на конечном масштабе

Конечные данные разрешают только диапазон радиусов

Предел $r \downarrow 0$ по конечной записи недостижим; для $0 < r_1 < r_2$

$$d_R(\mathbf{c}; r_1, r_2) := \frac{\log \mu_R(B(\mathbf{c}, r_2)) - \log \mu_R(B(\mathbf{c}, r_1))}{\log r_2 - \log r_1}.$$

Компонента с амплитудой ниже r_1 **не разрешается**.

Оценка (MacKay–Ghahramani)

$r_1^{(i)} \leq \dots \leq r_m^{(i)}$ — расстояния от точки i до её m соседей; сосед учитывается лишь при $|t_i - t_j| > W_T$ (исключение Тейлера). Пулинг правдоподобия по N точкам до обращения:

$$\hat{d}_{\text{MG}}^{-1}(\mathcal{W}) = \frac{1}{N(m-1)} \sum_{i=1}^N \sum_{j=1}^{m-1} \log \frac{r_m^{(i)}}{r_j^{(i)}}.$$

MG оценивает **тот же показатель, но на масштабе самих расстояний до соседей**.

Когда оценку можно назвать размерностью


Четыре условия

1. окно целиком лежит в одном режиме R ;
2. динамика покрывает $\mathcal{A}_R$ достаточно плотно — **нужны возвраты**;
3. радиусы соседей лежат в устойчивом диапазоне скейлинга;
4. delay map — корректное вложение.

Иначе сообщается **только статистика** $\hat{d}_{\text{MG}}(\mathcal{W})$, без знака равенства. Заморожено: $\tau = 4$, $E \leq 20$, $m = 20$, $W_T = 76$, $L = 8000$.


Четыре величины, которые нельзя путать

$d_{\text{act}}(R)$	размерность режима
$d_{\text{act}}(R; r_1, r_2)$	её конечномасштабная версия
$\hat{d}_{\text{MG}}(\mathcal{W})$	вычисленная оконная статистика
$\text{PR}(\mathcal{W})$	effective rank: линейный, вспомогательный




- excluded: $|\Delta t| \leq W_T$
- reference point
- the $m = 20$ nearest

- Один и тот же запуск: $d_{\text{act}} = 1$, одна фаза. В **(b)** лежит реконструкция, сохранённая самим оценщиком; здесь ничего не пересчитывается. Занятое множество — замкнутая петля.
- Золотые в **(b)** — сэмплы ближе W_T по времени: период петли ≈ 25 шагов, поэтому они разбросаны по всей петле, а соседи в **(c)** — возвраты с других витков.




- Стенд: голова в 10-мерном подпространстве над замороженной сетью; данные модулированы синусоидами с несоизмеримыми частотами — их число и есть истина.
- **(b)** ρ — ранговая корреляция с истиной. Держит **схема «задержки + соседи»**; оценщик решает мало: линейный PR проигрывает лишь вдвое.

На построенной истине оценка попадает — до потолка $d_{\text{act}} \approx 8$




- Ранги 1–8; медиана по 10 наблюдателям и 4 сидам, полоса — межквартильный разброс. (b) — то же минус истины.
- Быстрый привод: промах < 0.7 компоненты до $d_{\text{act}} = 8$, выше — потолок конфигурации. В 25 раз медленнее оценка встаёт на 3.4. Ромб — транзист: 1 против 16.

Ошибка — свойство наблюдателя не меньше, чем оценщика





- Задача: тот же стенд с известной истиной, что на слайдах 9–10; меняем только то, *какой скаляр* логируем.
- Каждый наблюдатель — фиксированная до запуска функция состояния. Ошибка на отложенных рангах 1, 3, 5, 8: от 0.34 до 1.87, медиана 0.48.



К самой геометрии оценка чувствительна, а шероховатость — нет



- Задача: за чем следует оценка — за размерностью или за гладкостью? Сети здесь нет: два сигнала, $d_{act} = 4$ и $d_{act} = 1$.
- Частота второго **подобрана бисекцией** так, что шероховатость совпадает до последнего бита. Переключаем $4 \rightarrow 1 \rightarrow 4$; штриховка — смесь сигналов, истины нет.




- (a) дрейф выключен: голову один раз толкнули из решения, $\mathbf{c}^* + 0.8 \mathbf{V}_{:,r} \xi$, и она съезжает обратно. **100 %** шагов вниз, ни одной смены знака.
- (b) дрейф включён: 1697 смен знака. Невозвратный транзиент **не семплирует инвариантную меру** — $\mathcal{A}_R$ у него нет. Сам путь — кривая размерности 1, но это другая величина.



— the path itself: dimension 1 —●— fast forcing —■— slow forcing —◆— transient


- Меняем *только* W_T , всё остальное заморожено: на транзиенте статистика идёт от 1.20 до 174, на торе стоит. При $W_T = 0$ она даёт размерность *самого пути*; при $W_T = 76$ — ничего.
- **(b)** почему: ближайшая точка у тора — в 2554 шагах, у транзиента — в 6. Запрет отнимает у одного всё, у другого ничего.

Шум входит в оценку: 2.5 % шума дают 11 вместо 1




--- clean-drive truth —●— clean drive -▲- + 2.5 % noise + real mini-batch

- Шум в 2.5 % от амплитуды дрейфа: при $d_{\text{act}} = 1$ оценка уезжает на 11.3 и дальше почти не зависит от r .
- Пунктир — истина *чистого* дрейфа. У шумных ветвей occupation-мера может существовать, но её размерность считает **и направления, возбуждённые шумом** — это не та величина.




- Диагностика: считаем оценку при E и при $2E$. Если это размерность множества, удвоение вложения её не меняет, и $\rho_{\text{ident}} \approx 1$; если оценка следует за E , она уезжает.
- Два разных механизма шума — гауссово форсирование шага и честный мини-батч — дают **один** вердикт $\rho_{\text{ident}} \approx 1.55$. Транзиент уезжает ещё дальше.

У grokking'a оценка на дешёвом логe падает вдвое на переходе



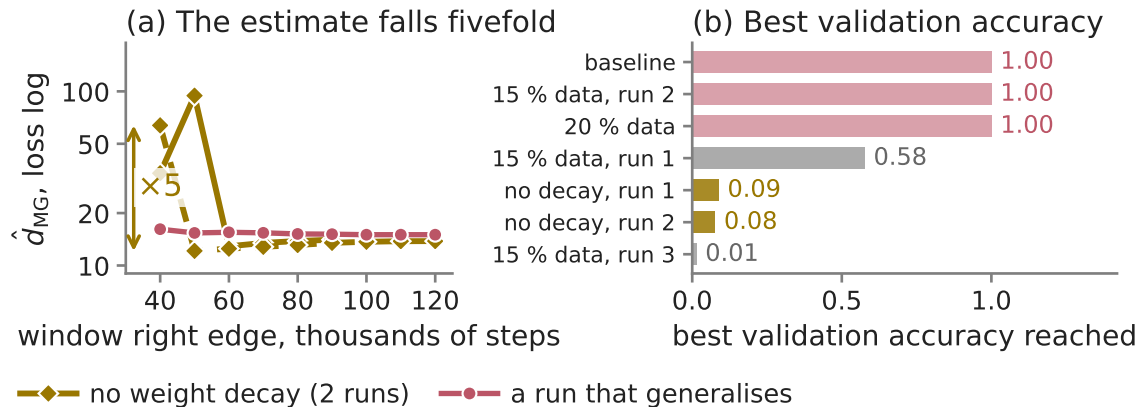
- Трансформер: 4 запуска с weight decay обобщают, 2 без него — нет; всё выровнено по шагу генерализации t_{gen} .
- (c) по столбцу на запуск, сверху 4 обобщающих (розовые), снизу 2 без weight decay (золотые): глубина $\times 2-3$ при $p \leq 0.075$ против $\times 1$ при $p \geq 0.95$.

Почему уровень читать нельзя 1: обе постановки вне области




- Задача: попадает ли опубликованный grokking в область, где оценку можно называть размерностью? Точка — один лог, по x число пересечений своего тренда, по y — ρ_{ident} .
- Зона — оба условия сразу. В ней нет никого: полнобатчевые пересекают тренд дважды, у трансформеров $\rho_{\text{ident}} \approx 1.5$.

Почему уровень читать нельзя 2: падение бывает без обобщения




- (a) два запуска без weight decay: оценка на логe лосса падает впятеро.
- (b) а валидация у них так и остаётся на уровне шума, 0.08–0.09 против 1.00 у обобщающих.

Почему уровень читать нельзя 3: есть механизм без размерности




- Истина всё время одна, $r = 4$; меняем по одному фактору, который размерность не задевает. Серые почти ничего не двигают.
- Два розовых — рост амплитуды и рост усиления лог — дают +1.5 компоненты. Ровно это и делает растущая норма параметров.

Но это не ложная тревога: система там правда упрощается




- **(a)** у обоих запусков без weight decay норма растёт на **100 %** логируемых шагов — это и есть скатывание в тупое наращивание нормы.
- **(b)** у одного из них ранг пути ровно 1.00: всё движение сводится к одному направлению.
Оценка говорит «стало проще» — и не врёт.

Прямое измерение: у перехода траектория сжимается и разжимается




- Меряем эффективный ранг траектории напрямую — по проекции каждого шага в $\mathbb{R}^{1024}$ (её цена в резерве). Ранг коллапсирует у перехода почти до единицы и **снова расширяется**; у контролей без weight decay (t_{gen} нет, выровнены по парному) этого не видно.
- (c) снимает возражение «траектория встала»: путь достигает дна позже и не возвращается.

Глубина падения запуски не разделяет



- Во сколько раз упал ранг у перехода: $\times 2.2$ – $\times 5.2$. У контролей перехода нет, поэтому их выравнивают по t_{gen} парного запуска той же задачи — выходит $\times 1.0$ – $\times 1.2$.
- Засечка снимает вопрос о выравнивании: самое глубокое падение где угодно в том же контроле — 2.39, столько же, сколько у одного обобщающего. Порога по глубине нет.

Разделяют время падения и возврат




--- a fixed absolute step ● minimum, parameters ▲ minimum, function space

- t_{gen} у четырёх запусков различаются вчетверо (3.7–13.7 тыс. шагов), а минимум у каждого лежит в пределах 1.6 тыс. шагов от своего t_{gen} — и в параметрах, и в функциях.
- Пунктир — где лежал бы минимум, если бы коллапс случался на фиксированном абсолютном шаге. Точки на нём не лежат.


Итоги: сигнал об упрощении есть, размерности в нём нет

1. Где $\hat{d}_{MG}(\mathcal{W})$ можно назвать $d_{act}(R)$. В детерминированном и возвратном режиме с согласованным лагом — до потолка ≈ 8 компонент. Держит схема «задержки + соседи»; конкретный оценщик почти не важен.
2. В **grokking'e** — нельзя. Диагностики отвергают обе постановки; окно у перехода не обязано семплировать одну стационарную меру. Поэтому падение — **сигнал, скоррелированный с переходом**; измерением $d_{act}(R)$ его называть нельзя.
3. **Но как детектор упрощения метод работает.** И у обобщающих запусков, и без weight decay он ловит реальное событие: там — временное сжатие у перехода, здесь — скатывание в рост нормы с траекторией ранга 1. Ложных тревог нет; есть неразличение *вида* упрощения.
4. **Вид различает прямое измерение.** Сжатие у grokking'a временное и *обращается*, у запуска без weight decay — постоянное. Разделяют время и возврат; глубина — нет.

- Нужен возвратный режим и лаг, согласованный с периодом, которого лог не выдаёт. Выше ≈ 8 компонент оценка только порядковая, и линейный PR по задержкам почти не хуже.
- Условие про **устойчивый диапазон скейлинга** мы не проверяем: r_1, r_2 задаются самими расстояниями до соседей, отбора области нет. Для шумного режима это очевидное улучшение протокола, для транзиента бесполезное — там все двадцать расстояний лежат в полосе шириной 13 %.
- Коллапс — четыре запуска против двух, разделённых weight decay, который заодно двигает норму. Метка ставится только *после* перехода.
- В полнобатчевой постановке результат не воспроизводится.
- У двух запусков без weight decay лог нормы почти прямой, и оценка на нём гуляет на три тысячных компоненты. Их $D \approx 1$ значит, что наблюдатель не дал оценщику структуры, а не что размерность не падала: **отрицательным контролем они не служат**.




- Задача: измерения слайдов 22–24 идут не по всем 227 тыс. параметров, а по случайной проекции каждого шага в $\mathbb{R}^{1024}$ (CountSketch). Проверяем, что проекция не портит ранг.
- (a)** на траекториях известного ранга сжатая оценка расходится с несжатой не больше чем на 0.11; **(b)** памяти в 36 раз меньше при $+6\%$ времени.



- (a)** каждый ранг поделён на свою истину. Окно задержки должно покрывать заметную долю периода; лог обучения периода не даёт.
- (b)** при амплитудах фаз q^l размерность остаётся r , а эффективный ранг падает. Оценка следует за *размерностью*.


Резерв: падение не объясняется гладкостью лога



- Суррогат хранит спектр и значения лога, но перемешивает фазы: гладкость та же, структура разрушена.
- **Кружок правее полосы** — просел глубже собственных суррогатов; полоса — их 5–95 процентиль, p — доля упавших не мельче. У контролей своего t_{gen} нет, окно взято у парного, но сравнение всё равно только с собой.


Резерв: четыре формы облака и оценка на каждой

one phase
driven




$$d_{\text{act}}(R) = 1$$
$$\hat{d}_{\text{MG}} = 1.2$$

two phases
driven



$$d_{\text{act}}(R) = 2$$
$$\hat{d}_{\text{MG}} = 2.2$$

transient:
traversed once



no invariant measure

$$\hat{d}_{\text{MG}} \approx 16$$

batch noise
alone



noise counted too

$$\hat{d}_{\text{MG}} \approx 15$$

grey: the estimand. Coloured: the estimate.

- Плоскость первых двух delay-координат — то множество, по которому идёт поиск соседей. У двух возвратных случаев оно заполнено, и оценка совпадает с истиной.
- У транзientа ≈ 16 : величина на пределе исключения, размерностью она не является.